

Super Apéndice B

Guía completa, paso a paso, del paper PANN
(Physics-Augmented Neural Networks and Projection-Based
Reduced-Order Models for Anisotropic Hyperelasticity)

Notas de estudio, construidas junto con Claude

Documento vivo: se construye por capítulos, uno a la vez

Cómo usar este documento: este NO es el paper. Es un compañero de estudio, mucho más largo y mucho más lento, que existe para que ninguna idea del paper se dé por sentada. Cada vez que el paper mencione un objeto por primera vez (por ejemplo $\mathbf{F}$), aquí encontrarás un capítulo dedicado exclusivamente a explicar ese objeto desde cero, con ejemplos numéricos concretos y gráficas reales. Vamos a construirlo un capítulo a la vez, para que puedas leer y digerir cada uno antes de seguir con el siguiente. Este documento cumple dos funciones a la vez: es un **resumen ejecutivo** (las páginas que siguen, autocontenidas, pensadas para enviarse solas) y, después, una **guía completa capítulo a capítulo** que demuestra cada afirmación del resumen desde cero.

Resumen ejecutivo

El problema, en una frase

Queremos una energía elástica $W(\mathbf{F})$ para un material anisotrópico (con direcciones preferentes, como fibras) que sea **físicamente admisible** (termodinámicamente consistente, objetiva, simétrica, nula sin deformación, polyconvexa, y con el crecimiento correcto en los extremos) y que además reproduzca bien la respuesta real medida en este RVE. Construimos esa energía con una red neuronal *input-convex* (ICNN) aplicada, no a $\mathbf{F}$ directamente, sino a quince números diseñados para que la admisibilidad sea automática.

La fórmula completa, de un vistazo

$$W_{\text{pc}}(\mathbf{F}) = \underbrace{\Phi_{\theta}(\mathbf{z}_{\text{pc}}(\mathbf{F}))}_{\text{red neuronal}} - \underbrace{\Phi_{\theta}(\mathbf{z}_{\text{pc}}(\mathbf{I}))}_{\text{normalización}} - \underbrace{r \log J}_{\text{barrera de colapso}} + \underbrace{\frac{\beta}{2}(J-1)^2}_{\text{rigidez volumétrica}}. \quad (1)$$

Todo el resto de este documento explica, pieza por pieza, de dónde sale cada símbolo de esta línea. Por ahora, un diccionario rápido:

- $\mathbf{F}$: el gradiente de deformación, una matriz 2×2 (Capítulo 1).
- $\mathbf{z}_{\text{pc}}(\mathbf{F}) \in \mathbb{R}^{15}$: un vector de quince números contruidos a partir de $\mathbf{F}$ (la lista completa, abajo).
- $\Phi_{\theta} : \mathbb{R}^{15} \rightarrow \mathbb{R}$: una red neuronal *input-convex* (ICNN) con anchos (64, 64, 32), activaciones Softplus, y **todos** sus pesos restringidos a ser ≥ 0 en cada capa.
- $J = \det \mathbf{F}$: el cambio de volumen (área, en 2D).
- $r > 0, \beta > 0$: dos escalares aprendidos durante el entrenamiento (valores reales del modelo: $r = 2.0390e - 01, \beta = 2.2357e - 09$).

Qué garantiza cada pieza

Condición	Qué exige	Qué, en la fórmula, la garantiza
(C1) Consistencia termodinámica	$\boldsymbol{\sigma}^T \dot{\boldsymbol{\varepsilon}} - \dot{W} \geq 0$	Automático: $\boldsymbol{\sigma} := \partial W / \partial \boldsymbol{\varepsilon}$ es un gradiente.
(C2) Objetividad	$W(\mathbf{Q}\mathbf{F}) = W(\mathbf{F})$	$\mathbf{z}_{\text{pc}}$ se construye solo de $\mathbf{C}$, $\text{cof } \mathbf{C}$, J (Cap. 3, 8).
(C3) Simetría	$\mathbf{S} = \mathbf{S}^T$	Incorporada en la notación de ingeniería $(E_{11}, E_{22}, \gamma_{12})$.
(C4) Normalización	$W(\mathbf{0}) = 0, \boldsymbol{\sigma}(\mathbf{0}) = \mathbf{0}$	La resta $-\Phi_\theta(\mathbf{z}_{\text{pc}}(\mathbf{I}))$ y el escalar r (próximo capítulo).
(C5) Polyconvexidad	$W = G(\mathbf{F}, \text{cof } \mathbf{F}, J), G$ convexa	Φ_θ convexa y monótona en cada bloque (Cap. 4–8).
(C6) Crecimiento	$W \rightarrow \infty$ en los extremos	$-r \log J + \frac{\beta}{2}(J-1)^2$ (colapso y volumen, Cap. 10) y $Q_{k,3} \geq \frac{1}{4} \mathbf{F} ^6$ (estiramiento, Cap. 9).

Los tres bloques cinemáticos

Todo se construye a partir de tres objetos (la terna de Ball): $\mathbf{F}$ (cómo se transforman vectores tangentes, Capítulo 1), $\text{cof } \mathbf{F}$ (cómo se transforman normales y áreas, Capítulo 5), y $J = \det \mathbf{F}$ (cómo se transforma el volumen). Φ_θ se pide convexa en estos tres bloques *tratados como variables independientes*: ese es el truco de lifting de Ball (Capítulo 4) que permite polyconvexidad sin exigir convexidad imposible en $\mathbf{F}$ directamente.

Las quince features

$$\mathbf{z}_{\text{pc}} = \left(I_1, \{Q_{k,2}^F, Q_{k,3}^F, Q_{k,2}^H, Q_{k,3}^H\}_{k=1}^3, J, J^2 \right) \in \mathbb{R}^{15}. \quad (2)$$

$I_1 = \text{tr } \mathbf{C} = |\mathbf{F}|^2$ es el único invariante clásico usado (Capítulo 6: los demás, por sí solos, forzarían isotropía). Los $Q_{k,p}^F = \sum_i w_{ki} (\mathbf{d}_{ki} \cdot \mathbf{C} \mathbf{d}_{ki})^p$ y $Q_{k,p}^H$ (idénticos pero con $\text{cof } \mathbf{C}$) miden estiramiento en tres sistemas de direcciones *balanceados* (Capítulo 7), a potencias $p = 2, 3$ (Capítulo 8). **Nota de honestidad**, ya discutida a fondo y reflejada en el paper: $Q_{k,2}^H = Q_{k,2}^F$ siempre en 2D (una redundancia real, demostrada, no solo observada); se mantiene por uniformidad con la receta general, no porque aporte información.

Mapa de capítulos

Cap.	Qué demuestra, desde cero
1	Qué es $\mathbf{F}$: columnas, área, los seis regímenes de J .
2	Por qué $\mathbf{F}$ solo no basta (objetividad); $\mathbf{C} = \mathbf{F}^T \mathbf{F}$; $\mathbf{E}$; $J = \sqrt{\det \mathbf{C}}$.
3	Por qué W no puede ser convexa en $\mathbf{F}$; el truco de lifting de Ball; polyconvexidad.
4	Qué es $\text{cof } \mathbf{F}$ (normales y áreas); por qué es lineal en 2D y cuadrática en 3D.
5	Invariantes clásicos (I_1, I_2); por qué no bastan para anisotropía.
6	Direcciones balanceadas: la condición $\sum_i w_i \mathbf{d}_i \otimes \mathbf{d}_i = \mathbf{I}$, y por qué se exige también para $p \geq 2$.
7	Las features $Q_{k,p}^F, Q_{k,p}^H$; la redundancia exacta $Q_{k,2}^F = Q_{k,2}^H$ y su consecuencia arquitectónica.
8	La condición de crecimiento: $Q_{k,3} \geq \frac{1}{4} \mathbf{F} ^6$, vía Jensen.
9	La barrera volumétrica $-r \log J + \frac{\beta}{2}(J-1)^2$: por qué el colapso y el estiramiento en J necesitan un mecanismo propio, y el hallazgo honesto de que $-r \log J$ solo decrece sin límite cuando $J \rightarrow \infty$.
10	Qué es un ICNN; la regla de composición convexa-y-no-decreciente; por qué todos los pesos deben ser ≥ 0 ; casi toda la Proposición de polyconvexidad.
11	Por qué $\boldsymbol{\sigma}(\mathbf{0}) = \mathbf{0}$ exactamente: los quince gradientes isotrópicos, el escalar r , verificado end-to-end con la red real.
12	ICKAN: splines en vez de pesos; puntos de control con dos sumas acumuladas; por qué todas las demostraciones se trasladan sin cambios.
13	Un FE ² genuino en Cook: por qué D-HPROM-ANN y HPROM-ANN se atascaban aunque fueran precisos, y cómo se resolvió; convexidad rank-one sin necesitar energía.
14+	(en construcción) El resto de los resultados numéricos del paper, en orden.

A partir de aquí, el documento cambia de modo: en vez de resumir, **demuestra**. Cada afirmación de las páginas anteriores se deriva desde cero, con números propios y figuras reales, empezando por la pregunta más simple de todas: ¿qué es $\mathbf{F}$?

Contents

1	El gradiente de deformación $\mathbf{F}$	5
1.1	El escenario físico	5
1.2	La forma matricial en 2D	6
1.3	La pregunta más importante: ¿qué le pasa a los vectores de la base?	6
1.4	El determinante: cambio de área	6
1.5	Seis ejemplos, para que se vea con los ojos	7
1.6	Resumen de este capítulo	8
2	El macro-stress: ¿promedio simple, o algo más sutil?	9
2.1	El escenario: un RVE con un agujero libre	9
2.2	La opción obvia: promediar el stress microscópico	9
2.3	El problema: aquí no hay periodicidad	9
2.4	La solución: el stress exactamente conjugado energéticamente	9
2.5	El atajo gratis: el teorema de la envolvente	10
2.6	Verificado con números reales	10
2.7	¿Y qué tiene que ver esto con MAW-ECM?	10
3	Por qué $\mathbf{F}$ solo no basta: objetividad y la aparición de $\mathbf{C}$	11
3.1	El problema: gira el objeto ya deformado, y $\mathbf{F}$ cambia	11
3.2	¿Qué es exactamente una rotación $\mathbf{Q}$ en 2D?	12
3.3	La solución: $\mathbf{C} = \mathbf{F}^T \mathbf{F}$	12
3.4	Qué significa $\mathbf{C}$ físicamente: longitudes al cuadrado	13

3.5	De $\mathbf{C}$ a $\mathbf{E}$: la deformación de Green–Lagrange	14
3.6	J en términos de $\mathbf{C}$, y por qué $\mathbf{C} \succ 0$ importa	14
3.7	Resumen de este capítulo	14
4	El truco de lifting de Ball, y la definición de polyconvexidad	14
4.1	Qué esperábamos de la convexidad (y qué vamos a perder)	14
4.2	Por qué W no puede ser convexa en $\mathbf{F}$	16
4.3	Un ejemplo muy concreto de que $\det \mathbf{F}$ no es convexo	16
4.4	La silla de montar	16
4.5	El mecanismo de Ball, y qué promete exactamente	17
4.6	La definición real: $\mathbf{F}$, $\text{cof } \mathbf{F}$ y $\det \mathbf{F}$ como tres bloques	18
4.7	¿Y qué pasa con la objetividad ahora?	19
4.8	Resumen de este capítulo	19
5	El cofactor $\text{cof } \mathbf{F}$: qué es, y qué hace de verdad	20
5.1	El problema: las normales no se comportan como los vectores tangentes	20
5.2	La solución: $\text{cof } \mathbf{F}$	20
5.3	Por qué funciona: una identidad algebraica de tres líneas	21
5.4	La sutileza de 2D: $\text{cof } \mathbf{F}$ es lineal, no cuadrático	22
5.5	Resumen de este capítulo	22
6	Invariantes clásicos: qué son, y por qué no bastan	24
6.1	¿Qué es un invariante?	24
6.2	Los invariantes clásicos	24
6.3	El problema: los invariantes clásicos olvidan la orientación	24
7	Direcciones balanceadas: cómo se construye la anisotropía	26
7.1	El problema: I_1 no basta, y ya sabemos por qué	26
7.2	La idea: promediar (con pesos) sobre varias direcciones	26
7.3	La regla: la condición de balance	26
7.4	Resolviéndolo: un sistema lineal 3×3	27
7.5	¿Y si $p = 2$ o $p = 3$? El balance protege algo distinto	27
7.6	Resumen de este capítulo	29
8	Las features $Q_{k,p}^F$ y $Q_{k,p}^H$, y una redundancia sorprendente	30
8.1	Recordatorio: el bloque F	30
8.2	¿Por qué no basta con el bloque F ?	30
8.3	Una sorpresa: verifiquemos $Q_{k,2}^F$ y $Q_{k,2}^H$ con números	30
8.4	Por qué $Q_{k,2}^F = Q_{k,2}^H$ siempre , en 2D	31
8.5	¿Y en $p = 3$? Ahí sí aparece información nueva	31
8.6	Ensamblando las quince features	32
8.7	Una decisión honesta: ¿quince inputs, o doce?	32
8.8	Resumen de este capítulo	33
9	La condición de crecimiento: por qué $Q_{k,3} \geq \frac{1}{4} \mathbf{F} ^6$	33
9.1	Para qué sirve esto	33
9.2	El ingrediente: Jensen, aplicado exactamente donde x^3 sí es convexa	33
9.3	La demostración, en tres líneas	34
9.4	¿Es la cota ajustada alguna vez?	34
9.5	Lo mismo para el bloque H	34
9.6	¿Y $p = 2$?	35
9.7	Resumen de este capítulo	35

10 La barrera volumétrica: por qué hace falta $-r \log J + \frac{\beta}{2}(J-1)^2$	35
10.1 Lo que el Capítulo 9 todavía no cubre	35
10.2 El primer término: por qué $-r \log J$ es una barrera de colapso	36
10.3 Un hallazgo honesto: $-r \log J$ solo, no explota cuando $J \rightarrow \infty$	36
10.4 El segundo término: por qué hace falta $\frac{\beta}{2}(J-1)^2$	36
10.5 ¿Cuándo le gana el cuadrático al logaritmo, con los números reales?	36
10.6 Resumen de este capítulo	37
11 La red Φ_θ: qué es un ICNN, y por qué es convexa por construcción	38
11.1 ¿Qué problema nos falta resolver?	38
11.2 Repaso relámpago: qué es una red neuronal	38
11.3 El truco de un solo escalón: pesos no-negativos + activación convexa no-decreciente	38
11.4 Por qué “no-decreciente” no es un detalle menor	39
11.5 La regla de composición vectorial: quince entradas a la vez	39
11.6 Por qué Softplus	40
11.7 Por qué <i>todos</i> los pesos, no solo los de la primera capa	40
11.8 Uniendo todo: casi tenemos la Proposición de polyconvexidad	41
11.9 Resumen de este capítulo	41
12 La tensión cero en la referencia: por qué $\sigma(0) = 0$ exactamente	41
12.1 ¿Qué falta demostrar, exactamente?	41
12.2 Un hecho que ya conocemos: el Lema del Capítulo 5	42
12.3 Cada una de las quince features tiene un gradiente isotrópico en la referencia . . .	42
12.4 Verificado con la red real entrenada	43
12.5 De quince gradientes a uno solo: la regla de la cadena	43
12.6 El término de barrera apunta en la misma dirección	43
12.7 El escalar r : diseñado para cancelar exactamente	43
12.8 Verificado con la red real: el resultado final	44
12.9 Resumen de este capítulo	44
13 El segundo núcleo convexo: ICKAN	45
13.1 ¿Por qué un segundo núcleo, si ya funciona el primero?	45
13.2 Qué es una red Kolmogorov–Arnold (KAN)	45
13.3 Cómo se fuerza una curva a ser convexa y no-decreciente: dos sumas acumuladas .	45
13.4 De un borde a toda la red: la misma regla de composición	46
13.5 Resumen de este capítulo	46
14 Cook con un FE^2 de verdad: por qué el ROM se atascaba, y cómo se resolvió	47
14.1 Tres formas de responder la misma pregunta	47
14.2 La pregunta que no tenía sentido	48
14.3 Cuatro sospechosos, revisados uno por uno	48
14.4 El verdadero culpable: la resta que se come los dígitos	49
14.5 La solución, y por qué no cambia nada del modelo	50
14.6 Un bono: revisando la convexidad rank-one sin necesitar energía	50
14.7 Resumen de este capítulo	50

1 El gradiente de deformación F

1.1 El escenario físico

Imagina un objeto sólido antes de deformarse. A esta versión “antes” la llamamos **configuración de referencia**, y a cada punto material dentro de ella lo llamamos $\mathbf{X}$ (mayúscula, para recordar que es la posición *original*).

Ahora deformamos el objeto: lo estiramos, lo comprimimos, lo cortamos, lo giramos. Cada punto material $\mathbf{X}$ termina en una nueva posición $\mathbf{x}$ (minúscula), en lo que llamamos la **configuración actual** o **deformada**.

El **gradiente de deformación** $\mathbf{F}$ es, por definición, el objeto que describe cómo cambia esa correspondencia punto a punto, de forma *local*:

$$\mathbf{F} := \frac{\partial \mathbf{x}}{\partial \mathbf{X}}. \quad (3)$$

En palabras: $\mathbf{F}$ te dice, si mueves un poquito el punto material de referencia en cierta dirección, cuánto y en qué dirección se mueve su imagen deformada.

En este proyecto trabajamos con **deformaciones homogéneas**: $\mathbf{F}$ es la misma matriz constante en todo el cuerpo (no cambia de punto a punto). En ese caso especial, la relación completa entre $\mathbf{X}$ y $\mathbf{x}$ se puede escribir simplemente como

$$\mathbf{x} = \mathbf{F}\mathbf{X} \quad (4)$$

(o $\mathbf{x} = \mathbf{F}(\mathbf{X} - \mathbf{X}_c) + \mathbf{x}_c$ si medimos posiciones desde un centro $\mathbf{X}_c$ que no se mueve; esto es exactamente lo que hace `fom_solver_rve.py` al imponer la condición de contorno del RVE). Por ahora, para entender qué *es* $\mathbf{F}$, basta con (4).

1.2 La forma matricial en 2D

En nuestro problema (2D), $\mathbf{F}$ es una matriz 2×2 :

$$\mathbf{F} = \begin{pmatrix} a & b \\ c & d \end{pmatrix}. \quad (5)$$

Cuatro números, $a, b, c, d \in \mathbb{R}$, describen completamente la deformación local (siempre que sea homogénea).

1.3 La pregunta más importante: ¿qué le pasa a los vectores de la base?

La forma más directa de entender qué *hace* una matriz es preguntar qué le hace a los vectores de la base canónica,

$$\mathbf{e}_1 = \begin{pmatrix} 1 \\ 0 \end{pmatrix}, \quad \mathbf{e}_2 = \begin{pmatrix} 0 \\ 1 \end{pmatrix}. \quad (6)$$

Multiplicando:

$$\mathbf{F}\mathbf{e}_1 = \begin{pmatrix} a \\ c \end{pmatrix}, \quad \mathbf{F}\mathbf{e}_2 = \begin{pmatrix} b \\ d \end{pmatrix}. \quad (7)$$

Es decir: **la primera columna de $\mathbf{F}$ es dónde termina el primer vector de la base, y la segunda columna es dónde termina el segundo**. Esto no es una coincidencia de notación: es literalmente la definición de multiplicar una matriz por un vector, columna por columna.

Como el cuadrado unidad de referencia (con vértices en $(0, 0)$, $(1, 0)$, $(1, 1)$, $(0, 1)$) está generado exactamente por $\mathbf{e}_1$ y $\mathbf{e}_2$, conocer $\mathbf{F}\mathbf{e}_1$ y $\mathbf{F}\mathbf{e}_2$ es suficiente para saber en qué paralelogramo se convierte ese cuadrado.

1.4 El determinante: cambio de área

El determinante de $\mathbf{F}$,

$$J := \det \mathbf{F} = ad - bc, \quad (8)$$

mide *cuánto cambia el área* de cualquier región al aplicar $\mathbf{F}$. Concretamente, si una región de referencia tiene área A_0 , su imagen deformada tiene área $|J| A_0$ (el valor absoluto importa; el signo de J es harina de otro costal, veámoslo abajo).

1.5 Seis ejemplos, para que se vea con los ojos

La Figura 1 muestra el cuadrado de referencia (línea discontinua gris), su imagen deformada (verde), y las dos columnas $\mathbf{F}\mathbf{e}_1$ (rojo) y $\mathbf{F}\mathbf{e}_2$ (azul), para seis matrices concretas. Vamos uno por uno.

El cuadrado de referencia (línea discontinua) y su imagen bajo $\mathbf{F}$ (verde), con las columnas $\mathbf{F}\mathbf{e}_1$ (rojo) y $\mathbf{F}\mathbf{e}_2$ (azul)




Figure 1: El cuadrado unidad de referencia y su imagen bajo seis matrices $\mathbf{F}$ distintas, cubriendo los cinco regímenes de J descritos en el texto (más un ejemplo de corte puro).

Ejemplo 1 (Identidad (panel 1)). $\mathbf{F} = \mathbf{I} = \text{diag}(1, 1)$. Entonces $\mathbf{F}\mathbf{e}_1 = (1, 0)^T$ y $\mathbf{F}\mathbf{e}_2 = (0, 1)^T$: los vectores de la base no se mueven. El cuadrado deformado coincide exactamente con el de referencia (por eso no se distingue la línea discontinua del relleno verde). El determinante es

$$J = (1)(1) - (0)(0) = 1 :$$

área exactamente conservada. Éste es el estado “sin deformar”, $\mathbf{F} = \mathbf{I}$, que usaremos constantemente como punto de referencia en el resto del paper.

Ejemplo 2 (Estiramiento que duplica el área (panel 2)). $\mathbf{F} = \text{diag}(2, 1)$. Entonces $\mathbf{F}\mathbf{e}_1 = (2, 0)^T$ (el vector horizontal se duplica en longitud) y $\mathbf{F}\mathbf{e}_2 = (0, 1)^T$ (el vector vertical no cambia). El cuadrado se convierte en un rectángulo el doble de ancho. El determinante es

$$J = (2)(1) - (0)(0) = 2,$$

exactamente el factor por el que creció el área (el cuadrado tenía área 1; el rectángulo tiene área $2 \times 1 = 2$).

Ejemplo 3 (Compresión isotrópica (panel 3)). $\mathbf{F} = \text{diag}(0.5, 0.5)$. Ambos vectores de la base se reducen a la mitad de su longitud: $\mathbf{F}\mathbf{e}_1 = (0.5, 0)^T$, $\mathbf{F}\mathbf{e}_2 = (0, 0.5)^T$. El cuadrado se encoge uniformemente. El determinante es

$$J = (0.5)(0.5) - 0 = 0.25,$$

consistente con que el área del cuadrado pequeño es $0.5 \times 0.5 = 0.25$ veces la original.

Ejemplo 4 (Colapso (panel 4)). $\mathbf{F} = \text{diag}(2, 0)$. Aquí $\mathbf{F}\mathbf{e}_1 = (2, 0)^T$ pero $\mathbf{F}\mathbf{e}_2 = (0, 0)^T$: **el segundo vector de la base desaparece por completo**, se colapsa al origen. El cuadrado, que tenía área, se aplasta en un segmento de recta (sin altura, área cero). El determinante es

$$J = (2)(0) - (0)(0) = 0.$$

Físicamente, esto representaría un material aplastado hasta volumen (área, en 2D) cero: una configuración no admisible, en la que esperamos que cualquier energía elástica razonable explote a $+\infty$ (esta es exactamente la condición de crecimiento, (C6), que el paper impone más adelante con el término $-r \log J$).

Ejemplo 5 (Reflexión (panel 5)). $\mathbf{F} = \text{diag}(-1, 1)$. Ahora $\mathbf{F}\mathbf{e}_1 = (-1, 0)^T$: el primer vector de la base se invierte, apunta en la dirección contraria. El cuadrado se refleja como en un espejo vertical. El determinante es

$$J = (-1)(1) - (0)(0) = -1.$$

El área en valor absoluto se conserva ($|J| = 1$), pero el signo negativo señala que **la orientación se invirtió**: si recorrías el borde del cuadrado original en sentido antihorario, ahora lo recorres en sentido horario. Físicamente, esto correspondería a que el material se “diera la vuelta” sobre sí mismo (como una tela que se voltea), algo que un sólido real no hace sin romperse. Por eso el paper exige $J > 0$ en todo momento (véase la discusión de $\mathbf{C}(\boldsymbol{\varepsilon}) \succ 0$ en la Sección 1 del paper principal).

Ejemplo 6 (Corte puro (shear) (panel 6)). $\mathbf{F} = \begin{pmatrix} 1 & 0.6 \\ 0 & 1 \end{pmatrix}$. Aquí $\mathbf{F}\mathbf{e}_1 = (1, 0)^T$ (el vector horizontal no cambia) pero $\mathbf{F}\mathbf{e}_2 = (0.6, 1)^T$ (el vector vertical se “inclina” hacia la derecha, sin cambiar su longitud vertical). El cuadrado se convierte en un paralelogramo inclinado, **sin cambiar de área**:

$$J = (1)(1) - (0.6)(0) = 1.$$

Este ejemplo es importante porque muestra que $J = 1$ (área conservada) **no** significa “nada cambió”: la forma cambió notablemente (el cuadrado ya no es un cuadrado), aunque el área sea la misma que en la identidad. Este tipo de deformación (cambio de forma sin cambio de volumen) es exactamente lo que en el paper se llama deformación isocórica, y es la razón por la que J por sí solo no basta para describir toda la deformación: hacen falta más invariantes (los que vienen en los próximos capítulos).

1.6 Resumen de este capítulo

Idea clave 1. • $\mathbf{F}$ es una matriz 2×2 que describe cómo un pequeño entorno de material se estira, comprime, corta o gira, localmente.

- Sus columnas, $\mathbf{F}\mathbf{e}_1$ y $\mathbf{F}\mathbf{e}_2$, son exactamente las imágenes de los vectores de la base: lo más directo posible para visualizar qué hace $\mathbf{F}$.
- $J = \det \mathbf{F}$ mide el cambio de área (en 2D) o volumen (en 3D).
- $J = 1$ conserva el área pero **no** implica que no haya deformación (ejemplo del corte); $J > 1$ expande; $0 < J < 1$ comprime; $J = 0$ es un colapso no físico; $J < 0$ invierte la orientación y tampoco es físicamente admisible.
- En este proyecto, $\mathbf{F}$ **no** es un dato libre: se construye a partir de la deformación macroscópica $\boldsymbol{\varepsilon} = (E_{11}, E_{22}, \gamma_{12})$ mediante $\mathbf{F} = \mathbf{U} = \sqrt{2\mathbf{E}(\boldsymbol{\varepsilon}) + \mathbf{I}}$ (la raíz cuadrada simétrica, sin rotación); esto lo explicaremos con calma en el capítulo dedicado a $\mathbf{E}$ y $\mathbf{C}$.

Antes de seguir: relea los seis ejemplos y, para cada uno, verifica tú mismo con lápiz y papel que $\mathbf{F}\mathbf{e}_1$, $\mathbf{F}\mathbf{e}_2$ y J coinciden con lo que dice el texto.

2 El macro-stress: ¿promedio simple, o algo más sutil?

2.1 El escenario: un RVE con un agujero libre

Ya sabemos qué es $\mathbf{F}$ y cómo se usa para imponer una deformación macroscópica $\boldsymbol{\varepsilon}$ en el borde exterior del RVE (el cuadrado con el agujero). Pero una vez que el RVE ya se deformó y el solver ya convergió, queda una pregunta que parece trivial y no lo es: *si alguien te pregunta “¿cuál es el stress macroscópico de este RVE, para esta $\boldsymbol{\varepsilon}$?”, qué número exactamente le contestas?*

El borde exterior del RVE es Dirichlet: le imponemos el desplazamiento $\mathbf{u}_d(\boldsymbol{\varepsilon})$ exactamente, nodo por nodo. Pero el agujero del centro, y el resto de los nodos interiores, son **libres**: nadie les impone nada, simplemente se mueven a donde el equilibrio mecánico los lleve. Esta mezcla (parte Dirichlet, parte libre) es la que hace que la pregunta de arriba no tenga una respuesta única y obvia.

2.2 La opción obvia: promediar el stress microscópico

Lo primero que a cualquiera se le ocurriría es: ya tenemos el stress $\mathbf{S}_{e,g}$ (segundo Piola–Kirchhoff) en cada punto de Gauss g de cada elemento e del RVE, así que promediémoslo, pesado por el volumen de cada punto de Gauss:

$$\bar{\mathbf{S}}_{\text{naive}} := \frac{1}{|\Omega_0|} \sum_{e,g} \mathbf{S}_{e,g} w_{e,g}. \quad (9)$$

Esto es exactamente lo que su nombre indica: un promedio de volumen, sin ningún truco. Y para un RVE con condiciones de contorno **periódicas** (la convención más común en homogeneización de celdas unitarias idealizadas), este promedio simple sí es, por un teorema clásico (la condición de Hill–Mandel), exactamente el stress macroscópico correcto, automáticamente, sin nada más que demostrar.

2.3 El problema: aquí no hay periodicidad

El RVE de este proyecto **no** usa condiciones periódicas: usa Dirichlet afín en el borde exterior, y deja el agujero completamente libre. La condición de Hill–Mandel que garantiza automáticamente que el promedio simple sea correcto **no aplica** a esta mezcla de Dirichlet y libre (el apéndice del paper principal, “The periodic-boundary-condition averaging identity, in full”, da la identidad exacta y explica por qué se rompe aquí). En otras palabras: para este RVE, el promedio simple (9) y el verdadero stress macroscópico “correcto” pueden, en principio, ser números distintos.

Y no es solo una posibilidad teórica remota: se verificó directamente, para el estado convergido de HPROM–ANN en este mismo proyecto, que el promedio simple y el stress correcto (el que se explica abajo) difieren en aproximadamente un 30%. Esa no es una diferencia de redondeo, es una diferencia real que importaría mucho si la ignoráramos.

2.4 La solución: el stress exactamente conjugado energéticamente

Si el promedio simple no sirve, ¿cuál es la definición correcta? La respuesta viene de la energía, no del stress directamente. Sea $W_{\text{RVE}}(\boldsymbol{\varepsilon})$ la energía total almacenada en el RVE, ya convergido, para una $\boldsymbol{\varepsilon}$ dada. El stress macroscópico **correcto**, por definición, es

$$\bar{\mathbf{S}} := \frac{\partial W_{\text{RVE}}}{\partial \boldsymbol{\varepsilon}}, \quad (10)$$

es decir: cuánto cambia la energía total del RVE si empujamos un poquito más la deformación macroscópica. Esta es, por construcción, la definición que hace que el trabajo macroscópico $\bar{\mathbf{S}} \cdot d\boldsymbol{\varepsilon}$ sea exactamente el trabajo real hecho sobre el RVE. Por eso se le llama “exactamente conjugada energéticamente”.

Calcular $\partial W_{\text{RVE}}/\partial \boldsymbol{\varepsilon}$ directamente sonaría caro: parecería que hay que volver a resolver el RVE varias veces, perturbando $\boldsymbol{\varepsilon}$ y usando diferencias finitas. Pero hay un atajo exacto, gratis, que no necesita ningún resolver adicional: el **teorema de la envolvente**.

2.5 El atajo gratis: el teorema de la envolvente

En el estado convergido, $\mathbf{u}_f$ ya satisface el equilibrio, $\mathbf{r}(\mathbf{u}_f; \boldsymbol{\varepsilon}) = \mathbf{0}$, lo cual es exactamente la condición $\partial W_{\text{RVE}}/\partial \mathbf{u}_f = \mathbf{0}$ (la energía es estacionaria respecto a los grados de libertad libres, en el equilibrio). Si ahora perturbamos $\boldsymbol{\varepsilon}$ un poquito, la regla de la cadena dice

$$\frac{dW_{\text{RVE}}}{d\boldsymbol{\varepsilon}} = \underbrace{\frac{\partial W_{\text{RVE}}}{\partial \mathbf{u}_f}}_{=\mathbf{0} \text{ (equilibrio)}} \cdot \frac{d\mathbf{u}_f}{d\boldsymbol{\varepsilon}} + \left. \frac{\partial W_{\text{RVE}}}{\partial \boldsymbol{\varepsilon}} \right|_{\mathbf{u}_f \text{ fijo}}. \quad (11)$$

El primer término se anula exactamente, sin aproximar nada, porque $\mathbf{u}_f$ está en equilibrio. Eso significa que **no necesitamos saber cómo cambia $\mathbf{u}_f$ con $\boldsymbol{\varepsilon}$** (que es precisamente lo caro de calcular): basta la derivada parcial con $\mathbf{u}_f$ congelado en su valor convergido. Y esa derivada parcial, evaluada en el nodo Dirichlet, resulta ser exactamente la suma pesada de las **fuerzas de reacción** en los nodos del borde exterior, las mismas fuerzas que el solver ya calculó para imponer $\mathbf{u}_d(\boldsymbol{\varepsilon})$. No hay que perturbar nada ni resolver de nuevo: las fuerzas de reacción del único solve ya convergido son suficientes.

2.6 Verificado con números reales

Este atajo no se quedó en teoría: se verificó directamente contra datos ya calculados de otra forma. En un subconjunto separado de los estados de entrenamiento (no usados para verificar nada más), el procedimiento de fuerzas de reacción reproduce el stress conjugado-energético ya guardado en el dataset de entrenamiento con un error relativo L^2 de

$$5.90 \times 10^{-10}, \quad (12)$$

es decir, precisión de máquina, no una aproximación. Solo después de esa verificación se usó el mismo atajo para HPROM-ANN y D-HPROM-ANN en la trayectoria de prueba.

2.7 ¿Y qué tiene que ver esto con MAW-ECM?

Si has leído la parte del paper sobre hiperreducción, es normal confundirse aquí: MAW-ECM (el método de cubatura adaptativa que usa HPROM-ANN) funciona justamente aproximando una suma completa por una suma dispersa, sobre unos pocos puntos de Gauss elegidos con cuidado. Entonces, ¿cómo se puede seguir usando la definición “correcta” (fuerzas de reacción) si HPROM-ANN ya solo tiene acceso a un puñado de puntos, no a todos?

La respuesta es que **MAW-ECM y el cálculo de fuerzas de reacción resuelven dos problemas distintos, en dos momentos distintos**, y no se estorban entre sí:

- **Durante el Newton iterativo** (encontrar el estado reducido convergido $\mathbf{q}_p$), sí, HPROM-ANN usa la suma dispersa de MAW-ECM (el conjunto $\mathcal{Z}$ del paper, unos 10 puntos de Gauss con pesos adaptativos) para que cada iteración sea barata. Esto se repite muchas veces por cada estado macroscópico, así que importa mucho que sea rápido.
- HPROM-ANN también tiene una salida “nativa” barata para el stress, calculada con **otro** conjunto disperso, $\mathcal{Z}_\sigma$ (típicamente distinto de $\mathcal{Z}$): es exactamente el promedio simple (9) de este capítulo, aproximado con pocos puntos. **Esta salida nativa es precisamente la que NO se reporta**, por la misma razón de todo este capítulo: el promedio simple no es el stress conjugado-energético correcto para este RVE.

- **Una vez que $\mathbf{q}_p$ ya convergió** (barato, gracias a MAW-ECM), se reconstruye el campo de desplazamiento **completo**, en **todos** los nodos del mesh original, no solo en los puntos de $\mathcal{Z}$ o $\mathcal{Z}_\sigma$, usando el mismo decoder ya entrenado ($\mathbf{u}_f \approx \mathbf{u}_f^{\text{aff}} + \mathbf{V}\mathbf{q} + \bar{\mathbf{V}}\mathcal{N}(\mathbf{q})$). Esta reconstrucción es barata: el decoder ya está entrenado, no hay que resolver nada.
- Con ese campo completo ya reconstruido, se hace **un ensamblaje completo, una sola vez** (todos los elementos del RVE original, con la ley microscópica verdadera, sin ningún subconjunto disperso) para sacar las fuerzas de reacción reales en los nodos Dirichlet, y de ahí el stress conjugado-energético, exactamente como en la sección anterior. Como esto se hace **una sola vez por estado convergido**, no en cada iteración, no le cuesta a HPROM-ANN la velocidad que ganó con MAW-ECM.

En código (carpeta `pann/direct_energy/`), esto vive en dos archivos distintos que no se pisan entre sí. `reaction_force_direct_stress.py` tiene el núcleo del cálculo, reutilizado sin modificar; `hprom_ann_direct_stress.py` reconstruye el campo completo de HPROM-ANN/D-HPROM-ANN y se lo pasa a ese mismo núcleo. El resultado, verificado contra el FOM verdadero en la trayectoria de prueba, es un error relativo de 0.174% para HPROM-ANN y 0.202% para D-HPROM-ANN. Preciso, y sin necesidad de que MAW-ECM apruebe nada al respecto, porque MAW-ECM ya terminó su trabajo (acelerar el Newton) antes de que este cálculo ni siquiera empiece.

Idea clave 2. • *Este RVE mezcla borde Dirichlet (el cuadrado exterior) con borde libre (el agujero); por eso el promedio simple del stress microscópico $\{\mathbf{S}_{e,g}\}$ **no** está garantizado a ser el verdadero stress macroscópico, a diferencia de lo que pasaría con condiciones periódicas.*

- *En este proyecto, promedio simple y stress correcto difieren en la práctica en aproximadamente 30% para HPROM-ANN: no es una diferencia hipotética.*
- *El stress macroscópico correcto es $\bar{\mathbf{S}} = \partial W_{\text{RVE}} / \partial \boldsymbol{\varepsilon}$ (exactamente conjugado energéticamente), y el teorema de la envolvente dice que, en el estado ya convergido, esto se puede leer directamente de las fuerzas de reacción del borde Dirichlet, sin resolver nada de nuevo.*
- *Este atajo se verificó contra datos independientes a precisión de máquina (5.90×10^{-10}) antes de confiar en él para cualquier resultado del paper.*
- *MAW-ECM y las fuerzas de reacción no compiten: MAW-ECM solo acelera el Newton iterativo (encontrar $\mathbf{q}_p$); una vez convergido, las fuerzas de reacción se calculan con un ensamblaje completo, una sola vez, sobre el campo reconstruido **completo**, no sobre los pocos puntos dispersos de MAW-ECM. Por eso el resultado final sigue siendo preciso (0.174% para HPROM-ANN, 0.202% para D-HPROM-ANN, contra el FOM verdadero).*

Antes de seguir: vuelve a leer, en el paper principal, la sección “Test-trajectory assessment: all six model variants” y busca, en su segundo párrafo, la misma cifra del 30% y el mismo error de 5.90×10^{-10} que acabas de ver aquí: son exactamente los mismos números, no una reexplicación independiente.

3 Por qué $\mathbf{F}$ solo no basta: objetividad y la aparición de $\mathbf{C}$

3.1 El problema: gira el objeto ya deformado, y $\mathbf{F}$ cambia

En el Capítulo 1 vimos que $\mathbf{F}$ describe cómo se deforma localmente un cuerpo. Ahora hagamos un experimento mental muy simple.

Toma el objeto *ya deformado* (el paralelogramo verde de cualquiera de nuestros ejemplos) y gíralo rígidamente en el espacio, sin estirarlo ni comprimirlo más, solo girándolo, como si lo

tomaras con la mano y lo rotaras. Físicamente, esto **no le añade ni le quita energía elástica almacenada**: el material sigue teniendo exactamente la misma cantidad de estiramiento interno, solo que ahora apunta en otra dirección del espacio. Esta idea tiene nombre propio:

Idea clave 3 (Objetividad, o *frame indifference*). *La energía elástica almacenada no puede depender de cómo está orientado el objeto ya deformado en el espacio: solo puede depender de cuánto se estiró o cortó internamente. En símbolos, si $\mathbf{Q}$ es cualquier rotación rígida,*

$$W(\mathbf{Q}\mathbf{F}) = W(\mathbf{F}).$$

Pero aquí está el problema numérico: si tomamos, por ejemplo, $\mathbf{F} = \text{diag}(2, 1)$ (nuestro ejemplo de estiramiento del Capítulo 1) y lo giramos 40° , la matriz resultante $\mathbf{Q}\mathbf{F}$ tiene entradas completamente distintas de $\mathbf{F}$ (lo verificamos numéricamente más abajo). Si construyéramos ingenuamente una energía W que dependiera de las entradas de $\mathbf{F}$ de cualquier forma arbitraria, casi con toda seguridad violaríamos $W(\mathbf{Q}\mathbf{F}) = W(\mathbf{F})$ por accidente. Necesitamos construir W a partir de *algún otro objeto* que, por construcción, no distinga entre $\mathbf{F}$ y $\mathbf{Q}\mathbf{F}$.

3.2 ¿Qué es exactamente una rotación $\mathbf{Q}$ en 2D?

Una rotación rígida de ángulo θ en 2D es la matriz

$$\mathbf{Q}(\theta) = \begin{pmatrix} \cos \theta & -\sin \theta \\ \sin \theta & \cos \theta \end{pmatrix}. \quad (13)$$

Dos propiedades algebraicas son las únicas que vamos a usar:

$$\mathbf{Q}^T \mathbf{Q} = \mathbf{I} \quad (\text{"ortogonal": preserva longitudes y ángulos}), \quad (14)$$

$$\det \mathbf{Q} = 1 \quad (\text{preserva la orientación, a diferencia de una reflexión}). \quad (15)$$

Puedes verificar $\mathbf{Q}^T \mathbf{Q} = \mathbf{I}$ tú mismo multiplicando (13) por su transpuesta y usando $\cos^2 \theta + \sin^2 \theta = 1$. El conjunto de todas estas matrices se llama $\text{SO}(2)$ (*special orthogonal group* en 2D), y es exactamente el conjunto $\mathbf{Q}$ que aparece en la condición de objetividad (C2) del paper.

3.3 La solución: $\mathbf{C} = \mathbf{F}^T \mathbf{F}$

Definimos

$$\mathbf{C} := \mathbf{F}^T \mathbf{F}. \quad (16)$$

Veamos qué le pasa a $\mathbf{C}$ cuando reemplazamos $\mathbf{F}$ por $\mathbf{Q}\mathbf{F}$:

$$(\mathbf{Q}\mathbf{F})^T (\mathbf{Q}\mathbf{F}) = \mathbf{F}^T \mathbf{Q}^T \mathbf{Q} \mathbf{F} = \mathbf{F}^T \underbrace{(\mathbf{Q}^T \mathbf{Q})}_{=\mathbf{I}} \mathbf{F} = \mathbf{F}^T \mathbf{F} = \mathbf{C}. \quad (17)$$

Ésa es toda la demostración. No hace falta nada más: el único ingrediente que se usó es $\mathbf{Q}^T \mathbf{Q} = \mathbf{I}$, la propiedad que define a una rotación. Por tanto,

Idea clave 4. $\mathbf{C} = \mathbf{F}^T \mathbf{F}$ toma *exactamente el mismo valor* para $\mathbf{F}$ y para $\mathbf{Q}\mathbf{F}$, para cualquier rotación $\mathbf{Q}$. $\mathbf{C}$ “no ve” la orientación en el espacio del objeto deformado: solo ve cuánto se estiró internamente.

Ejemplo 7 (Verificación numérica completa). Tomemos $\mathbf{F} = \begin{pmatrix} 2 & 0.5 \\ 0 & 1 \end{pmatrix}$ y una rotación de $\theta = 40^\circ$:

$$\mathbf{Q} = \begin{pmatrix} \cos 40^\circ & -\sin 40^\circ \\ \sin 40^\circ & \cos 40^\circ \end{pmatrix} \approx \begin{pmatrix} 0.766 & -0.643 \\ 0.643 & 0.766 \end{pmatrix}.$$

Entonces

$$\mathbf{F}' = \mathbf{Q}\mathbf{F} \approx \begin{pmatrix} 1.532 & -0.260 \\ 1.286 & 1.087 \end{pmatrix},$$

que, como puedes ver, **no se parece en nada a $\mathbf{F}$ entrada por entrada**. Sin embargo, calculando $\mathbf{C} = \mathbf{F}^T \mathbf{F}$ para ambas:

$$\mathbf{F}^T \mathbf{F} = \begin{pmatrix} 4 & 1 \\ 1 & 1.25 \end{pmatrix}, \quad (\mathbf{F}')^T \mathbf{F}' = \begin{pmatrix} 4 & 1 \\ 1 & 1.25 \end{pmatrix},$$

exactamente idénticas (verificado numéricamente, no solo algebraicamente). La Figura 2 muestra geométricamente qué está pasando: el círculo unidad se convierte, bajo $\mathbf{F}$, en una elipse; bajo $\mathbf{F}' = \mathbf{Q}\mathbf{F}$, en **la misma elipse, solo rotada 40° en el espacio**. La forma de la elipse (sus dos semiejes, cuánto se estiró en cada dirección) es lo único que $\mathbf{C}$ registra; hacia dónde apunta esa elipse en el espacio es exactamente la información que $\mathbf{C}$ descarta.

El círculo unidad deformado por $\mathbf{F}$ (izquierda) y por $\mathbf{Q}\mathbf{F}$ (derecha):
la elipse es idéntica en forma, solo rotada – y $\mathbf{C} = \mathbf{F}^T \mathbf{F}$ no distingue los dos casos




Figure 2: El mismo estiramiento interno ($\mathbf{C}$ idéntica), visto sin rotación extra (izquierda) y con una rotación rígida de 40° superpuesta (derecha). La elipse tiene la misma forma en ambos paneles; solo cambia su orientación en el espacio.

3.4 Qué significa $\mathbf{C}$ físicamente: longitudes al cuadrado

Hay una segunda forma, muy concreta, de entender $\mathbf{C}$: para cualquier vector material $\mathbf{v}$ (un vector dibujado en la configuración de referencia),

$$|\mathbf{F}\mathbf{v}|^2 = (\mathbf{F}\mathbf{v}) \cdot (\mathbf{F}\mathbf{v}) = \mathbf{v}^T \mathbf{F}^T \mathbf{F} \mathbf{v} = \mathbf{v}^T \mathbf{C} \mathbf{v}. \quad (18)$$

Es decir: $\mathbf{C}$ te permite calcular cuánto mide, al cuadrado, la imagen deformada de cualquier vector material, sin necesidad de calcular $\mathbf{F}\mathbf{v}$ primero. Por ejemplo, con $\mathbf{v} = \mathbf{e}_1$:

$$|\mathbf{F}\mathbf{e}_1|^2 = \mathbf{e}_1^T \mathbf{C} \mathbf{e}_1 = C_{11}.$$

Para nuestro ejemplo, $C_{11} = 4$, y en efecto $\mathbf{F}\mathbf{e}_1 = (2, 0)^T$ tiene longitud al cuadrado $2^2 = 4$. Consistente.

3.5 De C a E : la deformación de Green–Lagrange

Definimos ahora

$$\mathbf{E} := \frac{1}{2}(\mathbf{C} - \mathbf{I}). \quad (19)$$

¿Por qué restar $\mathbf{I}$? Porque queremos que la medida de deformación sea **exactamente cero cuando no hay deformación**. Si $\mathbf{F} = \mathbf{I}$ (nuestro Ejemplo 1 del Capítulo 1), entonces $\mathbf{C} = \mathbf{F}^T \mathbf{F} = \mathbf{I}$, y por tanto

$$\mathbf{E} = \frac{1}{2}(\mathbf{I} - \mathbf{I}) = \mathbf{0}.$$

Sin el $-\mathbf{I}$, tendríamos $\mathbf{C} = \mathbf{I} \neq \mathbf{0}$ incluso sin ninguna deformación, lo cual sería una convención mucho menos cómoda para escribir energías que deben anularse en el estado de referencia (la condición (C4) del paper, $W(\mathbf{0}) = 0$, se refiere precisamente a $\mathbf{E} = \mathbf{0}$).

3.6 J en términos de C , y por qué $C \succ 0$ importa

Como $\det(\mathbf{F}^T \mathbf{F}) = \det(\mathbf{F}^T) \det(\mathbf{F}) = (\det \mathbf{F})^2$, se sigue que

$$\det \mathbf{C} = J^2 \quad \Longleftrightarrow \quad J = \sqrt{\det \mathbf{C}} \quad (20)$$

(tomando la raíz positiva, ya que exigimos $J > 0$; recuerda el Ejemplo 5 del colapso y la reflexión del Capítulo 1). Para que esta raíz cuadrada exista como número real, necesitamos $\det \mathbf{C} \geq 0$; y para que la raíz cuadrada *matricial* $\mathbf{F} = \mathbf{U} = \sqrt{2\mathbf{E} + \mathbf{I}}$ que el paper usa para construir la condición de contorno (la mencionamos al final del Capítulo 1) tenga sentido como matriz simétrica real, se necesita además que $\mathbf{C} = \mathbf{I} + 2\mathbf{E} \succ 0$ (positiva definida, es decir, todos sus autovalores estrictamente positivos). Ésta es exactamente la condición que el código verifica explícitamente antes de construir la deformación de contorno, y que dispara un error en vez de devolver silenciosamente un $\mathbf{F}$ espúreo si se viola.

3.7 Resumen de este capítulo

Idea clave 5. • $\mathbf{F}$ por sí solo no sirve para medir “cuánto se deformó” un material de forma que no dependa de la orientación en el espacio: $\mathbf{F}$ y $\mathbf{QF}$ representan físicamente lo mismo, pero son matrices distintas.

- $\mathbf{C} := \mathbf{F}^T \mathbf{F}$ resuelve esto exactamente: $(\mathbf{QF})^T (\mathbf{QF}) = \mathbf{C}$ para toda rotación $\mathbf{Q}$, usando únicamente $\mathbf{Q}^T \mathbf{Q} = \mathbf{I}$.
- Interpretación física de $\mathbf{C}$: $\mathbf{v}^T \mathbf{C} \mathbf{v} = |\mathbf{Fv}|^2$, longitudes al cuadrado de vectores materiales deformados.
- $\mathbf{E} := \frac{1}{2}(\mathbf{C} - \mathbf{I})$ es la misma información que $\mathbf{C}$, montada de forma que $\mathbf{E} = \mathbf{0}$ exactamente quiere decir “sin deformación”.
- $J = \sqrt{\det \mathbf{C}}$, y necesitamos $\mathbf{C} \succ 0$ para que todo esto tenga sentido como números reales.

Antes de seguir: confirma con tus propios números (cambia θ en el ejemplo, o usa otro $\mathbf{F}$ del Capítulo 1) que $\mathbf{C}$ no cambia al rotar.

4 El truco de lifting de Ball, y la definición de polyconvexidad

4.1 Qué esperábamos de la convexidad (y qué vamos a perder)

Antes de tocar $\mathbf{F}$ para nada, recordemos **por qué nos importó la convexidad desde el principio**: si no dejamos esto clarísimo primero, cualquier truco que venga después va a sonar a engaño, con razón.

Piensa en $f(x) = x^2$: tiene un único mínimo, en $x = 0$, y cualquier método razonable (Newton, descenso de gradiente) lo encuentra sin ambigüedad, desde donde sea que empieces. Ahora piensa en $g(x) = x^4 - 3x^2$: tiene **dos** mínimos (en $x = \pm\sqrt{1.5}$, simétricos) y un máximo local falso en $x = 0$ separándolos. Si empiezas a optimizar cerca de un mínimo, puedes terminar ahí sin saber que había otro igual de válido del otro lado; y si tu problema representa algo físico, quedarte en “el mínimo equivocado” es una respuesta físicamente real pero incompleta.

Y ya que salió en nuestra conversación, agreguemos tu propio ejemplo, $h(x) = x^3$: ésta ni siquiera es convexa ni cóncava (se curva hacia arriba para $x > 0$ y hacia abajo para $x < 0$, con un punto de inflexión en $x = 0$ que no es ni máximo ni mínimo), y de hecho no tiene **ningún** mínimo global: se va a $-\infty$ sin límite conforme $x \rightarrow -\infty$. Si tu energía se comportara así, ni siquiera tendría sentido preguntar “¿cuál es el equilibrio?”: no habría ninguno, el sistema colapsaría sin fondo. La Figura 3 dibuja las tres, una junto a la otra.




Figure 3: Tres comportamientos posibles de una función de una sola variable, de mejor a peor para un problema de optimización: convexa, con un único mínimo (izquierda); no convexa pero con mínimos bien definidos, solo que hay más de uno (centro); y ni convexa ni cóncava, sin ningún mínimo global (derecha, tu ejemplo). $W(\mathbf{F})$ resultará estar, en cierto sentido preciso, más cerca del panel central que del derecho; pero eso es exactamente lo que el resto del capítulo tiene que demostrar, no algo que podamos asumir.

Idea clave 6 (Lo que queríamos, en una frase). *Si la energía elástica $W(\mathbf{F})$ fuera convexa, sabríamos que el problema de encontrar el equilibrio (minimizar la energía total) tiene una única solución, sin ambigüedades, y que la podemos encontrar de forma confiable. Eso, y nada menos, es lo que queríamos.*

Vamos a demostrar, en un momento, que **esto es imposible** para nuestra $W(\mathbf{F})$. Y quiero decir esto con toda claridad desde ya, para que no se pierda después entre fórmulas: **no vamos a recuperar esa garantía**. Lo que Ball ofrece en su lugar, más adelante en este capítulo, es algo *estrictamente más débil*: no “un único mínimo, fácil de encontrar”, sino solamente “existe *al menos una* solución de equilibrio”. Ni siquiera promete que no haya otras soluciones igualmente válidas (piensa en una regla delgada que, al comprimirla, se puede pandear hacia la izquierda o hacia la derecha: ambas son configuraciones de equilibrio físicamente reales, no “trampas” que un mejor método evitaría). Guardemos esta distinción (unicidad y facilidad de optimización por un lado, mera existencia por el otro), porque es exactamente lo que se perdió, y es importante no confundir lo uno con lo otro más adelante.

4.2 Por qué W no puede ser convexa en $\mathbf{F}$

Ahora que sabemos qué es la objetividad (Capítulo 3), podemos usarla para descartar la opción más ingenua de todas: pedir que W sea una función convexa ordinaria de $\mathbf{F}$.

Recuerda del Capítulo 3 que $\mathbf{Q} = -\mathbf{I}$ (una rotación de 180°) es una rotación válida en 2D: $\det(-\mathbf{I}) = (-1)^2 = 1$ y $(-\mathbf{I})^T(-\mathbf{I}) = \mathbf{I}$. Por objetividad,

$$W(-\mathbf{F}) = W(\mathbf{F}) \quad \text{para todo } \mathbf{F}. \quad (21)$$

Supongamos, por contradicción, que W fuera convexa en $\mathbf{F}$. Entonces, evaluando la desigualdad de convexidad en el punto medio entre $\mathbf{F}$ y $-\mathbf{F}$:

$$W\left(\frac{1}{2}\mathbf{F} + \frac{1}{2}(-\mathbf{F})\right) \leq \frac{1}{2}W(\mathbf{F}) + \frac{1}{2}W(-\mathbf{F}) \stackrel{(21)}{=} W(\mathbf{F}). \quad (22)$$

Pero el punto medio $\frac{1}{2}\mathbf{F} + \frac{1}{2}(-\mathbf{F})$ es, exactamente, la **matriz cero**, $\mathbf{F} = \mathbf{0}$. Con $\mathbf{F} = \mathbf{0}$: $\det \mathbf{F} = 0$, que en el Capítulo 1 identificamos como un **colapso** (el cuadrado de referencia se aplasta a un punto, área cero). Físicamente, cualquier energía elástica razonable debe **explotar** en ese estado, $W(\mathbf{0}) = +\infty$: es exactamente la condición de crecimiento (C6) que el paper exige. Pero (22) dice $W(\mathbf{0}) \leq W(\mathbf{F})$, un número finito. Contradicción.

Idea clave 7. *Convexidad ordinaria en $\mathbf{F}$ es incompatible con la objetividad: una fuerza a que $W(\mathbf{0})$ sea finito, la otra exige que sea infinito. Esto no es un defecto de ningún modelo en particular: es un resultado clásico (se remonta a Coleman y Noll, y aparece en prácticamente cualquier libro de texto moderno de elasticidad no lineal). Necesitamos una noción de convexidad más débil, compatible con $W(-\mathbf{F}) = W(\mathbf{F})$ y con $W \rightarrow \infty$ en el colapso.*

4.3 Un ejemplo muy concreto de que $\det \mathbf{F}$ no es convexo

Antes de buscar la solución, veamos con números por qué ni siquiera la función más simple posible construida a partir de $\mathbf{F}$, el propio determinante $h(\mathbf{F}) := \det \mathbf{F}$, es convexa. Vamos a usar este mismo ejemplo numérico durante el resto del capítulo.

Ejemplo 8 (Dos matrices con el mismo determinante). Sean

$$\mathbf{F}_1 = \begin{pmatrix} 2 & 0 \\ 0 & 0.5 \end{pmatrix}, \quad \mathbf{F}_2 = \begin{pmatrix} 0.5 & 0 \\ 0 & 2 \end{pmatrix}.$$

Ambas tienen el mismo determinante:

$$\det \mathbf{F}_1 = 2 \times 0.5 = 1, \quad \det \mathbf{F}_2 = 0.5 \times 2 = 1.$$

Su punto medio es

$$\mathbf{F}_m = \frac{1}{2}\mathbf{F}_1 + \frac{1}{2}\mathbf{F}_2 = \begin{pmatrix} 1.25 & 0 \\ 0 & 1.25 \end{pmatrix},$$

con determinante

$$\det \mathbf{F}_m = 1.25 \times 1.25 = 1.5625.$$

Si $h = \det$ fuera convexa, exigiríamos $h(\mathbf{F}_m) \leq \frac{1}{2}h(\mathbf{F}_1) + \frac{1}{2}h(\mathbf{F}_2) = \frac{1}{2}(1) + \frac{1}{2}(1) = 1$. Pero obtuvimos $h(\mathbf{F}_m) = 1.5625 > 1$. **Violación directa:** el determinante no es convexo.

4.4 La silla de montar

¿Por qué ocurre esto? Restrinjámonos a matrices diagonales, $\mathbf{F} = \text{diag}(a, d)$, para poder dibujar la función completa (en 4 variables generales, $h(a, b, c, d) = ad - bc$, no cabe en una gráfica ordinaria, pero en 2 variables sí). Con $\mathbf{F}$ diagonal,

$$h(a, d) = ad.$$

El panel izquierdo de la Figura 4 dibuja esta función. Nota la forma de **silla de montar**: a lo largo de la diagonal $d = a$, $h(a, a) = a^2$ crece hacia arriba en ambas direcciones (curvatura positiva); a lo largo de la antidiagonal $d = -a$, $h(a, -a) = -a^2$ decrece en ambas direcciones (curvatura negativa). Una función convexa no puede curvarse hacia arriba en una dirección y hacia abajo en otra: eso es precisamente lo que le pasa a h , y es la razón geométrica detrás de la Ejemplo 8: nuestros dos puntos $\mathbf{F}_1 = (2, 0.5)$ y $\mathbf{F}_2 = (0.5, 2)$ (en coordenadas (a, d)) están situados de tal manera que el segmento entre ellos atraviesa la región “que se curva hacia arriba” de la silla.




Figure 4: Izquierda: $h(a, d) = ad$ sobre matrices diagonales, con $\mathbf{F}_1$, $\mathbf{F}_2$ y su punto medio marcados. Derecha: el valor de $\det \mathbf{F}(t)$ a lo largo del segmento $\mathbf{F}(t) = (1 - t)\mathbf{F}_1 + t\mathbf{F}_2$ (verde), comparado con la cuerda recta que conecta los dos valores extremos (gris discontinuo). El área sombreada es exactamente la violación de convexidad del Ejemplo 8.

El panel derecho muestra lo mismo de otra forma, quizá la más directa de todas: a lo largo del segmento que une $\mathbf{F}_1$ con $\mathbf{F}_2$, parametrizado por $t \in [0, 1]$,

$$\det \mathbf{F}(t) = 1 + 2.25t(1 - t)$$

(verifícalo tú mismo expandiendo $(2 - 1.5t)(0.5 + 1.5t)$). Esta curva vale 1 en ambos extremos pero sube hasta 1.5625 en el medio: **queda por encima** de la cuerda recta (que, al valer lo mismo en ambos extremos, es simplemente la línea horizontal en 1). Una función convexa siempre debe quedar *por debajo* de sus cuerdas; ésta queda por encima. Confirmado, con números y con dibujo.

4.5 El mecanismo de Ball, y qué promete exactamente

Vamos a repasar el mecanismo (ya lo entendiste bien la primera vez, así que esta vez lo dejamos corto) y después vamos a ser muy precisos sobre qué obtenemos de él, retomando justo la distinción de la Sección 4.1.

El mecanismo, resumido

Introducimos una variable nueva δ , sin relación todavía con $\mathbf{F}$, y definimos

$$G(\mathbf{F}, \delta) := \delta.$$

Como función de δ sola (ignorando $\mathbf{F}$ por completo), G es lineal, luego convexa, de la forma más trivial posible: si mueves δ en línea recta de un valor a otro, su valor a mitad de camino es

exactamente el promedio: eso es, literalmente, la definición de moverse en línea recta. Después, **imponemos** $\delta := \det \mathbf{F}$, y recuperamos

$$G(\mathbf{F}, \det \mathbf{F}) = \det \mathbf{F} = h(\mathbf{F}).$$

Esto es exactamente lo que hicimos antes, y el mecanismo en sí no tiene nada más escondido.

La pregunta que de verdad importa: ¿qué compramos con esto?

Aquí es donde había una confusión que valía la pena parar a corregir. Tú preguntabas, con toda razón: si a alguien le pregunto “¿ x^3 es convexa?” es porque quiero saber si el problema de *minimizar* tiene una única solución, fácil de encontrar, sin trampas. Entonces, ¿qué tiene que ver con *eso* el que G sea convexa cuando yo mismo decidí que δ se comportara en línea recta?

La respuesta honesta es: **nada, directamente**. Y no porque el mecanismo esté mal, sino porque **no está tratando de darte esa garantía**. Como dejamos escrito en la Sección 4.1: esa garantía completa (única solución, sin trampas, fácil de encontrar) ya la perdimos, para siempre, en cuanto demostramos que W no puede ser convexa en $\mathbf{F}$. No hay mecanismo, truco, ni cambio de variable que la vaya a devolver: eso sería, con toda justicia, hacer trampa.

Lo que el mecanismo de δ *sí* es el primer paso hacia algo mucho más modesto: un teorema real, debido a Ball (1977), que dice (sin que lo vayamos a demostrar aquí) que si puedes escribir tu energía como $W(\mathbf{F}) = G(\mathbf{F}, \det \mathbf{F})$ con G convexa (más una condición técnica de crecimiento), entonces el problema de equilibrio elástico **tiene al menos una solución**. Nada de unicidad. Nada de “sin trampas”: de hecho, un material elástico real *puede* tener más de un equilibrio válido para las mismas condiciones de frontera (una regla delgada comprimida se puede pandear hacia la izquierda o hacia la derecha; ambas son soluciones legítimas, ninguna es una “trampa” que un mejor método evitaría). Ball no promete evitar eso. Promete, únicamente, que no te vas a quedar sin ninguna solución en absoluto.

Idea clave 8. *El mecanismo de δ (o, con la definición completa, $G(\mathbf{F}, \text{cof } \mathbf{F}, \det \mathbf{F})$) no es la respuesta a “¿tiene mi problema un único mínimo, fácil de encontrar?”: esa pregunta ya la contestamos que no, y sigue siendo no. Es el punto de partida de una demostración distinta, de una afirmación más débil: “¿tiene mi problema al menos una solución?”. Confundir estas dos preguntas es precisamente lo que hacía sonar al mecanismo como un engaño; distinguiéndolas, el mecanismo deja de prometer algo que nunca quiso prometer.*

Una honestidad final para este capítulo: el paso que falta (cómo, exactamente, “ G es convexa” implica “existe al menos una solución de equilibrio”) es el contenido real del teorema de Ball de 1977, y su demostración necesita herramientas de análisis funcional (convergencia débil de sucesiones, semicontinuidad inferior) que no hemos construido en este documento. No vamos a fingir aquí que lo demostramos. Lo dejamos marcado, honestamente, como un capítulo pendiente para cuando tengamos esas herramientas. Lo que sí queda completamente claro, y es lo que queríamos lograr en este capítulo, es **qué pregunta exactamente estamos contestando** (existencia) y **cuál ya no** (unicidad, ausencia de trampas), para que ningún resultado posterior se lea como más de lo que en realidad es.

4.6 La definición real: $\mathbf{F}$, $\text{cof } \mathbf{F}$ y $\det \mathbf{F}$ como tres bloques

Además de δ (que al final identificamos con $\det \mathbf{F}$), Ball añade un segundo bloque elevado: la matriz auxiliar $\text{cof } \mathbf{F} = \begin{pmatrix} d & -c \\ -b & a \end{pmatrix}$ para $\mathbf{F} = \begin{pmatrix} a & b \\ c & d \end{pmatrix}$ (le dedicaremos un capítulo propio más adelante). Ball construye su definición completa de **polyconvexidad**, usada en el paper (Sección 5), tratando a $\mathbf{F}$, $\text{cof } \mathbf{F}$ y $\det \mathbf{F}$ como **tres bloques de variables independientes**:

$$W(\mathbf{F}) = G(\mathbf{F}, \text{cof } \mathbf{F}, \det \mathbf{F}), \quad G \text{ conjuntamente convexa en } \mathbb{R}^{2 \times 2} \times \mathbb{R}^{2 \times 2} \times \mathbb{R}, \quad (23)$$

exactamente la misma idea del mecanismo de δ de la sección anterior, ahora con dos bloques elevados en vez de uno, y sujeta a la misma advertencia que dejamos clarísima ahí: esto es el punto de partida de una demostración de *existencia*, no una prueba de que el problema tenga una única solución fácil de encontrar. Polyconvexidad es estrictamente más débil que convexidad ordinaria en $\mathbf{F}$ (toda función convexa en $\mathbf{F}$ es polyconvexa, ignorando los bloques extra; pero, como acabamos de ver con $\det \mathbf{F}$, no toda función polyconvexa es convexa en $\mathbf{F}$).

4.7 ¿Y qué pasa con la objetividad ahora?

Con la nueva definición en mano, volvamos a la pregunta que abrió este capítulo: ¿es compatible (23) con $W(-\mathbf{F}) = W(\mathbf{F})$? Aquí podemos usar directamente lo que ya demostramos en el Capítulo 3, sin necesitar ningún truco adicional: mostramos que $\mathbf{C} = \mathbf{F}^T \mathbf{F}$ es invariante bajo *cualquier* rotación $\mathbf{Q} \in \text{SO}(2)$ (no solo $\mathbf{Q} = -\mathbf{I}$), y exactamente la misma identidad algebraica aplicada a $\text{cof } \mathbf{F}$ en lugar de $\mathbf{F}$ da

$$\text{cof}(\mathbf{Q}\mathbf{F})^T \text{cof}(\mathbf{Q}\mathbf{F}) = \text{cof}(\mathbf{C}) \quad (24)$$

para toda $\mathbf{Q} \in \text{SO}(2)$ (el paper lo usa exactamente así en la prueba de (C2)). Por tanto: **cualquier** G que dependa de $\mathbf{F}$ solo a través de $\mathbf{C} = \mathbf{F}^T \mathbf{F}$, de $\text{cof } \mathbf{F}$ solo a través de $\text{cof}(\mathbf{F})^T \text{cof}(\mathbf{F}) = \text{cof}(\mathbf{C})$, y de $\det \mathbf{F}$ directamente, automáticamente hereda $W(\mathbf{Q}\mathbf{F}) = W(\mathbf{F})$ para *toda* rotación, no solo para el caso especial $\mathbf{Q} = -\mathbf{I}$ que usamos para romper la convexidad ordinaria. Esta es la razón real, completa y correcta por la que el paper puede pedir polyconvexidad y objetividad al mismo tiempo sin ninguna tensión entre las dos exigencias: no es que los bloques “no cambien” bajo $\mathbf{F} \mapsto -\mathbf{F}$ (de hecho $\text{cof}(-\mathbf{F}) = -\text{cof } \mathbf{F}$ en 2D: **sí** cambia de signo, a diferencia de $\det(-\mathbf{F}) = \det \mathbf{F}$ que no cambia), sino que **construimos G para que dependa solo de combinaciones que ya son invariantes por construcción**, como $\mathbf{C}$ y $\text{cof}(\mathbf{C})$, en lugar de depender de $\mathbf{F}$ o $\text{cof } \mathbf{F}$ de cualquier forma arbitraria.

4.8 Resumen de este capítulo

- Idea clave 9.** • *Objetividad ($\mathbf{Q} = -\mathbf{I}$) más convexidad ordinaria en $\mathbf{F}$ fuerza $W(\mathbf{0}) \leq W(\mathbf{F})$, lo cual contradice que la energía deba explotar en el colapso $\mathbf{F} = \mathbf{0}$. Convexidad ordinaria en $\mathbf{F}$ queda descartada.*
- *Confirmamos con un ejemplo numérico explícito ($\mathbf{F}_1 = \text{diag}(2, 0.5)$, $\mathbf{F}_2 = \text{diag}(0.5, 2)$) que $\det \mathbf{F}$ efectivamente no es convexo: el punto medio da 1.5625, por encima de la cuerda que vale 1.*
 - *El mecanismo de Ball: introducir δ (y, en la definición completa, también $\text{cof } \mathbf{F}$) como variables independientes, y pedir convexidad conjunta $G(\mathbf{F}, \text{cof } \mathbf{F}, \det \mathbf{F})$ en el espacio elevado: estrictamente más fácil de satisfacer que convexidad en $\mathbf{F}$ directamente.*
 - *Lo que esto promete, con precisión: no “única solución, fácil de encontrar” (eso ya lo perdimos para siempre). Sólo “existe al menos una solución de equilibrio”: un teorema real de Ball (1977) cuya demostración completa necesita herramientas de análisis funcional que dejamos pendientes para más adelante. Confundir esta garantía débil con la fuerte que queríamos al principio es exactamente lo que hace que el mecanismo parezca evasión; distinguiéndolas, deja de parecerlo.*
 - *La compatibilidad con objetividad no viene de que los bloques elevados se queden fijos bajo $\mathbf{F} \mapsto -\mathbf{F}$ (el cofactor sí cambia de signo en 2D); viene de construir G a partir de combinaciones ya invariantes bajo toda rotación, como $\mathbf{C}$ y $\text{cof}(\mathbf{C})$, exactamente como en el Capítulo 3.*

Antes de seguir: con lápiz y papel, repite el cálculo del Ejemplo 8 con otras dos matrices de tu elección que tengan el mismo determinante (por ejemplo $\text{diag}(3, 1/3)$ y $\text{diag}(1/3, 3)$) y confirma que vuelves a obtener una violación. Cuando estés listo, seguimos con el Capítulo 4: qué es exactamente $\text{cof } \mathbf{F}$, qué significa físicamente, y por qué en 2D es, en cierto sentido, “menos nuevo” de lo que parece.

5 El cofactor $\text{cof } \mathbf{F}$: qué es, y qué hace de verdad

5.1 El problema: las normales no se comportan como los vectores tangentes

$\mathbf{F}$ nos dice qué le pasa a un vector material pequeño, $d\mathbf{x} = \mathbf{F} d\mathbf{X}$ (así lo usamos todo el Capítulo 1: las columnas de $\mathbf{F}$ son las imágenes de los vectores de la base). Si tienes una línea recta en la referencia con dirección (tangente) $\mathbf{t}$, su imagen deformada tiene tangente $\mathbf{F}\mathbf{t}$: sin sorpresas, es exactamente para eso que sirve $\mathbf{F}$.

Pero ahora pregunta algo distinto: si $\mathbf{n}$ es un vector **normal** (perpendicular) a esa línea en la referencia, ¿qué vector es normal a la línea *deformada*? La respuesta ingenua sería “también $\mathbf{F}\mathbf{n}$ ”; y esa respuesta es, en general, **falsa**.

Ejemplo 9 (La normal ingenua falla, verificado con números). *Usemos el corte del Capítulo 1, $\mathbf{F} = \begin{pmatrix} 1 & 0.6 \\ 0 & 1 \end{pmatrix}$, con una línea de tangente $\mathbf{t} = (1, 1)^T$ y normal $\mathbf{n} = (1, -1)^T$ (verifica tú mismo: $\mathbf{t} \cdot \mathbf{n} = (1)(1) + (1)(-1) = 0$, son perpendiculares).*

La tangente deformada es

$$\mathbf{F}\mathbf{t} = \begin{pmatrix} 1 & 0.6 \\ 0 & 1 \end{pmatrix} \begin{pmatrix} 1 \\ 1 \end{pmatrix} = \begin{pmatrix} 1.6 \\ 1 \end{pmatrix}.$$

Si la normal ingenua $\mathbf{F}\mathbf{n}$ fuera correcta, debería seguir siendo perpendicular a $\mathbf{F}\mathbf{t}$. Calculemos:

$$\mathbf{F}\mathbf{n} = \begin{pmatrix} 1 & 0.6 \\ 0 & 1 \end{pmatrix} \begin{pmatrix} 1 \\ -1 \end{pmatrix} = \begin{pmatrix} 0.4 \\ -1 \end{pmatrix}, \quad (\mathbf{F}\mathbf{n}) \cdot (\mathbf{F}\mathbf{t}) = (0.4)(1.6) + (-1)(1) = -0.36 \neq 0.$$

No es perpendicular. $\mathbf{F}$ es la matriz correcta para tangentes, pero no para normales.

5.2 La solución: $\text{cof } \mathbf{F}$

Para $\mathbf{F} = \begin{pmatrix} a & b \\ c & d \end{pmatrix}$, definimos

$$\text{cof } \mathbf{F} := \begin{pmatrix} d & -b \\ -c & a \end{pmatrix}. \quad (25)$$

(Ya la usamos, sin detenernos, en el Capítulo 4; ahora le toca su propio capítulo.) Repitamos el Ejemplo 9 pero transformando la normal con $\text{cof } \mathbf{F}$ en vez de con $\mathbf{F}$: para nuestra $\mathbf{F}$, $\text{cof } \mathbf{F} = \begin{pmatrix} 1 & 0 \\ -0.6 & 1 \end{pmatrix}$, así que

$$\text{cof}(\mathbf{F})\mathbf{n} = \begin{pmatrix} 1 & 0 \\ -0.6 & 1 \end{pmatrix} \begin{pmatrix} 1 \\ -1 \end{pmatrix} = \begin{pmatrix} 1 \\ -1.6 \end{pmatrix}, \quad (\text{cof}(\mathbf{F})\mathbf{n}) \cdot (\mathbf{F}\mathbf{t}) = (1)(1.6) + (-1.6)(1) = 0.$$

Exactamente perpendicular. La Figura 5 dibuja los tres vectores: la tangente correcta $\mathbf{F}\mathbf{t}$, la normal correcta $\text{cof}(\mathbf{F})\mathbf{n}$, y la normal ingenua incorrecta $\mathbf{F}\mathbf{n}$ para que veas la diferencia con tus propios ojos.

$\mathbf{F} = \begin{pmatrix} 1 & 0.6 \\ 0 & 1 \end{pmatrix}$ (el corte del Capítulo 1): las tangentes se transforman con $\mathbf{F}$, las normales con $\text{cof}(\mathbf{F})$




Figure 5: Izquierda: una línea de referencia con su tangente $\mathbf{t}$ y normal $\mathbf{n}$ (perpendiculares). Derecha: bajo la misma $\mathbf{F}$ (el corte del Capítulo 1), la tangente se transforma con $\mathbf{F}$ y sigue siendo tangente a la línea deformada; la normal se transforma con $\text{cof}(\mathbf{F})$ y sigue siendo exactamente perpendicular a $\mathbf{F}\mathbf{t}$, mientras que $\mathbf{F}\mathbf{n}$ (rojo, discontinuo) no lo es.

5.3 Por qué funciona: una identidad algebraica de tres líneas

Esto no es coincidencia para nuestro ejemplo: es una identidad general. Para cualquier $\mathbf{F}$ invertible,

$$\mathbf{F}^T (\text{cof } \mathbf{F}) = (\det \mathbf{F}) \mathbf{I}. \quad (26)$$

Verifícalo con nuestros números: $\mathbf{F}^T = \begin{pmatrix} 1 & 0 \\ 0.6 & 1 \end{pmatrix}$,

$$\mathbf{F}^T \text{cof } \mathbf{F} = \begin{pmatrix} 1 & 0 \\ 0.6 & 1 \end{pmatrix} \begin{pmatrix} 1 & 0 \\ -0.6 & 1 \end{pmatrix} = \begin{pmatrix} 1 & 0 \\ 0.6 - 0.6 & 1 \end{pmatrix} = \begin{pmatrix} 1 & 0 \\ 0 & 1 \end{pmatrix} = \mathbf{I} = (\det \mathbf{F}) \mathbf{I}$$

(aquí $\det \mathbf{F} = 1$). Con esta identidad, la comprobación de perpendicularidad del Ejemplo 9 sale en una línea, para *cualquier* $\mathbf{F}$, $\mathbf{t}$, $\mathbf{n}$ con $\mathbf{t} \cdot \mathbf{n} = 0$:

$$(\text{cof}(\mathbf{F})\mathbf{n}) \cdot (\mathbf{F}\mathbf{t}) = \mathbf{n}^T (\text{cof } \mathbf{F})^T \mathbf{F} \mathbf{t} = \mathbf{n}^T (\mathbf{F}^T \text{cof } \mathbf{F})^T \mathbf{t} = \mathbf{n}^T (\det \mathbf{F}) \mathbf{I} \mathbf{t} = (\det \mathbf{F}) (\mathbf{n} \cdot \mathbf{t}) = 0.$$

(Usamos que $(\text{cof } \mathbf{F})^T \mathbf{F} = (\mathbf{F}^T \text{cof } \mathbf{F})^T$ porque $\mathbf{F}^T \text{cof } \mathbf{F} = (\det \mathbf{F}) \mathbf{I}$ es simétrica, así que es igual a su propia transpuesta.) Esta es, en esencia, la fórmula de Nanson de la mecánica del medio continuo: las áreas y normales orientadas se transportan con $\text{cof } \mathbf{F}$, no con $\mathbf{F}$.

Una consecuencia útil, cuando $\mathbf{F}$ es invertible: dividiendo (26) por $\det \mathbf{F}$,

$$\text{cof } \mathbf{F} = (\det \mathbf{F}) \mathbf{F}^{-T}. \quad (27)$$

Verifícalo: $\mathbf{F}^{-1} = \begin{pmatrix} 1 & -0.6 \\ 0 & 1 \end{pmatrix}$ (comprueba tú mismo que $\mathbf{F}\mathbf{F}^{-1} = \mathbf{I}$), así que $\mathbf{F}^{-T} = \begin{pmatrix} 1 & 0 \\ -0.6 & 1 \end{pmatrix} = \text{cof } \mathbf{F}$ exactamente (con $\det \mathbf{F} = 1$ en este ejemplo).

5.4 La sutileza de 2D: $\text{cof } \mathbf{F}$ es lineal, no cuadrático

Mira otra vez la fórmula (25): cada entrada de $\text{cof } \mathbf{F}$ es, literalmente, **una sola entrada de $\mathbf{F}$, con signo**. No hay productos, no hay cuadrados. Eso es lo que quiere decir que $\text{cof } \mathbf{F}$ es una función **lineal** de las entradas de $\mathbf{F}$; ya usamos esto, sin detenernos a justificarlo, en el Capítulo 4.

Esto es **especial de 2D**. En 3D, cada entrada de $\text{cof } \mathbf{F}$ es un menor de 2×2 de $\mathbf{F}$: un determinante de una submatriz 2×2 , que involucra *productos de dos entradas distintas* de $\mathbf{F}$, genuinamente **cuadrático**, no lineal. La razón por la que en 2D es distinto es simplemente de tamaño: un menor “de tamaño $(n-1)$ ” de una matriz $n \times n$ es un determinante de tamaño $n-1$, y un determinante de tamaño 1 (2D: $n-1=1$) es, trivialmente, una sola entrada, mientras que un determinante de tamaño 2 (3D: $n-1=2$) ya involucra un producto de dos entradas menos otro producto de dos entradas, genuinamente cuadrático.

Idea clave 10 (Por qué esto es “menos nuevo de lo que parece”). *Como $\text{cof } \mathbf{F}$ es **lineal** en $\mathbf{F}$ (en 2D), componer cualquier función convexa q con $\text{cof } \mathbf{F}$, es decir, considerar $q(\text{cof } \mathbf{F})$ como función de $\mathbf{F}$, es **automáticamente convexa en $\mathbf{F}$ directamente** (una función convexa compuesta con un mapa lineal preserva convexidad, sin necesitar ningún truco de lifting: es el mismo hecho de tres líneas del Capítulo 4, ahora con un mapa lineal en vez de afín a lo largo de un segmento, que es un caso aún más simple). Es decir: **en 2D, el bloque $\text{cof } \mathbf{F}$ nunca fue el que aportaba convexidad genuinamente nueva**: eso lo aporta únicamente $\det \mathbf{F}$ (que sí es cuadrático, como vimos con nuestro contraejemplo $\mathbf{F}_1, \mathbf{F}_2$). En 3D, en cambio, $\text{cof } \mathbf{F}$ también sería cuadrático y sí aportaría lifting genuino, además de $\det \mathbf{F}$.*

Que $\text{cof } \mathbf{F}$ “no aporte nada nuevo para la convexidad” en 2D **no** quiere decir que sea inútil: todo lo contrario. Sigue siendo, exactamente como acabamos de ver, el objeto físicamente correcto para transformar normales y áreas, y en el paper se usa para construir features direccionales genuinamente distintas de las que se construyen con $\mathbf{F}$ solo ($Q_{k,p}^H$ construidas a partir de $\text{cof } \mathbf{F}$, frente a $Q_{k,p}^F$ construidas a partir de $\mathbf{F}$). “Menos nuevo para demostrar polyconvexidad” y “menos útil para construir un modelo anisotrópico” son afirmaciones completamente distintas: lo primero es cierto, lo segundo no.

5.5 Resumen de este capítulo

Idea clave 11. • $\mathbf{F}$ transforma vectores tangentes ($d\mathbf{x} = \mathbf{F} d\mathbf{X}$); $\text{cof } \mathbf{F}$ transforma vectores normales y áreas orientadas: son objetos físicamente distintos, con reglas de transformación distintas, y confundirlos da un resultado numéricamente incorrecto (verificado: $\mathbf{F}\mathbf{n}$ no queda perpendicular a $\mathbf{F}\mathbf{t}$, pero $\text{cof}(\mathbf{F})\mathbf{n}$ sí).

- La identidad $\mathbf{F}^T \text{cof } \mathbf{F} = (\det \mathbf{F})\mathbf{I}$ (y, si $\mathbf{F}$ es invertible, $\text{cof } \mathbf{F} = (\det \mathbf{F})\mathbf{F}^{-T}$) es la razón algebraica exacta de por qué esto funciona, en cualquier dimensión.
- En 2D específicamente, $\text{cof } \mathbf{F}$ es **lineal** en las entradas de $\mathbf{F}$ (un menor de tamaño 1), a diferencia de 3D (menores de tamaño 2, cuadráticos). Por eso, en 2D, $\text{cof } \mathbf{F}$ no aporta convexidad genuinamente nueva para la definición de polyconvexidad (solo $\det \mathbf{F}$ lo hace), aunque sigue siendo útil físicamente y para construir features anisotrópicas.

Antes de seguir: repite el Ejemplo 9 con otra $\mathbf{F}$ de tu elección (por ejemplo, el estiramiento $\text{diag}(2,1)$ del Capítulo 1) y otra pareja perpendicular $\mathbf{t}, \mathbf{n}$, y confirma con tus propios números que $\text{cof}(\mathbf{F})\mathbf{n}$ se queda perpendicular a $\mathbf{F}\mathbf{t}$ mientras que $\mathbf{F}\mathbf{n}$ no.

Extra: así se ve $\text{cof } \mathbf{F}$ en 3D

Todo lo de este capítulo lo hicimos en 2D, pero vale la pena ver el caso 3D una vez, con números, para que la diferencia entre “lineal” y “cuadrático” deje de ser abstracta.

La definición general: menores con signo

Para $\mathbf{F}$ de 3×3 , con entradas a_{ij} , la entrada (i, j) de $\text{cof } \mathbf{F}$ se define borrando la fila i y la columna j de $\mathbf{F}$ (queda una submatriz 2×2), tomando su determinante, y multiplicando por el signo $(-1)^{i+j}$:

$$(\text{cof } \mathbf{F})_{11} = \det \begin{pmatrix} a_{22} & a_{23} \\ a_{32} & a_{33} \end{pmatrix} = a_{22}a_{33} - a_{23}a_{32}, \quad (\text{cof } \mathbf{F})_{12} = -\det \begin{pmatrix} a_{21} & a_{23} \\ a_{31} & a_{33} \end{pmatrix} = a_{23}a_{31} - a_{21}a_{33},$$

y así sucesivamente para las siete entradas restantes. Mira bien estas dos fórmulas: cada una es un **producto de dos entradas distintas de $\mathbf{F}$, menos otro producto de dos entradas distintas**: genúinamente **cuadrático**. Compara con la fórmula 2D, $\text{cof } \mathbf{F} = \begin{pmatrix} d & -c \\ -b & a \end{pmatrix}$, donde cada entrada era *una sola* entrada de $\mathbf{F}$ con signo, sin ningún producto. Esa es, literalmente, toda la diferencia entre 2D y 3D: un menor de tamaño 1 (2D) es trivialmente lineal; un menor de tamaño 2 (3D) ya involucra productos.

Ejemplo 10 (Un $\mathbf{F}$ de 3×3 , calculado a mano). *Tomemos*

$$\mathbf{F} = \begin{pmatrix} 1 & 2 & 0 \\ 0 & 1 & 1 \\ 1 & 0 & 1 \end{pmatrix}, \quad \det \mathbf{F} = 3$$

(verifícalo expandiendo por la primera fila: $1(1 \cdot 1 - 1 \cdot 0) - 2(0 \cdot 1 - 1 \cdot 1) + 0 = 1 - 2(-1) = 3$). Aplicando la receta de menores a las nueve entradas se obtiene

$$\text{cof } \mathbf{F} = \begin{pmatrix} 1 & 1 & -1 \\ -2 & 1 & 2 \\ 2 & -1 & 1 \end{pmatrix}.$$

Como comprobación (la misma identidad (26) que verificamos en 2D, ahora en 3D),

$$\mathbf{F}^T \text{cof } \mathbf{F} = \begin{pmatrix} 1 & 0 & 1 \\ 2 & 1 & 0 \\ 0 & 1 & 1 \end{pmatrix} \begin{pmatrix} 1 & 1 & -1 \\ -2 & 1 & 2 \\ 2 & -1 & 1 \end{pmatrix} = \begin{pmatrix} 3 & 0 & 0 \\ 0 & 3 & 0 \\ 0 & 0 & 3 \end{pmatrix} = (\det \mathbf{F}) \mathbf{I}.$$

Multiplica tú mismo un par de entradas para confirmarlo: por ejemplo, la entrada $(1, 1)$: $(1)(1) + (0)(-2) + (1)(2) = 3$. ✓

El hecho más bonito: columnas de $\text{cof } \mathbf{F} = \text{productos cruz}$

En 3D hay una manera todavía más directa de calcular $\text{cof } \mathbf{F}$, que conecta perfectamente con el significado físico del capítulo (áreas y normales). Si $\mathbf{f}_1, \mathbf{f}_2, \mathbf{f}_3$ son las columnas de $\mathbf{F}$ (las imágenes de $\mathbf{e}_1, \mathbf{e}_2, \mathbf{e}_3$, como en el Capítulo 1), entonces

$$(\text{cof } \mathbf{F})\mathbf{e}_1 = \mathbf{f}_2 \times \mathbf{f}_3, \quad (\text{cof } \mathbf{F})\mathbf{e}_2 = \mathbf{f}_3 \times \mathbf{f}_1, \quad (\text{cof } \mathbf{F})\mathbf{e}_3 = \mathbf{f}_1 \times \mathbf{f}_2. \quad (28)$$

Verifiquemoslo con el Ejemplo 10: las columnas de $\mathbf{F}$ son $\mathbf{f}_1 = (1, 0, 1)^T$, $\mathbf{f}_2 = (2, 1, 0)^T$, $\mathbf{f}_3 = (0, 1, 1)^T$. Calculando el producto cruz:

$$\mathbf{f}_2 \times \mathbf{f}_3 = \begin{pmatrix} 1 \cdot 1 - 0 \cdot 1 \\ 0 \cdot 0 - 2 \cdot 1 \\ 2 \cdot 1 - 1 \cdot 0 \end{pmatrix} = \begin{pmatrix} 1 \\ -2 \\ 2 \end{pmatrix},$$

exactamente la primera columna de $\text{cof } \mathbf{F}$ que calculamos arriba por menores. Esto no es casualidad: $\mathbf{e}_1$ es la normal a la cara del cubo de referencia generada por $\mathbf{e}_2, \mathbf{e}_3$, y su área orientada deformada es, por definición geométrica del producto cruz, exactamente $\mathbf{f}_2 \times \mathbf{f}_3$: el mismo papel que $\text{cof } \mathbf{F}$ jugaba para normales de líneas en 2D, ahora para áreas de caras en 3D.

Idea clave 12. En 2D, transformar una normal era “multiplicar por una sola entrada de $\mathbf{F}$, con signo”. En 3D, transformar una normal (de una cara) es “tomar el producto cruz de las otras dos columnas de $\mathbf{F}$ ”, genúinamente cuadrático, porque un producto cruz en 3D siempre multiplica pares de componentes entre sí. La fórmula de menores y la fórmula de productos cruz son dos caminos al mismo resultado; la segunda es la que de verdad explica, geométricamente, por qué $\text{cof } \mathbf{F}$ tiene que ser cuadrática en 3D.

6 Invariantes clásicos: qué son, y por qué no bastan

6.1 ¿Qué es un invariante?

Todo lo que hemos construido hasta ahora ($\mathbf{C}$, $\mathbf{E}$, J , $\text{cof } \mathbf{F}$) depende de $\mathbf{F}$ de formas muy concretas. Ahora vamos a preguntar algo distinto: dado $\mathbf{C}$, ¿qué números podemos sacar de él que no dependan de *cómo lo miramos*?

Concretamente: si rotamos $\mathbf{C}$ como $\mathbf{C} \mapsto \mathbf{Q}^T \mathbf{C} \mathbf{Q}$ para una rotación $\mathbf{Q}$ cualquiera, un **invariante** es una función escalar $I(\mathbf{C})$ que no cambia:

$$I(\mathbf{Q}^T \mathbf{C} \mathbf{Q}) = I(\mathbf{C}) \quad \text{para toda rotación } \mathbf{Q}. \quad (29)$$

Alerta importante, para no confundir esto con la objetividad del Capítulo 3: ahí probamos que $\mathbf{C} = \mathbf{F}^T \mathbf{F}$ es invariante bajo $\mathbf{F} \mapsto \mathbf{Q} \mathbf{F}$, una rotación *rígida del cuerpo ya deformado*, aplicada por la izquierda. Eso es universal, cierto para *cualquier* material, y ya quedó demostrado para siempre.

Aquí estamos preguntando algo distinto: qué le pasa a $\mathbf{C}$ si en cambio giramos $\mathbf{F}$ por la **derecha**, $\mathbf{F} \mapsto \mathbf{F} \mathbf{Q}$, lo que correspondería a rotar el material *antes* de deformarlo (p.ej., cortar la misma probeta de un tejido, pero orientando las fibras en otro ángulo). Esto da $\mathbf{C} \mapsto (\mathbf{F} \mathbf{Q})^T (\mathbf{F} \mathbf{Q}) = \mathbf{Q}^T \mathbf{C} \mathbf{Q}$, exactamente la transformación de (29). Que la energía sea invariante bajo *esta* transformación (es decir, $W(\mathbf{F} \mathbf{Q}) = W(\mathbf{F})$ para toda $\mathbf{Q}$) no es una ley universal: es la definición de que el material sea **isotrópico** (que responde igual sin importar cómo esté orientado internamente). Un material con fibras, como el nuestro, en general **no** es isotrópico, así que no esperamos ni queremos que $W(\mathbf{F} \mathbf{Q}) = W(\mathbf{F})$.

6.2 Los invariantes clásicos

Los invariantes clásicos son las funciones más simples que satisfacen (29). En 2D, donde $\mathbf{C}$ simétrica 2×2 tiene exactamente dos autovalores λ_1, λ_2 , hay dos:

$$I_1 := \text{tr } \mathbf{C} = \lambda_1 + \lambda_2, \quad I_2 := \det \mathbf{C} = \lambda_1 \lambda_2 = J^2. \quad (30)$$

(En 3D, con tres autovalores, hay tres: $I_1 = \text{tr } \mathbf{C} = \lambda_1 + \lambda_2 + \lambda_3$, $I_2 = \lambda_1 \lambda_2 + \lambda_2 \lambda_3 + \lambda_3 \lambda_1$, $I_3 = \det \mathbf{C} = \lambda_1 \lambda_2 \lambda_3$; lo mencionamos solo para contraste, en este proyecto todo es 2D.)

¿Por qué son invariantes? Porque $\mathbf{Q}^T \mathbf{C} \mathbf{Q}$ es una *transformación de semejanza*, y las transformaciones de semejanza preservan los autovalores exactamente (ésa es su definición en álgebra lineal). Como I_1, I_2 dependen únicamente de los autovalores de $\mathbf{C}$ (nunca de sus autovectores, las direcciones principales), no pueden cambiar bajo esta transformación.

6.3 El problema: los invariantes clásicos olvidan la orientación

Aquí está el punto clave: precisamente *porque* I_1, I_2 solo ven los autovalores, **cualquier** energía construida únicamente a partir de I_1, I_2 es automáticamente isotrópica. Eso es exactamente lo que **no** queremos para un material con fibras.

Ejemplo 11 (Dos estados distintos, mismos invariantes). *Tomemos*

$$\mathbf{C}_1 = \begin{pmatrix} 2 & 0 \\ 0 & 0.5 \end{pmatrix}, \quad \mathbf{C}_2 = \mathbf{Q}^T \mathbf{C}_1 \mathbf{Q} = \begin{pmatrix} 1.25 & 0.75 \\ 0.75 & 1.25 \end{pmatrix}$$

con $\mathbf{Q}$ una rotación de 45° (verifícalo tú mismo multiplicando). Ambas tienen los mismos autovalores, 2 y 0.5 (rotar no los cambia), así que

$$I_1(\mathbf{C}_1) = I_1(\mathbf{C}_2) = 2.5, \quad I_2(\mathbf{C}_1) = I_2(\mathbf{C}_2) = 1.0.$$

Idénticos. Pero $\mathbf{C}_1$ y $\mathbf{C}_2$ representan estiramientos físicamente muy distintos: uno alineado con los ejes, el otro girado 45° . Si nuestro material tiene una fibra fija a lo largo de $\mathbf{d} = (1, 0)^T$, la fibra siente

$$\mathbf{d} \cdot \mathbf{C}_1 \mathbf{d} = 2.0, \quad \mathbf{d} \cdot \mathbf{C}_2 \mathbf{d} = 1.25,$$

claramente distintos: la fibra se estira el doble en el primer caso que en el segundo. Los invariantes clásicos son ciegos a esta diferencia; una cantidad que involucra una dirección fija, como $\mathbf{d} \cdot \mathbf{C} \mathbf{d}$, no lo es.

En la Figura 6, la línea punteada horizontal es $\mathbf{d}$, **fija**, idéntica en ambos paneles, porque así decidimos medir (es la fibra del material, y la fibra no se mueve solo porque roten los ejes con los que describimos $\mathbf{C}$). La flecha roja **no es** $\mathbf{d}$: es $\mathbf{U} \mathbf{d}$, la imagen de esa fibra después de aplicarle el estiramiento $\mathbf{U} = \sqrt{\mathbf{C}}$ (exactamente como en el Capítulo 3, donde usamos $\mathbf{F} = \mathbf{U}$). Para $\mathbf{C}_1$, $\mathbf{d}$ es una dirección principal (un autovector), así que $\mathbf{U}_1 \mathbf{d}$ apunta en la *misma* dirección que $\mathbf{d}$, solo más largo, por eso ahí la flecha sí queda horizontal. Para $\mathbf{C}_2$, $\mathbf{d}$ **no** es una dirección principal (las direcciones principales de $\mathbf{C}_2$ están giradas 45°), así que $\mathbf{U}_2 \mathbf{d}$ apunta en una dirección distinta de $\mathbf{d}$: la fibra, embebida en este material girado, no solo se estira, también gira. Esto es físicamente real, no un error de la figura: lo único que estamos comparando entre los dos paneles es la **longitud al cuadrado** de esa flecha, $|\mathbf{U} \mathbf{d}|^2 = \mathbf{d} \cdot \mathbf{C} \mathbf{d}$ (exactamente la fórmula (18) del Capítulo 3), no su dirección, que es un efecto secundario, correcto, de la anisotropía.

Mismos I_1, I_2 (misma elipse, solo rotada) – pero $\mathbf{d} \cdot \mathbf{C} \mathbf{d}$ distinto para la misma dirección fija $\mathbf{d}$




Figure 6: Las elipses de estiramiento de $\mathbf{C}_1$ y $\mathbf{C}_2$ del Ejemplo 11, idénticas en forma (mismos I_1, I_2), solo rotadas 45° . La línea punteada es la dirección fija $\mathbf{d}$ (p.ej., la fibra del material, idéntica en ambos paneles); la flecha roja es $\mathbf{U} \mathbf{d}$, la imagen deformada de esa fibra, horizontal para $\mathbf{C}_1$ (donde $\mathbf{d}$ es una dirección principal) pero girada para $\mathbf{C}_2$ (donde no lo es). Lo que comparamos es $|\mathbf{U} \mathbf{d}|^2 = \mathbf{d} \cdot \mathbf{C} \mathbf{d}$: 2.0 en el primer panel, 1.25 en el segundo.

Idea clave 13. Los invariantes clásicos I_1, I_2 no están “mal”: describen exactamente y con precisión toda la información que le importa a un material **isotrópico**. El problema es que nuestro

material no lo es: tiene direcciones que importan (fibras, orientaciones preferentes), y I_1, I_2 olvidan exactamente esa información por construcción (dependen solo de autovalores, nunca de autovectores). Para capturar anisotropía genuina necesitamos features que **sí** dependan de una dirección fija, como $\mathbf{d} \cdot \mathbf{C}\mathbf{d}$, y que no son invariantes en el sentido de (29), **a propósito**.

¿De dónde viene esta idea? $\mathbf{d} \cdot \mathbf{C}\mathbf{d}$ no es una invención de este proyecto: es el pseudo-invariante clásico (a menudo llamado I_4) usado desde los años 70 en toda la teoría de hiperelasticidad anisotrópica para un material con una dirección de fibra fija. Lo introdujo Spencer [3, 4], y Boehler [5] lo formalizó dentro de un marco general: escribir una función anisotrópica como una función isotrópica de $\mathbf{C}$ y de un **tensor estructural** que codifica la simetría del material (en nuestro caso, $\mathbf{d} \otimes \mathbf{d}$). Si quieres leer los textos originales, esos son los dos clásicos.

Antes de seguir: repite el Ejemplo 11 con otro ángulo de rotación (por ejemplo 30°) y otra dirección fija $\mathbf{d}$, y confirma que I_1, I_2 siguen siendo idénticos mientras que $\mathbf{d} \cdot \mathbf{C}\mathbf{d}$ cambia. Cuando estés listo, seguimos con el Capítulo 6: cómo combinar *varias* direcciones fijas, con pesos, en una familia de features direccionales controlada: las direcciones balanceadas.

7 Direcciones balanceadas: cómo se construye la anisotropía

7.1 El problema: I_1 no basta, y ya sabemos por qué

En el Capítulo 6 vimos que $I_1 = \text{tr } \mathbf{C} = |\mathbf{F}|^2$ es ciego a la orientación: no sabe nada de direcciones, y por eso no puede describir un material con fibras. Si estiras el material 20% hacia la derecha o 20% hacia arriba, I_1 da exactamente el mismo número en los dos casos (compruébalo: para $\mathbf{F} = \text{diag}(1.2, 1)$ y $\mathbf{F} = \text{diag}(1, 1.2)$, $I_1 = \text{tr}(\mathbf{F}^T \mathbf{F})$ es idéntico en ambos, por simetría), exactamente el mismo fenómeno del Ejemplo 11, ahora en $\mathbf{F}$ en vez de en $\mathbf{C}$.

Pero nuestro material (piensa en el RVE con el agujero circular, o en cualquier tejido con fibras) **sí** puede responder distinto según la dirección: más rígido a lo largo de una fibra, más flexible perpendicular a ella. Necesitamos features que sepan distinguir direcciones: ahí es donde entra la idea de sumar, con pesos, la respuesta del material medida en varias direcciones concretas $\mathbf{d}_1, \mathbf{d}_2, \mathbf{d}_3$.

7.2 La idea: promediar (con pesos) sobre varias direcciones

Para una dirección unitaria $\mathbf{d}$, la cantidad $\mathbf{d} \cdot \mathbf{C}\mathbf{d} = |\mathbf{F}\mathbf{d}|^2$ mide cuánto se estira el material específicamente en la dirección $\mathbf{d}$ (es exactamente la fórmula de longitudes al cuadrado del Capítulo 3, (18), aplicada a $\mathbf{d}$). Eso ya distingue direcciones. La pregunta es cómo combinar varias de estas medidas, en varias direcciones, en un conjunto de features manejable, y el paper lo hace con una suma ponderada

$$\sum_{i=1}^3 w_i (\mathbf{d}_i \cdot \mathbf{C}\mathbf{d}_i)^p \quad (31)$$

sobre tres direcciones $\mathbf{d}_1, \mathbf{d}_2, \mathbf{d}_3$ con pesos w_1, w_2, w_3 , para distintas potencias p . Pero no podemos elegir los pesos w_i de cualquier manera: si los elegimos mal, esta suma introduciría anisotropía incluso donde no debería haberla, o duplicaría información que I_1 ya nos da. Necesitamos una regla.

7.3 La regla: la condición de balance

La regla que impone el paper es

$$\sum_{i=1}^3 w_i \mathbf{d}_i \otimes \mathbf{d}_i = \mathbf{I}, \quad (32)$$

donde $\mathbf{d} \otimes \mathbf{d}$ es la matriz 2×2 con entradas $(\mathbf{d} \otimes \mathbf{d})_{jk} = d_j d_k$ (para $\mathbf{d} = (\cos \theta, \sin \theta)$, esto es $\begin{pmatrix} \cos^2 \theta & \sin \theta \cos \theta \\ \sin \theta \cos \theta & \sin^2 \theta \end{pmatrix}$).

¿Por qué esta condición en particular? Porque garantiza que, para $p = 1$, la suma ponderada (31) **colapsa exactamente a** I_1 , sin importar qué ángulos elijamos:

$$\sum_i w_i (\mathbf{d}_i \cdot \mathbf{C} \mathbf{d}_i) = \sum_i w_i \operatorname{tr}(\mathbf{C} \mathbf{d}_i \otimes \mathbf{d}_i) = \operatorname{tr}\left(\mathbf{C} \sum_i w_i \mathbf{d}_i \otimes \mathbf{d}_i\right) \stackrel{(32)}{=} \operatorname{tr}(\mathbf{C} \mathbf{I}) = \operatorname{tr} \mathbf{C} = I_1.$$

(Usamos $\mathbf{d} \cdot \mathbf{C} \mathbf{d} = \operatorname{tr}(\mathbf{C} \mathbf{d} \otimes \mathbf{d})$, cierto para cualquier vector $\mathbf{d}$ y matriz simétrica $\mathbf{C}$; verifícalo tú mismo expandiendo ambos lados en componentes.)

Idea clave 14. *La condición de balance no es arbitraria: es exactamente la condición que hace que el caso más simple ($p = 1$) de la suma ponderada no aporte ninguna información nueva: siempre reproduce I_1 , sea cual sea la elección de ángulos. Toda la anisotropía genuina tiene que venir de las potencias $p \geq 2$, que en general **no** colapsan a una función de I_1 sola (lo veremos en el próximo capítulo). El balance evita que estemos inventando anisotropía por una elección descuidada de pesos, en vez de por una elección deliberada de exponente.*

7.4 Resolviéndolo: un sistema lineal 3×3

En 2D, cada dirección $\mathbf{d}_i$ es un ángulo θ_i , y $\mathbf{d}_i \otimes \mathbf{d}_i$ tiene tres entradas independientes (es simétrica 2×2). Escribiendo (32) entrada por entrada se obtiene un sistema lineal de tres ecuaciones para los tres pesos w_1, w_2, w_3 :

$$\begin{pmatrix} \cos^2 \theta_1 & \cos^2 \theta_2 & \cos^2 \theta_3 \\ \sin^2 \theta_1 & \sin^2 \theta_2 & \sin^2 \theta_3 \\ \sin \theta_1 \cos \theta_1 & \sin \theta_2 \cos \theta_2 & \sin \theta_3 \cos \theta_3 \end{pmatrix} \begin{pmatrix} w_1 \\ w_2 \\ w_3 \end{pmatrix} = \begin{pmatrix} 1 \\ 1 \\ 0 \end{pmatrix}. \quad (33)$$

(Las primeras dos filas son las entradas diagonales de (32), que deben sumar 1 cada una, para dar $\mathbf{I}$; la tercera es la entrada fuera de la diagonal, que debe sumar 0.) Dados tres ángulos cualesquiera (no todos iguales entre sí), este sistema tiene solución única para los pesos.

Ejemplo 12 (Un sistema balanceado, resuelto y verificado). *Tomemos $\theta_1 = 0^\circ$, $\theta_2 = 55^\circ$, $\theta_3 = 130^\circ$ (ángulos arbitrarios, sin ninguna simetría especial). Resolviendo (33) numéricamente se obtiene*

$$w_1 = 0.412, \quad w_2 = 0.812, \quad w_3 = 0.775.$$

La Figura 7 dibuja las tres direcciones, con el grosor de cada línea proporcional a su peso. Verificamos directamente (32) sumando las tres matrices $w_i \mathbf{d}_i \otimes \mathbf{d}_i$:

$$\sum_i w_i \mathbf{d}_i \otimes \mathbf{d}_i = \begin{pmatrix} 1.000 & -6 \times 10^{-17} \\ -6 \times 10^{-17} & 1.000 \end{pmatrix} = \mathbf{I}$$

(el 6×10^{-17} es puro error numérico de redondeo, cero hasta la precisión de la máquina). Y, tomando una matriz $\mathbf{C}$ simétrica positiva definida cualquiera (generada al azar en la verificación numérica), la suma ponderada con $p = 1$ reproduce $\operatorname{tr} \mathbf{C}$ exactamente, hasta el último dígito, tal como prometía la demostración de arriba.

7.5 ¿Y si $p = 2$ o $p = 3$? El balance protege algo distinto

Buena pregunta, y la respuesta **no** es la misma que para $p = 1$. Para $p = 1$, el balance hacía que la suma *colapsara por completo* a I_1 , una identidad válida para **cualquier** $\mathbf{C}$, no solo cerca de la referencia. Si el balance hiciera lo mismo para $p = 2, 3$, estaríamos tirando exactamente la anisotropía que queríamos capturar, y no tendría sentido subir la potencia.

Sistema balanceado de 3 direcciones: $\sum_i w_i \mathbf{d}_i \otimes \mathbf{d}_i = \mathbf{I}$
(grosor de la línea $\propto$ peso w_i)




Figure 7: Un sistema balanceado de tres direcciones (ángulos arbitrarios $0^\circ, 55^\circ, 130^\circ$). El grosor de cada línea es proporcional a su peso w_i ; las direcciones se dibujan como líneas, no flechas, porque $\mathbf{d}$ y $-\mathbf{d}$ dan el mismo $\mathbf{d} \otimes \mathbf{d}$ y por tanto son intercambiables para este propósito.

Por suerte, no es lo que pasa. Verifiquemoslo con los mismos $\mathbf{C}_1, \mathbf{C}_2$ del Capítulo 6 (mismos I_1, I_2 , elipse rotada 45°) y el mismo sistema balanceado de este capítulo:

p	$\sum_i w_i (\mathbf{d}_i \cdot \mathbf{C}_1 \mathbf{d}_i)^p$	$\sum_i w_i (\mathbf{d}_i \cdot \mathbf{C}_2 \mathbf{d}_i)^p$
1	2.500000	2.500000
2	3.423609	3.951391
3	5.184615	6.977254

Para $p = 1$, idénticos (ya lo sabíamos). Para $p = 2, 3$, **distintos**: la suma ponderada sí distingue $\mathbf{C}_1$ de $\mathbf{C}_2$, exactamente lo que queríamos. El balance, aparentemente, no le quita nada a la anisotropía de $p \geq 2$.

Entonces, ¿por qué seguir imponiéndolo ahí? Porque protege algo más sutil que “no colapsar a I_1 ”: protege el comportamiento **exactamente en el estado de referencia**, $\mathbf{C} = \mathbf{I}$, no en todas partes, solo ahí.

Fijémonos en $t_i := \mathbf{d}_i \cdot \mathbf{C} \mathbf{d}_i$. En la referencia, $\mathbf{C} = \mathbf{I}$, así que $t_i = \mathbf{d}_i \cdot \mathbf{d}_i = 1$ para **todos** los i , sin importar qué ángulos hayamos elegido (los $\mathbf{d}_i$ son unitarios). Con esto, la derivada de $g_k(\mathbf{C}) = \sum_i w_i t_i^p$ respecto de $\mathbf{C}$, evaluada en la referencia, es

$$\left. \frac{\partial g_k}{\partial \mathbf{C}} \right|_{\mathbf{C}=\mathbf{I}} = \sum_i w_i p t_i^{p-1} \Big|_{t_i=1} \mathbf{d}_i \otimes \mathbf{d}_i = p \sum_i w_i \mathbf{d}_i \otimes \mathbf{d}_i \stackrel{(32)}{=} p \mathbf{I},$$

para cualquier p , gracias al balance. Verificado numéricamente (derivadas por diferencias finitas, con nuestro propio sistema de ángulos $0^\circ, 55^\circ, 130^\circ$):

$$p = 1 : \begin{pmatrix} 1 & 0 \\ 0 & 1 \end{pmatrix}, \quad p = 2 : \begin{pmatrix} 2 & 0 \\ 0 & 2 \end{pmatrix}, \quad p = 3 : \begin{pmatrix} 3 & 0 \\ 0 & 3 \end{pmatrix} \quad \left(= p \mathbf{I} \text{ en cada caso} \right).$$

Idea clave 15. *El balance cumple **dos** papeles distintos, uno por rango de p :*

- Para $p = 1$: colapsa la suma a I_1 **en todo el dominio** de C , una identidad global, por eso no aporta información nueva en absoluto.
- Para $p \geq 2$: **no** colapsa la suma globalmente (sí hay anisotropía genuína, verificado arriba con $C_1 \neq C_2$ pero mismos invariantes): solo fija que su **derivada, justo en $C = I$** , sea pI : isotrópica, sin importar los ángulos.

*Esto no es un capricho: en un capítulo posterior veremos que la energía completa necesita tener tensión exactamente cero en la referencia (condición (C4) del paper), y esa demostración cancela el residuo de la red con un único escalar r : algo que solo funciona porque **cada** feature $Q_{k,p}^F, Q_{k,p}^H$, para **cualquier** k y p , aporta un residuo isotrópico ($\propto I$) en la referencia. Si una sola de estas features usara pesos sin balancear, su contribución al residuo sería anisotrópica, y ningún escalar único podría cancelar la suma completa. El balance no limita la anisotropía lejos de la referencia (donde vive toda la información que nos interesa); solo la prohíbe explícitamente en la referencia (donde, por (C4), no debe haber ninguna).*

Antes de seguir: repite la verificación numérica de la tabla de arriba con tu propio sistema de ángulos (el que resolviste en el ejercicio del capítulo anterior) y con C_1, C_2 de tu elección (mismos autovalores, distintos autovectores) para $p = 2$, y confirma que los valores difieren: la anisotropía sobrevive.

7.6 Resumen de este capítulo

Idea clave 16. • I_1 no distingue direcciones; para capturar anisotropía genuína hace falta medir el estiramiento en direcciones concretas, $\mathbf{d} \cdot C\mathbf{d} = |\mathbf{F}\mathbf{d}|^2$.

- Combinamos varias direcciones con una suma ponderada $\sum_i w_i (\mathbf{d}_i \cdot C\mathbf{d}_i)^p$, pero los pesos no son libres: deben satisfacer la **condición de balance** $\sum_i w_i \mathbf{d}_i \otimes \mathbf{d}_i = I$.
- Esa condición garantiza, con una demostración de tres líneas, que el caso $p = 1$ siempre colapsa exactamente a I_1 : ninguna anisotropía se cuela por una mala elección de pesos.
- En 2D, la condición de balance es un sistema lineal 3×3 para los pesos, dados los ángulos; lo resolvimos y lo verificamos numéricamente para tres ángulos arbitrarios.

¿De dónde viene esta idea? Combinar varias direcciones fijas con pesos que satisfacen una condición de exactitud tampoco es una invención de este proyecto. Bažant y Oh [8] construyen, para integración numérica sobre la esfera (no para hiperelasticidad), conjuntos discretos de direcciones y pesos que reproducen exactamente integrales de polinomios hasta cierto grado; de sus propias condiciones de exactitud se sigue, aunque ellos no lo escriben así explícitamente, una identidad tensorial equivalente a $\sum_i w_i \mathbf{d}_i \otimes \mathbf{d}_i = I$ (salvo normalización). Es la construcción discreta más cercana a la nuestra que encontramos en la literatura, aunque en un campo distinto (integración numérica, no hiperelasticidad anisotrópica).

Antes de seguir: elige tus propios tres ángulos (evita que dos sean iguales) y resuelve tú mismo el sistema (33) (con lápiz y papel o con una calculadora) y confirma que los pesos que obtienes satisfacen (32). Cuando estés listo, seguimos con el Capítulo 7: qué pasa cuando subimos la potencia a $p = 2$ y $p = 3$; ahí es donde aparece la anisotropía genuina, y donde nacen las features $Q_{k,p}^F$ y $Q_{k,p}^H$ del paper.

8 Las features $Q_{k,p}^F$ y $Q_{k,p}^H$, y una redundancia sorprendente

8.1 Recordatorio: el bloque F

Ya tenemos todo lo necesario para el bloque F . Para cada sistema balanceado k (ángulos $\theta_{k1}, \theta_{k2}, \theta_{k3}$, pesos w_{k1}, w_{k2}, w_{k3} del Capítulo 7), definimos

$$Q_{k,p}^F := \sum_{i=1}^3 w_{ki} (\mathbf{d}_{ki} \cdot \mathbf{C} \mathbf{d}_{ki})^p = \sum_{i=1}^3 w_{ki} |\mathbf{F} \mathbf{d}_{ki}|^{2p}, \quad p = 2, 3, \quad (34)$$

usando $\mathbf{d} \cdot \mathbf{C} \mathbf{d} = |\mathbf{F} \mathbf{d}|^2$ del Capítulo 3. Esto mide, con pesos, cuánto se estiran las tres direcciones del sistema k , elevado a la potencia p para que $p = 2, 3$ (a diferencia de $p = 1$) sí porten anisotropía genuína, como acabamos de verificar.

¿De dónde viene esta idea? Para una sola dirección y $p = 1$, $Q_{k,1}^F$ es exactamente el pseudo-invariante clásico $\mathbf{d} \cdot \mathbf{C} \mathbf{d}$ del Capítulo 6 (Spencer [3, 4], Boehler [5]). Que elevarlo a *cualquier* potencia p , para una sola dirección fija, preserva la polyconvexidad ya lo demostraron Schröder y Neff [6], junto con el análogo construido con $\text{cof } \mathbf{C}$ en vez de $\mathbf{C}$, exactamente el bloque H que construiremos más adelante en este capítulo; el paper principal extiende esa idea a nuestras sumas balanceadas sobre varias direcciones.

8.2 ¿Por qué no basta con el bloque F ?

$\mathbf{F}$ nos dice cómo se estiran las direcciones materiales (Capítulo 1). Pero en el Capítulo 5 vimos que $\text{cof } \mathbf{F}$ contiene información *distinta*: cómo se transforman normales y áreas: algo que $\mathbf{F}$ solo, por construcción, no puede decirnos directamente ($\mathbf{F} \mathbf{n}$ ni siquiera se queda perpendicular a $\mathbf{F} \mathbf{t}$, lo verificamos con números en ese capítulo). Si $\text{cof } \mathbf{F}$ trae información geométrica distinta de la de $\mathbf{F}$, tiene sentido preguntarse si también trae información *anisotrópica* distinta, y construir un segundo bloque de features, análogo al primero, pero con $\text{cof } \mathbf{F}$ en vez de $\mathbf{F}$.

Definimos, exactamente igual que arriba pero con $\text{cof } \mathbf{C}$ en vez de $\mathbf{C}$ (recordando, del Capítulo 5, que $\mathbf{d} \cdot \text{cof}(\mathbf{C}) \mathbf{d} = |\text{cof}(\mathbf{F}) \mathbf{d}|^2$, la misma identidad de longitudes al cuadrado aplicada a $\text{cof } \mathbf{F}$ en vez de a $\mathbf{F}$):

$$Q_{k,p}^H := \sum_{i=1}^3 w_{ki} (\mathbf{d}_{ki} \cdot \text{cof}(\mathbf{C}) \mathbf{d}_{ki})^p = \sum_{i=1}^3 w_{ki} |\text{cof}(\mathbf{F}) \mathbf{d}_{ki}|^{2p}, \quad p = 2, 3. \quad (35)$$

Como $\text{cof}(\mathbf{I}) = \mathbf{I}$ (compruébalo con la fórmula del Capítulo 5), el mismo argumento de balance del Capítulo 7 (Sección 7.5) aplica palabra por palabra a $Q_{k,p}^H$: su derivada en la referencia también es $p \mathbf{I}$, isotrópica, para cualquier p .

8.3 Una sorpresa: verifiquemos $Q_{k,2}^F$ y $Q_{k,2}^H$ con números

Usemos el corte del Capítulo 1, $\mathbf{F} = \begin{pmatrix} 1 & 0.6 \\ 0 & 1 \end{pmatrix}$, con nuestro sistema balanceado de ángulos $0^\circ, 55^\circ, 130^\circ$ del Capítulo 7. Calculando:

$$\mathbf{C} = \begin{pmatrix} 1 & 0.6 \\ 0.6 & 1.36 \end{pmatrix}, \quad \text{cof } \mathbf{C} = \begin{pmatrix} 1.36 & -0.6 \\ -0.6 & 1 \end{pmatrix}.$$

Evalutando (34) y (35) numéricamente:

$$Q_{k,2}^F = 3.358653, \quad Q_{k,2}^H = 3.358653.$$

Idénticos, hasta el último dígito. Esto no parece casualidad. Y no lo es.

8.4 Por qué $Q_{k,2}^F = Q_{k,2}^H$ siempre, en 2D

La razón es una identidad algebraica de 2D que ya casi tenemos: recuerda que, para $\mathbf{C}$ simétrica 2×2 , $\text{cof } \mathbf{C} = \begin{pmatrix} C_{22} & -C_{12} \\ -C_{12} & C_{11} \end{pmatrix}$ (Capítulo 5). Escribiendo $T := \text{tr } \mathbf{C} = C_{11} + C_{22}$,

$$T\mathbf{I} - \mathbf{C} = \begin{pmatrix} T - C_{11} & -C_{12} \\ -C_{12} & T - C_{22} \end{pmatrix} = \begin{pmatrix} C_{22} & -C_{12} \\ -C_{12} & C_{11} \end{pmatrix} = \text{cof } \mathbf{C}$$

(usamos $T - C_{11} = C_{22}$ y $T - C_{22} = C_{11}$, ciertas por definición de T). Es decir, **en 2D**,

$$\text{cof } \mathbf{C} = T\mathbf{I} - \mathbf{C}, \quad T := \text{tr } \mathbf{C}. \quad (36)$$

Verifícalo con nuestros números: $T = 1 + 1.36 = 2.36$, y $T\mathbf{I} - \mathbf{C} = \begin{pmatrix} 2.36 - 1 & -0.6 \\ -0.6 & 2.36 - 1.36 \end{pmatrix} = \begin{pmatrix} 1.36 & -0.6 \\ -0.6 & 1 \end{pmatrix}$, exactamente $\text{cof } \mathbf{C}$ de arriba.

Con esta identidad, y escribiendo $t_i := \mathbf{d}_i \cdot \mathbf{C} \mathbf{d}_i$ (así que $\mathbf{d}_i \cdot \text{cof}(\mathbf{C}) \mathbf{d}_i = T|\mathbf{d}_i|^2 - t_i = T - t_i$, usando que $\mathbf{d}_i$ es unitario):

$$Q_{k,2}^H = \sum_i w_i (T - t_i)^2 = \sum_i w_i (T^2 - 2Tt_i + t_i^2) = T^2 \sum_i w_i - 2T \sum_i w_i t_i + \sum_i w_i t_i^2.$$

Necesitamos dos hechos que ya conocemos: $\sum_i w_i t_i = I_1 = T$ (el colapso a $p = 1$ del Capítulo 7), y $\sum_i w_i = 2$: éste es nuevo, pero se obtiene tomando la traza de la propia condición de balance (32): $\text{tr}(\sum_i w_i \mathbf{d}_i \otimes \mathbf{d}_i) = \sum_i w_i \text{tr}(\mathbf{d}_i \otimes \mathbf{d}_i) = \sum_i w_i |\mathbf{d}_i|^2 = \sum_i w_i$, y esto debe igualar $\text{tr } \mathbf{I} = 2$. (Verifícalo con nuestros pesos: $0.412 + 0.812 + 0.775 = 1.999 \approx 2$, hasta redondeo.) Sustituyendo:

$$Q_{k,2}^H = T^2(2) - 2T(T) + Q_{k,2}^F = 2T^2 - 2T^2 + Q_{k,2}^F = Q_{k,2}^F.$$

Idea clave 17. $Q_{k,2}^F = Q_{k,2}^H$ *exactamente*, siempre, en 2D: no es una coincidencia numérica de nuestro ejemplo, es una consecuencia algebraica directa de $\text{cof } \mathbf{C} = T\mathbf{I} - \mathbf{C}$ (una identidad puramente 2D) combinada con el balance. El bloque H , en $p = 2$, no aporta **ninguna** información que el bloque F no tuviera ya.

8.5 ¿Y en $p = 3$? Ahí sí aparece información nueva

Repitamos el cálculo para $p = 3$ con el mismo ejemplo:

$$Q_{k,3}^F = 5.377935, \quad Q_{k,3}^H = 5.257074.$$

Distintos. Repitiendo el mismo truco (expandir $(T - t_i)^3 = T^3 - 3T^2 t_i + 3T t_i^2 - t_i^3$ y sumar con pesos w_i , usando $\sum w_i = 2$, $\sum w_i t_i = T$, $\sum w_i t_i^2 = Q_{k,2}^F$, $\sum w_i t_i^3 = Q_{k,3}^F$) se obtiene una relación exacta, no una igualdad:

$$Q_{k,3}^H = -T^3 + 3T Q_{k,2}^F - Q_{k,3}^F. \quad (37)$$

Verifiquemosla: $T = 2.36$, $Q_{k,2}^F = 3.358653$, $Q_{k,3}^F = 5.377935$,

$$-T^3 + 3T Q_{k,2}^F - Q_{k,3}^F = -13.144256 + 3(2.36)(3.358653) - 5.377935 = 5.257074,$$

que coincide con $Q_{k,3}^H$ calculado directamente arriba, hasta el último dígito.

Idea clave 18. $Q_{k,3}^H$ no es independiente de $T, Q_{k,2}^F, Q_{k,3}^F$ (se puede calcular a partir de ellos exactamente con (37)), pero **no es igual** a $Q_{k,3}^F$ (a diferencia de $p = 2$). Es aquí, en $p = 3$, donde el bloque H finalmente aporta algo que el bloque F no contenía. Ésta es exactamente la razón por la que el paper necesita subir hasta $p = 3$ (no le bastaría con $p = 2$) para que $\text{cof } \mathbf{F}$ deje de ser un pasajero redundante y empiece a aportar anisotropía propia.

8.6 Ensamblando las quince features

Con I_1 (Capítulo 6), J, J^2 (Capítulo 1), y $Q_{k,p}^F, Q_{k,p}^H$ para $p = 2, 3$ y tres sistemas de direcciones $k = 1, 2, 3$, el vector de features completo del paper es

$$z_{pc} = (I_1, \{Q_{k,2}^F, Q_{k,3}^F, Q_{k,2}^H, Q_{k,3}^H\}_{k=1}^3, J, J^2) \in \mathbb{R}^{15} \quad (38)$$

Contemos: 1 (de I_1) + 3×4 (tres sistemas, cuatro features cada uno: $Q_2^F, Q_3^F, Q_2^H, Q_3^H$) + 2 (de J, J^2) = $1 + 12 + 2 = 15$. Y ahora sabemos, con demostración propia y no solo de nombre, exactamente qué tan independientes son estas quince entradas entre sí: I_1 es un caso límite ($p = 1$) que colapsa para *cualquier* sistema; cada $Q_{k,2}^H$ es idéntico a su $Q_{k,2}^F$ correspondiente; solo $Q_{k,3}^H$ aporta, dentro de cada sistema k , algo que no estuviera ya en $I_1, Q_{k,2}^F, Q_{k,3}^F$.

Un pariente continuo. La construcción de este capítulo (varias direcciones discretas, cada una con su peso) tiene un pariente cercano en la biomecánica de tejidos fibrosos: Gasser, Ogden y Holzapfel [7] generalizan el mismo pseudo-invariante $\mathbf{d} \cdot \mathbf{C} \mathbf{d}$ a una integral continua sobre una distribución de orientaciones de fibra, en vez de una suma discreta sobre unas pocas direcciones fijas. Es la misma idea de fondo, con una integral en lugar de una suma.

8.7 Una decisión honesta: ¿quince inputs, o doce?

Dado lo que acabamos de demostrar, surge una pregunta legítima: si $Q_{k,2}^H = Q_{k,2}^F$ siempre, ¿no deberíamos simplemente **quitar** $Q_{k,2}^H$ del vector de features y entrenar con doce en vez de quince? Vale la pena responderla con el mismo rigor que todo lo demás, no dejarla como curiosidad.

La red Φ_θ (la discutiremos a fondo más adelante) es una ICNN *monótona*: todos sus pesos, en cada capa, son ≥ 0 . Esto tiene una consecuencia directa sobre qué combinaciones de las features de entrada puede reconstruir internamente:

- Como $Q_{k,2}^H = Q_{k,2}^F$ tiene coeficiente +1 (ningún signo negativo), una red así **ya puede** representar cualquier múltiplo no negativo de $Q_{k,2}^H$ simplemente ajustando el peso que le asigna a $Q_{k,2}^F$. Dar $Q_{k,2}^H$ como input separado **no cambia en nada** el conjunto de funciones que la red puede representar: no es solo redundante en información, es redundante en *expresividad*.
- $Q_{k,3}^H = -T^3 + 3T Q_{k,2}^F - Q_{k,3}^F$, en cambio, necesita coeficientes **negativos** (-1 en T^3 y en $Q_{k,3}^F$) para reconstruirse a partir de las demás: algo que una red con pesos ≥ 0 no puede hacer internamente. Ahí sí, darle $Q_{k,3}^H$ como input propio le da acceso a combinaciones que de otra forma serían inalcanzables.

Entonces, con toda honestidad: **sí, se podría entrenar con doce inputs en vez de quince**, quitando $Q_{k,2}^H$ de cada uno de los tres sistemas, sin perder absolutamente nada de lo que el modelo puede representar. Verificamos, además, que esta redundancia no es solo teórica: se cumple a precisión de máquina con los ángulos y pesos *reales* del modelo entrenado ($\theta = (0^\circ, 50^\circ, 130^\circ)$ y sus análogos para los otros dos sistemas), no solo con el ejemplo genérico de este capítulo.

¿Por qué, entonces, se mantienen los quince? No porque así se haya planeado desde el principio: la redundancia es, honestamente, una coincidencia de 2D que se descubrió después, no un diseño deliberado. La decisión de **mantenerla**, tomada ahora, con esto ya sabido, es por uniformidad con la receta general: el bloque H se construye exactamente igual que el bloque F (con $\text{cof } \mathbf{F}$ en vez de $\mathbf{F}$) para *todo* k y *todo* p , sin casos especiales, y esa receta general es independiente de la dimensión. En 3D, como vimos, $\text{cof } \mathbf{C}$ ya no es afín en $\mathbf{C}$ (es cuadrática), así que la misma construcción **no** colapsaría: $Q_{k,2}^H$ sería, ahí, tan genuinamente nueva como $Q_{k,3}^H$ lo es aquí. Reentrenar para quitar un término que solo es redundante en el caso 2D concreto de este RVE tiene un costo real (rehacer verificaciones, tablas, ambos núcleos ICNN e ICKAN) por una ganancia que es puramente estética; así que, con conocimiento completo de que es opcional, se optó por no hacerlo.

Idea clave 19. $Q_{k,2}^H$ es prescindible **de verdad**: no solo redundante en información, sino redundante en lo que la red puede aprender, algo demostrado y no solo observado. Se mantiene por una decisión de uniformidad arquitectónica tomada con ese conocimiento, no porque aporte algo ni porque así se diseñó originalmente. $Q_{k,3}^H$ es un caso distinto: genuinamente necesario, porque reconstruirlo exige coeficientes negativos que la red monótona no puede producir por su cuenta.

8.8 Resumen de este capítulo

Idea clave 20. • El bloque H se construye exactamente igual que el bloque F , pero usando $\text{cof } \mathbf{C}$ en vez de $\mathbf{C}$, motivado porque $\text{cof } \mathbf{F}$ porta información geométrica distinta de $\mathbf{F}$ (Capítulo 5).

- En $2D$, $\text{cof } \mathbf{C} = T\mathbf{I} - \mathbf{C}$ ($T = \text{tr } \mathbf{C}$) es una identidad exacta que, combinada con el balance, fuerza $Q_{k,2}^F = Q_{k,2}^H$ **siempre**, una redundancia real, no aproximada, verificada tanto en general como con los números reales del modelo entrenado.
- $Q_{k,3}^F$ y $Q_{k,3}^H$ ya no coinciden, pero están relacionados por la fórmula exacta $Q_{k,3}^H = -T^3 + 3T Q_{k,2}^F - Q_{k,3}^F$: aquí es donde el bloque H finalmente aporta algo nuevo.
- Dado el signo de esos coeficientes, $Q_{k,2}^H$ no aporta **ninguna** expresividad a una ICNN monótona (se podría entrenar con doce inputs sin perder nada), mientras que $Q_{k,3}^H$ sí, genuinamente. Se decidió mantener los quince por uniformidad con la receta general (independiente de la dimensión), no porque $Q_{k,2}^H$ aporte algo, y esa distinción se dice así, sin adornos, en el paper.

Antes de seguir: repite la verificación numérica de este capítulo con otra $\mathbf{F}$ de tu elección (por ejemplo el estiramiento $\text{diag}(2, 1)$ del Capítulo 1) y confirma que $Q_{k,2}^F = Q_{k,2}^H$ exactamente, mientras que (37) predice $Q_{k,3}^H$ correctamente a partir de $Q_{k,3}^F$. Cuando estés listo, seguimos con el Capítulo 8, la condición de crecimiento: por qué $Q_{k,3}^F \geq \frac{1}{4}|\mathbf{F}|^6$, y qué tiene que ver Jensen con todo esto.

9 La condición de crecimiento: por qué $Q_{k,3} \geq \frac{1}{4}|\mathbf{F}|^6$

9.1 Para qué sirve esto

Ya vimos, en el Capítulo 4, que la energía debe **explotar** cuando el material colapsa ($J \rightarrow 0^+$): eso lo maneja el término $-r \log J$. Pero la condición de crecimiento (C6) pide algo más: que la energía también explote cuando el material se **estira sin límite** ($|\mathbf{F}| \rightarrow \infty$). Como Φ_θ es no decreciente en cada feature (Capítulo 8 en adelante lo usa; lo formalizaremos del todo más tarde), basta con que **alguna** de las quince features crezca sin límite cuando $|\mathbf{F}| \rightarrow \infty$, con una tasa conocida. Ese es el papel de $Q_{k,3}^F, Q_{k,3}^H$: vamos a demostrar que crecen, como mínimo, tan rápido como $|\mathbf{F}|^6$.

9.2 El ingrediente: Jensen, aplicado exactamente donde x^3 sí es convexa

Recuerda la Figura 3 del Capítulo 4: $h(x) = x^3$ no es convexa ni cóncava en todo $\mathbb{R}$: se curva hacia abajo para $x < 0$ y hacia arriba para $x > 0$. Pero nuestras cantidades $t_i := \mathbf{d}_i \cdot \mathbf{C} \mathbf{d}_i = |\mathbf{F} \mathbf{d}_i|^2$ son **siempre** ≥ 0 (son longitudes al cuadrado). Restringida a $x \geq 0$, x^3 **sí** es convexa (segunda derivada $6x \geq 0$ ahí), así que, sin ninguna contradicción con el Capítulo 4, podemos aplicarle la desigualdad de Jensen a nuestros t_i .

Jensen, para una función convexa ϕ y pesos normalizados $\hat{w}_i \geq 0$ con $\sum_i \hat{w}_i = 1$, dice

$$\sum_i \hat{w}_i \phi(x_i) \geq \phi\left(\sum_i \hat{w}_i x_i\right). \quad (39)$$

(El promedio de la función es al menos la función del promedio, exactamente la definición geométrica de convexidad que usamos desde el Capítulo 4: la cuerda queda por encima de la función, así que el valor *promedio* en la cuerda domina al valor de la función en el punto promedio.)

Nuestros pesos w_i no sonan a 1, sino a 2 (Capítulo 8: $\sum_i w_i = 2$, tomando la traza de la condición de balance). Los normalizamos: $\hat{w}_i := w_i/2$, así que $\sum_i \hat{w}_i = 1$.

9.3 La demostración, en tres líneas

Aplicando (39) con $\phi(x) = x^3$ y $x_i = t_i$:

$$\sum_i \hat{w}_i t_i^3 \geq \left(\sum_i \hat{w}_i t_i \right)^3.$$

Multiplicando ambos lados por 2 y usando $\hat{w}_i = w_i/2$:

$$Q_{k,3}^F = \sum_i w_i t_i^3 = 2 \sum_i \hat{w}_i t_i^3 \geq 2 \left(\sum_i \hat{w}_i t_i \right)^3 = 2 \left(\frac{1}{2} \sum_i w_i t_i \right)^3 = 2 \left(\frac{T}{2} \right)^3 = \frac{T^3}{4}$$

(usamos $\sum_i w_i t_i = T$, el colapso a $p = 1$ del Capítulo 7). Y como $T = \text{tr } \mathbf{C} = |\mathbf{F}|^2$ (Capítulo 6), $T^3 = |\mathbf{F}|^6$, así que

$$Q_{k,3}^F \geq \frac{1}{4} |\mathbf{F}|^6. \quad (40)$$

Tres líneas, sin nada oculto: normalizar los pesos, aplicar Jensen, sustituir el colapso a I_1 que ya conocíamos.

Ejemplo 13 (Verificado con los ángulos reales del modelo). *Usando el sistema real $\theta = (0^\circ, 50^\circ, 130^\circ)$, $w = (0.2959, 0.8520, 0.8520)$, y el corte $\mathbf{F} = \begin{pmatrix} 1 & 0.6 \\ 0 & 1 \end{pmatrix}$ de siempre ($|\mathbf{F}|^2 = T = 2.36$):*

$$\sum_i \hat{w}_i t_i^3 = 2.743, \quad \left(\sum_i \hat{w}_i t_i \right)^3 = 1.643,$$

Jensen se cumple ($2.743 \geq 1.643$), y

$$Q_{k,3}^F = 5.486, \quad \frac{1}{4} |\mathbf{F}|^6 = 3.286,$$

la cota se cumple ($5.486 \geq 3.286$), con margen: no es ajustada para esta $\mathbf{F}$ en particular.

9.4 ¿Es la cota ajustada alguna vez?

Sí: exactamente cuando Jensen se cumple con igualdad, es decir, cuando todos los t_i son iguales entre sí. Esto pasa, por ejemplo, si $\mathbf{F} = \sqrt{c} \mathbf{I}$ (un escalado isótropo puro, sin corte ni anisotropía): entonces $t_i = \mathbf{d}_i \cdot (c\mathbf{I}) \mathbf{d}_i = c |\mathbf{d}_i|^2 = c$ para **todas** las direcciones, sin importar el ángulo. Verificando con $c = 2$: $Q_{k,3}^F = 16.0$ y $\frac{1}{4} |\mathbf{F}|^6 = 16.0$, **exactamente iguales**, hasta el último dígito.

Idea clave 21. *La cota $Q_{k,3}^F \geq \frac{1}{4} |\mathbf{F}|^6$ no es floja ni arbitraria: es **ajustada** (se alcanza con igualdad) exactamente cuando la deformación es un escalado isótropo puro, el caso en que no hay ninguna dirección privilegiada, y por tanto ninguna pérdida de información al promediar con Jensen.*

9.5 Lo mismo para el bloque H

El argumento se repite palabra por palabra para $Q_{k,3}^H$, usando $s_i := \mathbf{d}_i \cdot \text{cof}(\mathbf{C}) \mathbf{d}_i = |\text{cof}(\mathbf{F}) \mathbf{d}_i|^2 \geq 0$ (otra longitud al cuadrado, también siempre no negativa) en vez de t_i . Lo único que hace falta confirmar es que $\sum_i w_i s_i$ también valga T , y en 2D, sí:

$$\sum_i w_i s_i = \text{tr} \left(\text{cof}(\mathbf{C}) \sum_i w_i \mathbf{d}_i \otimes \mathbf{d}_i \right) \stackrel{\text{balance}}{=} \text{tr} (\text{cof}(\mathbf{C})) = \text{tr } \mathbf{C} = T$$

(la última igualdad, $\text{tr}(\text{cof } \mathbf{C}) = \text{tr } \mathbf{C}$, es cierta para cualquier $\mathbf{C}$ simétrica 2×2 , verifícalo con la fórmula de $\text{cof } \mathbf{C}$ del Capítulo 5). Exactamente el mismo cálculo de tres líneas da

$$Q_{k,3}^H \geq \frac{1}{4}|\mathbf{F}|^6. \quad (41)$$

Verificado con nuestro ejemplo: $Q_{k,3}^H = 5.378 \geq 3.286$. ✓

9.6 ¿Y $p = 2$?

El mismo truco, con $\phi(x) = x^2$ (convexa en **todo** $\mathbb{R}$, sin necesitar restringirse a $x \geq 0$) da, por el cálculo idéntico, $Q_{k,2}^F, Q_{k,2}^H \geq \frac{1}{4}|\mathbf{F}|^4$: una cota de cuarto grado, más débil que la de sexto grado de $p = 3$. Por eso el paper apoya la condición de crecimiento en $Q_{k,3}^F, Q_{k,3}^H$: es la cota más fuerte disponible, y la que de verdad se necesita para dominar el resto de la energía cuando $|\mathbf{F}| \rightarrow \infty$.

9.7 Resumen de este capítulo

Idea clave 22. • $t_i = |\mathbf{F}\mathbf{d}_i|^2 \geq 0$ siempre, así que aunque x^3 no sea convexa en todo $\mathbb{R}$ (Capítulo 4), sí lo es exactamente donde la necesitamos: en $x \geq 0$.

- Jensen, con los pesos normalizados ($\sum \hat{w}_i = 1$, de $\sum w_i = 2$) y el colapso a $I_1 = T = |\mathbf{F}|^2$ del balance, da $Q_{k,3}^F, Q_{k,3}^H \geq \frac{1}{4}|\mathbf{F}|^6$ en tres líneas.
- La cota es ajustada exactamente en el caso isótropo puro ($\mathbf{F} = \sqrt{c}\mathbf{I}$), verificado con igualdad exacta.
- El mismo argumento con x^2 da una cota más débil, de cuarto grado, para $p = 2$: por eso es $p = 3$ el que sostiene la condición de crecimiento del paper.

Antes de seguir: repite la Ejemplo 13 con otra $\mathbf{F}$ de tu elección y confirma la cota; luego prueba con $\mathbf{F} = \sqrt{c}\mathbf{I}$ para un c distinto y confirma que la cota se vuelve igualdad exacta. Cuando estés listo, seguimos con el Capítulo 9: la otra mitad de la condición de crecimiento, la que falta, la barrera volumétrica $-r \log J + \frac{\beta}{2}(J - 1)^2$.

10 La barrera volumétrica: por qué hace falta $-r \log J + \frac{\beta}{2}(J - 1)^2$

10.1 Lo que el Capítulo 9 todavía no cubre

El Capítulo 9 demostró que la energía explota cuando el material se **estira** sin límite ($|\mathbf{F}| \rightarrow \infty$). Pero la condición de crecimiento (C6) pide algo más, en la otra dirección: la energía también debe explotar cuando el material **colapsa**, es decir, cuando el volumen se aplasta a cero ($J \rightarrow 0^+$). Estirar y aplastar son extremos distintos, y ninguna de las quince features $Q_{k,p}^F, Q_{k,p}^H, I_1$ vistas hasta ahora hace ese trabajo: todas dependen de $\mathbf{C} = \mathbf{F}^T \mathbf{F}$, y una matriz $\mathbf{F}$ puede aplastarse ($J \rightarrow 0$) sin que $|\mathbf{F}|$ dependa de eso en absoluto (piensa en $\mathbf{F} = \text{diag}(a, 1/a)$ con $a \rightarrow \infty$: $J = 1$ **siempre**, aunque $|\mathbf{F}| \rightarrow \infty$; o en $\mathbf{F} = \text{diag}(\epsilon, 1)$ con $\epsilon \rightarrow 0^+$: aquí $J \rightarrow 0$ pero $|\mathbf{F}|$ ni se inmuta). Colapso y estiramiento son fenómenos independientes, y cada uno necesita su propio mecanismo en la fórmula (1). Este capítulo cubre el que falta: los dos últimos términos,

$$h(J) := -r \log J + \frac{\beta}{2}(J - 1)^2, \quad (42)$$

con los valores reales del modelo entrenado, $r = 2.0390e - 01$ y $\beta = 2.2357e - 09$.

10.2 El primer término: por qué $-r \log J$ es una barrera de colapso

Con $r > 0$, la función $-\log J$ tiene exactamente la forma que queremos: cuando $J \rightarrow 0^+$, $\log J \rightarrow -\infty$, así que $-r \log J \rightarrow +\infty$. Ninguna deformación que aplaste el material a volumen cero puede tener energía finita: la barrera lo prohíbe de raíz, sin necesitar ninguna restricción adicional en el optimizador ni en la red. Es, además, convexa en J : la segunda derivada es

$$\frac{d^2}{dJ^2}(-r \log J) = \frac{r}{J^2} > 0 \quad \text{para todo } J > 0,$$

así que $-r \log J$ por sí sola ya contribuye a la polyconvexidad de Φ_θ (Capítulo 4: J es uno de los tres bloques de Ball, y $-\log J$ es convexa en ese bloque).

Ejemplo 14 (Verificado con el r real del modelo). Con $r = 2.0390e - 01$:

$$J = 0.5 : -r \log J = 0.1413, \quad J = 0.1 : -r \log J = 0.4696, \quad J = 0.01 : -r \log J = 0.9391,$$

creciendo sin límite a medida que $J \rightarrow 0^+$, exactamente como se esperaba.

10.3 Un hallazgo honesto: $-r \log J$ solo, no explota cuando $J \rightarrow \infty$

Aquí hay que ser cuidadosos, y no dar nada por sentado solo porque “tiene forma de barrera”. Miremos qué hace $-r \log J$ cuando $J \rightarrow \infty$ (el material se **expande** sin límite, en vez de colapsar). Como $\log J \rightarrow +\infty$, tenemos $-r \log J \rightarrow -\infty$: el término **decrece sin límite**, no crece. Esto no es un error de signo ni una sorpresa a estas alturas: $-\log J$ es convexa, sí, pero convexa **no** significa creciente en todas direcciones (el mismo punto del Capítulo 11 sobre la diferencia entre “convexa” y “no-decreciente”, aplicado aquí a un solo escalar). Una parábola $y = x^2$ también es convexa y también decrece a la izquierda del mínimo; $-\log J$ simplemente nunca llega a un mínimo dentro del rango $J > 0$, así que sigue decreciendo para siempre.

Ejemplo 15 (Verificado con el r real del modelo). Con $r = 2.0390e - 01$, el término $-r \log J$ solo:

$$J = 1 : 0, \quad J = 10 : -0.4696, \quad J = 100 : -0.9391, \quad J = 1000 : -1.4087,$$

cada vez más negativo, sin ningún indicio de detenerse.

Esto significa que, si $-r \log J$ fuera el único responsable del comportamiento en J **grande**, la condición de crecimiento (C6) fallaría: la energía bajaría sin límite en vez de subir. Aquí es donde entra el segundo término.

10.4 El segundo término: por qué hace falta $\frac{\beta}{2}(J-1)^2$

Con $\beta > 0$, $\frac{\beta}{2}(J-1)^2$ es una parábola con mínimo en $J = 1$ (deformación que no cambia el volumen), y crece sin límite en **ambas** direcciones: $J \rightarrow 0^+$ y $J \rightarrow \infty$. También es convexa en J (segunda derivada constante, $\beta > 0$), así que no estropea la polyconvexidad. Sumado a $-r \log J$, es exactamente lo que falta para que $h(J) \rightarrow +\infty$ también cuando $J \rightarrow \infty$: por grande que sea r y por pequeño que sea β , un término cuadrático siempre le gana a un logaritmo eventualmente, porque J^2 crece más rápido que $\log J$ sin importar las constantes que los multipliquen.

10.5 ¿Cuándo le gana el cuadrático al logaritmo, con los números reales?

Aquí es donde conviene ser explícitos, porque los números reales de este modelo dan una respuesta que vale la pena mirar de cerca. Buscamos dónde $h(J)$ deja de decrecer y empieza a crecer, es decir, dónde $h'(J) = 0$ para $J > 1$:

$$h'(J) = -\frac{r}{J} + \beta(J-1) = 0.$$

Con $r = 2.0390e - 01$ y $\beta = 2.2357e - 09$, resolviendo numéricamente:

$$J^* \approx 9550. \quad (43)$$

Es decir: con los valores realmente aprendidos por este modelo, el término cuadrático no le gana al logaritmo hasta una dilatación de área de casi diez mil veces. Para poner esto en perspectiva: ninguna trayectoria de este RVE, ni en entrenamiento ni en las pruebas del paper, se acerca remotamente a $J \sim 10^3$, mucho menos a $J \sim 10^4$. La conclusión honesta es esta: el término cuadrático es **matemáticamente imprescindible** (sin él, (C6) falla en $J \rightarrow \infty$, sin excepción), pero en la práctica, para cualquier estado de deformación que este RVE realmente visita, **nunca llega a activarse**: todo el trabajo útil de frenar el colapso en el rango operativo real lo hace $-r \log J$ solo.

Ejemplo 16 (Verificación del punto de cruce). *Evaluando $h'(J)$ justo en $J^* = 9550$:*

$$h'(9550) = -\frac{2.0390e - 01}{9550} + 2.2357e - 09 \times (9550 - 1) \approx -1.65 \times 10^{-9} \approx 0,$$

confirmando, hasta la precisión numérica, que este es en efecto el punto donde h cambia de decreciente a creciente.

La barrera volumétrica real: $r = 0.2039$, $\beta = 2.2357e - 09$




Figure 8: La barrera volumétrica real, con $r = 2.0390e - 01$ y $\beta = 2.2357e - 09$. Izquierda: cerca de $J = 1$, $h(J)$ (azul) y el término $-r \log J$ solo (rojo) son visualmente indistinguibles, y ambos divergen cuando $J \rightarrow 0^+$: la barrera de colapso funciona exactamente como se diseñó. Derecha: en escala logarítmica y para J mucho mayor, el término $-r \log J$ solo (rojo) decrece sin límite, y $h(J)$ total (azul) lo sigue de cerca hasta que el término cuadrático solo (verde) finalmente lo alcanza y supera cerca de $J \approx 9550$ (línea vertical), el punto donde $h(J)$ por fin empieza a crecer.

10.6 Resumen de este capítulo

Idea clave 23. • *La condición de crecimiento (C6) necesita dos mecanismos independientes: coercividad en el estiramiento ($Q_{k,3} \geq \frac{1}{4}|\mathbf{F}|^6$, Capítulo 9) y coercividad en el volumen (este capítulo), porque J y $|\mathbf{F}|$ pueden divergir por separado.*

- $-r \log J$ es convexa en J y prohíbe el colapso ($J \rightarrow 0^+ \Rightarrow -r \log J \rightarrow +\infty$), pero, verificado numéricamente, **decrece sin límite** cuando $J \rightarrow \infty$: por sí sola no basta para (C6).
- $\frac{\beta}{2}(J-1)^2$ es convexa, simétrica alrededor de $J = 1$, y crece sin límite en ambas direcciones: es lo que garantiza $h(J) \rightarrow +\infty$ también cuando $J \rightarrow \infty$, para cualquier $\beta > 0$, sin importar cuán pequeño.

- Con los valores reales entrenados, el cuadrático no le gana al logaritmo hasta $J^* \approx 9550$, verificado numéricamente ($h'(J^*) \approx 0$): matemáticamente necesario, prácticamente inactivo en el rango real de este RVE.

Antes de seguir: con $r = 2.0390e-01$ y $\beta = 2.2357e-09$, evalúa $h(J)$ tú mismo en $J = 0.5, 2, 100$ y confirma los signos; luego repite la búsqueda de J^* resolviendo $h'(J) = 0$ a mano (o con una calculadora) y confirma el valor de la Ecuación (43). Cuando estés listo, seguimos con el Capítulo 10: la red Φ_θ misma, qué es un ICNN, y por qué es convexa por construcción, no por entrenamiento.

11 La red Φ_θ : qué es un ICNN, y por qué es convexa por construcción

11.1 ¿Qué problema nos falta resolver?

Tenemos, de los Capítulos 6–9, quince números (I_1 , doce Q 's, J , J^2) calculados a partir de $\mathbf{F}$, y sabemos que cada uno, por separado, es convexo en su propio bloque ($\mathbf{F}$, $\text{cof } \mathbf{F}$, o J). Pero la energía final no es una lista de quince números: es un solo escalar, Φ_θ de esos quince números. La pregunta de este capítulo es muy concreta: ¿qué tiene que cumplir la función Φ_θ (una red neuronal) para que, al combinar las quince entradas convexas, el resultado **siga siendo convexo**? Esta no es una pregunta retórica: hay muchas formas razonables de combinar quince números en uno (sumarlos, promediarlos, multiplicarlos, meterlos a una red neuronal cualquiera) que **rompen** la convexidad. Vamos a construir, paso a paso, una que no la rompe.

11.2 Repaso relámpago: qué es una red neuronal

Una red neuronal (en su forma más simple, un *perceptrón multicapa*) transforma un vector de entrada en un escalar de salida aplicando, capa por capa, dos operaciones: una **combinación lineal** de pesos ($\mathbf{W}\mathbf{x} + \mathbf{b}$) y una **activación** no lineal aplicada a cada componente ($\sigma(\cdot)$). Con L capas ocultas,

$$\mathbf{h}_1 = \sigma(\mathbf{W}_1\mathbf{x} + \mathbf{b}_1), \quad \mathbf{h}_{\ell+1} = \sigma(\mathbf{W}_{\ell+1}\mathbf{h}_\ell + \mathbf{b}_{\ell+1}), \quad \Phi_\theta(\mathbf{x}) = \mathbf{w}_{\text{out}} \cdot \mathbf{h}_L + b_{\text{out}},$$

donde θ denota, colectivamente, todos los pesos $\mathbf{W}_\ell$ y sesgos $\mathbf{b}_\ell$ (los números que el entrenamiento ajusta). En una red neuronal *normal*, estos pesos pueden ser cualquier número real, positivo o negativo, y no hay ninguna garantía de que Φ_θ sea convexa en $\mathbf{x}$: de hecho, para una red normal, casi nunca lo es. Un ICNN (*input-convex neural network*, Amos et al. [2]) es exactamente una red de esta forma, pero con dos restricciones adicionales, diseñadas para **garantizar** la convexidad sin importar qué valores tomen los pesos durante el entrenamiento.

11.3 El truco de un solo escalón: pesos no-negativos + activación convexa no-decreciente

Empecemos con el caso más simple posible: una sola entrada x , una sola neurona oculta, sin capas intermedias: $\Phi_\theta(x) = \sigma(wx + b)$ con $w \geq 0$. Si σ es convexa, ¿es Φ_θ convexa en x ? La respuesta es sí, y la razón es la **regla de composición escalar**:

Idea clave 24 (Regla de composición escalar). Si $f: \mathbb{R} \rightarrow \mathbb{R}$ es convexa, y $g: \mathbb{R} \rightarrow \mathbb{R}$ es convexa y **no-decreciente**, entonces $g \circ f$ (es decir, $x \mapsto g(f(x))$) es convexa.

Aplicado a nuestro caso: $f(x) = wx + b$ es afín (lineal más constante), que siempre es convexa (de hecho, convexa y cóncava a la vez, por eso no importa el signo de w para que f misma sea convexa). Si además σ es convexa y no-decreciente, la composición $\sigma(wx + b)$ es convexa, para *cualquier* w , incluso $w < 0$, en este caso particular (porque f afín ya es convexa sin importar el signo). El problema real aparece cuando f misma **no** es afín sino ya convexa-no-lineal (como nuestras quince features): ahí sí importa el signo de w , como veremos en la Sección 11.5.

11.4 Por qué “no-decreciente” no es un detalle menor

La condición “ g no-decreciente” en la regla de composición no es un tecnicismo que se pueda ignorar: sin ella, la regla **falla por completo**, incluso si g sigue siendo convexa.

Ejemplo 17 (Convexa y decreciente: la composición se rompe). *Tomemos $f(x) = x^2$ (convexa, la conocemos bien del Capítulo 4). Comparemos dos opciones para g :*

- $g_1(y) = e^y$: *convexa* ($g_1''(y) = e^y > 0$) **y no-decreciente** ($g_1'(y) = e^y > 0$). La composición es $g_1(f(x)) = e^{x^2}$.
- $g_2(y) = e^{-y}$: *también convexa* ($g_2''(y) = e^{-y} > 0$), pero **decreciente** ($g_2'(y) = -e^{-y} < 0$). La composición es $g_2(f(x)) = e^{-x^2}$.

La Figura 9 muestra las tres funciones. e^{x^2} sí es convexa (una curva en forma de U, cada vez más pronunciada). Pero e^{-x^2} es una campana: sube desde los extremos hasta un máximo en $x = 0$, exactamente la forma **opuesta** a lo que necesitamos. g_2 es convexa, f es convexa, y aun así $g_2 \circ f$ no es convexa en absoluto.

Por qué la regla de composición necesita “convexa y no-decreciente”, no solo “convexa”




Figure 9: $f(x) = x^2$ (izquierda) es convexa. Compuesta con $g_1(y) = e^y$ (centro, convexa y no-decreciente), el resultado sigue siendo convexo. Compuesta con $g_2(y) = e^{-y}$ (derecha, convexa pero **decreciente**), el resultado es una campana: no convexa en absoluto. La única diferencia entre los dos casos es el signo de la derivada de g .

Idea clave 25. *La monotonía de g no es un requisito estético ni una simplificación de la demostración: es la diferencia exacta entre “la composición hereda la convexidad” y “la composición puede ser lo opuesto de convexa”. Por eso un ICNN exige, explícitamente, que la función que combina las entradas sea no-decreciente en cada una de ellas, no solo convexa.*

11.5 La regla de composición vectorial: quince entradas a la vez

Nuestra situación real no es una sola entrada convexa: son quince ($I_1, Q_{k,2}^F, Q_{k,3}^F, Q_{k,2}^H, Q_{k,3}^H, J, J^2$). La generalización de la regla de composición a varias entradas a la vez (Boyd & Vandenberghe, *Convex Optimization*, §3.2.4) dice:

Idea clave 26 (Regla de composición vectorial). *Si cada $f_i : \mathbb{R}^n \rightarrow \mathbb{R}$ ($i = 1, \dots, m$) es convexa, y $h : \mathbb{R}^m \rightarrow \mathbb{R}$ es convexa y no-decreciente en cada uno de sus m argumentos por separado, entonces $x \mapsto h(f_1(x), \dots, f_m(x))$ es convexa.*

Con $m = 15$ (nuestras features) y $h = \Phi_\theta$, esto es exactamente lo que necesitamos: si Φ_θ es convexa y no-decreciente **en cada una de las quince entradas**, entonces $\Phi_\theta(z_{\text{pc}}(\mathbf{F}, \text{cof } \mathbf{F}, J))$

es convexa en el argumento conjunto $(\mathbf{F}, \text{cof } \mathbf{F}, J)$, sin importar qué tan complicada sea cada z_m individualmente, siempre que cada una ya sea convexa en su propio bloque (que es exactamente lo que los Capítulos 6–9 demostraron, feature por feature).

¿Cómo se garantiza que Φ_θ (una red con varias capas) sea convexa y no-decreciente en las quince entradas **a la vez**, y no solo función por función? Con la misma receta de la Sección 11.4, aplicada por inducción, capa por capa: si cada preactivación de la primera capa es una combinación **afín con pesos no-negativos** de las entradas, y la activación es convexa y no-decreciente, cada neurona de la primera capa es convexa y no-decreciente en las quince entradas (por la misma regla escalar de antes, aplicada entrada por entrada). Si además la *segunda* capa combina esas neuronas (ya convexas y no-decrecientes) con pesos **también no-negativos**, y aplica otra activación convexa no-decreciente, la regla vectorial dice que la segunda capa *también* es convexa y no-decreciente en las entradas originales. Repitiendo esto capa por capa, toda la red, hasta la salida final, hereda ambas propiedades. Esta es la idea completa de un ICNN: no hay ningún paso mágico, es la misma regla de composición aplicada una y otra vez.

11.6 Por qué Softplus

La activación usada en este proyecto es *Softplus*, $\sigma(x) = \log(1 + e^x)$. Verifiquémosla contra los dos requisitos:

$$\sigma'(x) = \frac{e^x}{1 + e^x} = \frac{1}{1 + e^{-x}} \in (0, 1), \quad \sigma''(x) = \sigma'(x)(1 - \sigma'(x)) > 0 \quad \text{siempre.}$$

$\sigma'(x) > 0$ para todo x significa **estrictamente creciente** (en particular, no-decreciente); $\sigma''(x) > 0$ para todo x significa **estrictamente convexa**. Softplus cumple ambos requisitos en todo $\mathbb{R}$, sin excepciones ni casos especiales, que es exactamente lo que la regla de composición necesita.

11.7 Por qué *todos* los pesos, no solo los de la primera capa

El ICNN original de Amos et al. [2] solo exige pesos no-negativos en las conexiones **entre capas ocultas** (hidden-to-hidden), dejando libres los pesos que van directamente de la entrada a cada capa (input-to-hidden, en cada capa, no solo la primera). Esa versión ya garantiza convexidad, pero **no** garantiza que la red sea no-decreciente en la entrada: una capa intermedia podría usar un peso negativo directo desde la entrada, y aunque el resultado seguiría siendo convexo, podría *disminuir* al aumentar alguna entrada.

Nuestra construcción necesita algo más fuerte que solo convexidad: necesita que Φ_θ sea no-decreciente en cada una de las quince entradas, porque eso es lo que la regla de composición vectorial exige para que $\Phi_\theta(\mathbf{z}_{\text{pc}})$ herede la convexidad de las features. Por eso este proyecto reparametriza **todas** las matrices de pesos, incluyendo las de entrada-a-capas-ocultas en cada capa (no solo la primera), como

$$\mathbf{W} = \text{softplus}(\mathbf{W}_{\text{crudo}}) + \varepsilon_0, \quad \varepsilon_0 > 0 \text{ pequeño,}$$

donde $\mathbf{W}_{\text{crudo}}$ es el parámetro real que el entrenamiento ajusta (libre, cualquier número real), y $\mathbf{W}$ es el peso **efectivo** que realmente se usa en el forward pass. Como $\text{softplus}(\cdot) \geq 0$ siempre, $\mathbf{W} \geq \varepsilon_0 > 0$ sin importar qué valor tenga $\mathbf{W}_{\text{crudo}}$: el entrenamiento nunca puede violar la restricción, porque la restricción está construida en la propia parametrización, no verificada después. Esta es la diferencia entre esta red (*monótona*, en la terminología del paper) y un ICNN clásico.

Ejemplo 18 (Verificado con la red real entrenada). *La red entrenada de este proyecto tiene anchos (64, 64, 32) (tres capas ocultas). Cargando el checkpoint real y calculando $\text{softplus}(\mathbf{W}_{\text{crudo}})$ para cada matriz de pesos (entrada-a-oculta en las tres capas, y oculta-a-oculta entre ellas), el peso efectivo más pequeño de toda la red es 1.8×10^{-7} , y el más grande es 54.5: todos, sin excepción, estrictamente positivos. No es una coincidencia del entrenamiento: es una consecuencia matemática de que todo peso efectivo se calcula como $\text{softplus}(\text{algo})$, que nunca puede ser negativo.*

11.8 Uniendo todo: casi tenemos la Proposición de polyconvexidad

Repasemos qué hemos acumulado, capítulo a capítulo:

- Capítulos 6–9: cada una de las quince features es convexa en su propio bloque $(\mathbf{F}, \text{cof } \mathbf{F}, J)$, o $J)$.
- Este capítulo: Φ_θ es convexa y no-decreciente en cada una de las quince entradas, por construcción (pesos efectivos ≥ 0 en **todas** las capas, activación Softplus convexa y creciente).

Por la regla de composición vectorial de la Sección 11.5, estas dos piezas juntas ya dicen que $\Phi_\theta(\mathbf{z}_{\text{pc}}(\mathbf{F}, \text{cof } \mathbf{F}, J))$ es convexa en el argumento conjunto $(\mathbf{F}, \text{cof } \mathbf{F}, J)$. Sumar el término constante $-\Phi_\theta(\mathbf{z}_{\text{pc}}(\mathbf{I}))$ no cambia la convexidad (sumar una constante nunca lo hace), y los términos volumétricos $-r \log J$, $\frac{\beta}{2}(J-1)^2$ son convexos en J por cálculo directo. Una suma de funciones convexas en $(\mathbf{F}, \text{cof } \mathbf{F}, J)$ es convexa en $(\mathbf{F}, \text{cof } \mathbf{F}, J)$: eso es, palabra por palabra, la Proposición de polyconvexidad del paper. No queda ningún paso oculto ni ningún salto de fe: cada pieza se demostró por separado, en su propio capítulo, y aquí es donde todas se juntan.

11.9 Resumen de este capítulo

Idea clave 27. • *Una red normal no tiene ninguna garantía de ser convexa. Un ICNN la tiene, por dos restricciones explícitas: pesos no-negativos y activación convexa no-decreciente.*

- *La regla de composición (escalar o vectorial) exige convexidad y monotonía de la función externa; sin la monotonía, la regla falla por completo (Ejemplo 17), no parcialmente.*
- *Softplus, $\log(1+e^x)$, es estrictamente convexa y estrictamente creciente en todo $\mathbb{R}$, sin casos especiales.*
- *Este proyecto usa pesos efectivos $\text{softplus}(\mathbf{W}_{\text{crudo}}) + \varepsilon_0 > 0$ en **todas** las capas (no solo entre capas ocultas, como el ICNN clásico), porque necesita monotonía en la entrada completa, no solo convexidad; verificado con la red real entrenada (Ejemplo 18).*
- *Con las quince features convexas en su bloque (Capítulos anteriores) y Φ_θ convexa y no-decreciente en ellas (este capítulo), la regla de composición vectorial da, casi directamente, la polyconvexidad de la energía completa.*

Antes de seguir: con lápiz y papel, verifica que $\sigma(x) = x^2$ (convexa, pero **no** no-decreciente en todo $\mathbb{R}$, solo para $x \geq 0$) rompe la regla de composición igual que $g_2(y) = e^{-y}$ del Ejemplo 17: calcula $\sigma(f(x))$ para $f(x) = -x$ (afín, convexa) y confirma que el resultado no es convexo. Cuando estés listo, seguimos con el Capítulo 11: por qué la energía vale exactamente cero, y el esfuerzo también, en el estado de referencia (las Proposiciones 1 y 2 del paper, explicadas desde cero).

12 La tensión cero en la referencia: por qué $\sigma(0) = 0$ exactamente

12.1 ¿Qué falta demostrar, exactamente?

En el estado de referencia, $\mathbf{F} = \mathbf{I}$ (sin deformar), dos cosas deberían ser cero: la energía, $W_{\text{pc}}(\mathbf{I}) = 0$, y el esfuerzo, $\sigma(0) = 0$. La primera es trivial, y ya la vimos de pasada: como $\mathbf{z}_{\text{pc}}(\mathbf{F}) = \mathbf{z}_{\text{pc}}(\mathbf{I})$ cuando $\mathbf{F} = \mathbf{I}$, los dos primeros términos de la energía (1) se cancelan exactamente por ser idénticos ($\Phi_\theta(\mathbf{z}) - \Phi_\theta(\mathbf{z}) = 0$, para *cualquier* red Φ_θ , entrenada como sea), y $J = 1$ hace que $\log J = 0$ y $(J-1)^2 = 0$. No hace falta ninguna propiedad especial de Φ_θ para esto: es álgebra pura.

El esfuerzo es harina de otro costal. $\sigma = \partial W_{\text{pc}} / \partial \varepsilon$ es una **derivada**, y que una función valga cero en un punto no dice nada sobre si su derivada también vale cero ahí (piensa en $f(x) = x^3$: $f(0) = 0$, pero $f'(x) = 3x^2$ tampoco es idénticamente cero cerca de 0... aunque en este caso sí se

anula justo en $x = 0$; el punto es que no es automático). Necesitamos que el gradiente de Φ_θ en la referencia quede **exactamente cancelado** por el gradiente del término de barrera $-r \log J$. Ese es el trabajo real de este capítulo.

12.2 Un hecho que ya conocemos: el Lema del Capítulo 5

Vamos a reusar, sin repetir la demostración, el hecho algebraico del Capítulo 5: para cualquier vector unitario $\mathbf{d}$,

$$\text{cof}(\mathbf{d} \otimes \mathbf{d}) = \mathbf{I} - \mathbf{d} \otimes \mathbf{d}. \quad (44)$$

Este único hecho, combinado con la condición de balance $\sum_i w_{ki} \mathbf{d}_{ki} \otimes \mathbf{d}_{ki} = \mathbf{I}$ del Capítulo 7, es todo lo que necesitamos para el resto de este capítulo.

12.3 Cada una de las quince features tiene un gradiente isotrópico en la referencia

Idea clave 28 (Lo que vamos a demostrar). En $\mathbf{C} = \mathbf{I}$, el gradiente de *cada una* de las quince features respecto a $\mathbf{C}$ es un múltiplo positivo de la identidad, $dz_m/dC|_{\mathbf{C}=\mathbf{I}} = c_m \mathbf{I}$, con un coeficiente c_m distinto para cada tipo de feature, pero **siempre** en la dirección isotrópica $\mathbf{I}$, sin importar qué tan anisotrópica sea la feature lejos de la referencia.

Tomando la traza de la condición de balance y usando $|\mathbf{d}_{ki}| = 1$, $\sum_i w_{ki} = 2$ para todo sistema k (verifícalo con los pesos reales del Capítulo 7: $0.2959 + 0.8520 + 0.8520 = 2.0000$). Con esto, cuatro casos:

- I_1 . Trivialmente, $dI_1/dC = \mathbf{I}$ para cualquier $\mathbf{C}$, en particular en $\mathbf{C} = \mathbf{I}$. Coeficiente $c = 1$.
- $Q_{k,p}^F$. Por la regla del producto,

$$\frac{dQ_{k,p}^F}{dC} = \sum_i p w_{ki} (\mathbf{d}_{ki} \cdot \mathbf{C} \mathbf{d}_{ki})^{p-1} \mathbf{d}_{ki} \otimes \mathbf{d}_{ki}.$$

En $\mathbf{C} = \mathbf{I}$, cada factor $\mathbf{d}_{ki} \cdot \mathbf{I} \mathbf{d}_{ki} = |\mathbf{d}_{ki}|^2 = 1$, así que la potencia $(p-1)$ desaparece (elevar 1 a cualquier potencia sigue siendo 1) y solo sobrevive la suma de balance:

$$\left. \frac{dQ_{k,p}^F}{dC} \right|_{\mathbf{C}=\mathbf{I}} = p \sum_i w_{ki} \mathbf{d}_{ki} \otimes \mathbf{d}_{ki} = p \mathbf{I}.$$

Coeficiente $c = p$ (es decir, 2 para $Q_{k,2}^F$, 3 para $Q_{k,3}^F$).

- $Q_{k,p}^H$. Necesita un paso extra antes del mismo truco: $\mathbf{d} \cdot \text{cof}(\mathbf{C}) \mathbf{d}$ es *lineal* en $\mathbf{C}$ (no solo en la referencia, sino para **cualquier** $\mathbf{C}$), porque $\mathbf{d} \cdot \text{cof}(\mathbf{C}) \mathbf{d} = \text{cof}(\mathbf{C}) : (\mathbf{d} \otimes \mathbf{d}) = \mathbf{C} : \text{cof}(\mathbf{d} \otimes \mathbf{d})$ (el cofactor es autoadjunto respecto al producto de Frobenius en 2×2), con gradiente **constante** $\text{cof}(\mathbf{d} \otimes \mathbf{d}) = \mathbf{I} - \mathbf{d} \otimes \mathbf{d}$, exactamente (44). Diferenciando,

$$\frac{dQ_{k,p}^H}{dC} = \sum_i p w_{ki} (\mathbf{d}_{ki} \cdot \text{cof}(\mathbf{C}) \mathbf{d}_{ki})^{p-1} (\mathbf{I} - \mathbf{d}_{ki} \otimes \mathbf{d}_{ki}).$$

En $\mathbf{C} = \mathbf{I}$, $\text{cof}(\mathbf{I}) = \mathbf{I}$, así que $\mathbf{d}_{ki} \cdot \text{cof}(\mathbf{I}) \mathbf{d}_{ki} = 1$ y la potencia $(p-1)$ vuelve a desaparecer, dejando

$$\left. \frac{dQ_{k,p}^H}{dC} \right|_{\mathbf{C}=\mathbf{I}} = p \left[\left(\sum_i w_{ki} \right) \mathbf{I} - \sum_i w_{ki} \mathbf{d}_{ki} \otimes \mathbf{d}_{ki} \right] = p(2\mathbf{I} - \mathbf{I}) = p \mathbf{I},$$

usando $\sum_i w_{ki} = 2$ y el balance una segunda vez. Mismo coeficiente $c = p$ que el bloque F .

- J, J^2 . La identidad estándar del determinante da

$$\frac{dJ}{dC} = \frac{1}{2J} \text{cof}(\mathbf{C}), \quad \left. \frac{dJ}{dC} \right|_{C=\mathbf{I}} = \frac{1}{2} \mathbf{I}; \quad \frac{dJ^2}{dC} = 2J \frac{dJ}{dC} = \text{cof}(\mathbf{C}), \quad \left. \frac{dJ^2}{dC} \right|_{C=\mathbf{I}} = \mathbf{I}.$$

Coefficientes $c = 1/2$ y $c = 1$ respectivamente.

Table 1: Coeficiente c_m de cada feature (Capítulo 12): $dz_m/dC|_{C=\mathbf{I}} = c_m \mathbf{I}$.

Feature	I_1	$Q_{k,2}^F, Q_{k,2}^H$	$Q_{k,3}^F, Q_{k,3}^H$	J	J^2
c_m	1	2	3	1/2	1

12.4 Verificado con la red real entrenada

Ejemplo 19 (Los quince gradientes, calculados con el modelo real). *Evaluando las quince features y sus gradientes en el estado de referencia con el checkpoint real (autodiferenciación, no una fórmula reescrita a mano), cada gradiente resulta de la forma $(X, X, \sim 0)$ en las coordenadas $(E_{11}, E_{22}, \gamma_{12})$: la componente de cortante es, en todos los casos, menor a 3×10^{-15} (ruido de máquina, no un valor real). Además, la proporción entre los valores X de features distintas reproduce **exactamente** la Tabla 1: si I_1 dio $X = 4.0$, cada $Q_{k,2}$ dio $X = 8.0$ (razón 2), cada $Q_{k,3}$ dio $X = 12.0$ (razón 3), J dio $X = 2.0$ (razón 1/2), y J^2 dio $X = 4.0$ (razón 1, igual que I_1). Esto no es aproximado: las quince proporciones coinciden con la tabla hasta el último dígito reportado.*

12.5 De quince gradientes a uno solo: la regla de la cadena

Por la regla de la cadena, el gradiente de Φ_θ (que depende de $\mathbf{C}$ solo a través de las quince features) es una combinación de los quince gradientes que acabamos de calcular:

$$\left. \frac{d\Phi_\theta}{dC} \right|_{C=\mathbf{I}} = \sum_m \left. \frac{\partial \Phi_\theta}{\partial z_m} \right|_{z(\mathbf{I})} \left. \frac{dz_m}{dC} \right|_{C=\mathbf{I}} = \left(\sum_m c_m \left. \frac{\partial \Phi_\theta}{\partial z_m} \right|_{z(\mathbf{I})} \right) \mathbf{I} =: \lambda \mathbf{I}.$$

Como cada $dz_m/dC|_{C=\mathbf{I}}$ es un múltiplo de $\mathbf{I}$ (lo que acabamos de demostrar), la suma **también** es un múltiplo de $\mathbf{I}$, sin importar los coeficientes $\partial \Phi_\theta / \partial z_m$ que dependan del entrenamiento: la dirección isotrópica no se pierde al combinar. Y como el Capítulo 11 demostró que Φ_θ es no-decreciente en cada entrada ($\partial \Phi_\theta / \partial z_m \geq 0$ siempre, por construcción del ICNN monótono) y cada $c_m > 0$ (Tabla 1), λ es una combinación no-negativa de términos no-negativos: $\lambda \geq 0$ **automáticamente**, para cualquier θ , sin excepción ni verificación posterior.

12.6 El término de barrera apunta en la misma dirección

Como $\log J = \frac{1}{2} \log \det \mathbf{C}$,

$$\frac{d(\log J)}{dC} = \frac{1}{2 \det \mathbf{C}} \text{cof}(\mathbf{C}), \quad \left. \frac{d(\log J)}{dC} \right|_{C=\mathbf{I}} = \frac{1}{2} \mathbf{I}.$$

También isotrópica, por la misma razón de siempre: en la referencia, $\text{cof}(\mathbf{I}) = \mathbf{I}$.

12.7 El escalar r : diseñado para cancelar exactamente

Convirtiendo de $\mathbf{C}$ a ε (con $\mathbf{C} = \mathbf{I} + 2\mathbf{E}$, que duplica el gradiente) y usando la coordenada de ingeniería $\varepsilon = (E_{11}, E_{22}, \gamma_{12})$, ambos gradientes de la Sección anterior se convierten en vectores de la forma $(*, *, 0)^T$ con las dos primeras entradas iguales: la entrada de cortante se anula porque es la

entrada fuera de la diagonal de una matriz isotrópica, y una matriz isotrópica no tiene componente fuera de la diagonal. El paper define

$$r := \frac{1}{2} \left(\frac{\partial \Phi_\theta}{\partial E_{11}} + \frac{\partial \Phi_\theta}{\partial E_{22}} \right) \Big|_{\varepsilon=0},$$

es decir, r es *exactamente* el número que hace que $r(1, 1, 0)^T$ coincida con el propio gradiente de Φ_θ en la referencia. Sumando los tres términos de la energía (1) en $\varepsilon = 0$:

$$\sigma(0) = \underbrace{(\dots)^T}_{\text{de } \Phi_\theta} - \underbrace{r(1, 1, 0)^T}_{\text{de } -r \log J} + \underbrace{\beta(J-1)\nabla J|_{J=1}}_{=0, \text{ ya que } J=1} = 0,$$

porque, por construcción de r , el primer término y el segundo son idénticos.

Idea clave 29. *Todo el argumento depende de un solo hecho, repetido quince veces: cada feature tiene un gradiente isotrópico en la referencia, gracias a la condición de balance. Sin el balance, el gradiente de Φ_θ sería, en general, un vector **anisotrópico** de tres componentes independientes, y ningún escalar único $r(1, 1, 0)^T$ podría cancelarlo exactamente: se necesitarían tres números libres, no uno. La condición de balance es precisamente lo que reduce el problema de “cancelar un vector arbitrario” a “cancelar un múltiplo de una dirección fija”, que un solo escalar sí puede resolver.*

12.8 Verificado con la red real: el resultado final

Ejemplo 20 ($\sigma(0)$, calculado end-to-end con el modelo entrenado). *Para el modelo certificado de este proyecto, $\lambda = r = 2.0390e - 01$ (el mismo número calculado de dos formas distintas: como la combinación de los quince $\partial \Phi_\theta / \partial z_m$, y como el promedio de las dos derivadas normales de Φ_θ en la referencia). Evaluando el esfuerzo completo del modelo entrenado, pasando por el pipeline real de autodiferenciación (no una fórmula manual), en $\varepsilon = 0$:*

$$\sigma(0) = (0, 0, 0)^T \text{ exactamente,}$$

sin redondeo, sin aproximación: los tres componentes son literalmente 0.0 en aritmética de doble precisión. No es una casualidad numérica: es la consecuencia directa de que r se construye, en el propio código del modelo, para ser exactamente ese número de cancelación, no un valor aproximado ajustado por el entrenamiento.

12.9 Resumen de este capítulo

Idea clave 30. • *La energía en la referencia es cero por álgebra pura ($\Phi_\theta(\mathbf{z}) - \Phi_\theta(\mathbf{z}) = 0$); el esfuerzo en la referencia **no** es automático, y requiere que quince gradientes distintos apunten en la misma dirección.*

- *Cada una de las quince features tiene, en la referencia, un gradiente que es un múltiplo positivo de $\mathbf{I}$: verificado algebraicamente (cuatro casos) y numéricamente (quince de quince, con las proporciones exactas de la Tabla 1).*
- *Por la regla de la cadena, el gradiente de Φ_θ también es isotrópico, con un coeficiente $\lambda \geq 0$ garantizado por construcción (ICNN monótono + coeficientes $c_m > 0$), no por entrenamiento.*
- *Un solo escalar r basta para cancelar el gradiente completo, **porque** ese gradiente es isotrópico; sin la condición de balance, harían falta tres números libres, no uno.*
- *Verificado end-to-end con el modelo real: $\sigma(0) = 0$ exactamente, no aproximadamente.*

Antes de seguir: con la fórmula del Ejemplo 19 en mente, predice qué proporción esperarías para una hipotética feature nueva con coeficiente $c = 4$; luego confirma que ninguna de las quince features actuales tiene ese coeficiente (revisa la Tabla 1). Cuando estés listo, seguimos con el Capítulo 12: el segundo núcleo convexo, ICKAN, y por qué las mismas demostraciones de este apéndice se trasladan a él sin cambiar una sola línea.

13 El segundo núcleo convexo: ICKAN

13.1 ¿Por qué un segundo núcleo, si ya funciona el primero?

Todo lo demostrado en los Capítulos 11 y 12 depende de **una sola propiedad** de Φ_θ : que sea convexa y no-decreciente en cada una de las quince entradas. Nunca usamos nada específico de *cómo* un ICNN logra eso (pesos softplus, activación Softplus). Esto sugiere una pregunta natural: si construimos una red **totalmente distinta**, que logre la misma propiedad por un mecanismo diferente, ¿se trasladan las demostraciones sin cambios? Este capítulo responde que sí, con una red basada en *splines* en vez de pesos: ICKAN (*input-convex Kolmogorov–Arnold network*, Thakolkaran et al. [1]).

13.2 Qué es una red Kolmogorov–Arnold (KAN)

Una red neuronal normal (Capítulo 11) tiene pesos **números** en cada conexión, y aplica una activación **fija** (igual para toda la red) después de sumar. Una KAN invierte la idea: cada conexión (“borde”) tiene su propia **función aprendida** $\phi_{ij}(x)$ (una curva spline, no un solo número), y la capa simplemente **suma** las salidas de esas funciones:

$$h_j = \sum_i \phi_{ij}(x_i).$$

No hay “pesos” en el sentido clásico: toda la flexibilidad de la red vive en la forma de cada curva ϕ_{ij} , representada como una curva B-spline con un conjunto de **puntos de control** $c_0, c_1, \dots, c_n$ que el entrenamiento ajusta.

13.3 Cómo se fuerza una curva a ser convexa y no-decreciente: dos sumas acumuladas

Igual que un ICNN reparametriza cada peso como softplus(crudo) para garantizar que sea ≥ 0 , la implementación de referencia de ICKAN reparametriza los puntos de control de **cada** curva con dos sumas acumuladas de cantidades no-negativas, en vez de dejarlos libres:

$$s_i = \text{ReLU}(a_i) \geq 0, \quad d_i = \sum_{l \leq i} s_l \quad (d_0 = 0), \quad c_i = c_0 + \sum_{l \leq i} d_l,$$

donde $a_1, a_2, \dots$ son los parámetros libres que el entrenamiento ajusta (cualquier número real), y c_0 también es libre. Fijémonos en qué implica esto para los propios puntos de control c_i :

- Las **primeras diferencias**, $c_{i+1} - c_i = d_{i+1} \geq 0$ (porque cada d_i es una suma de términos ReLU, automáticamente ≥ 0): los puntos de control nunca decrecen. Una propiedad clásica de las curvas B-spline (la “propiedad de disminución de variación”) dice que si los puntos de control no decrecen, la curva tampoco decrece: esto da **no-decreciente**.
- Las **segundas diferencias**, $(c_{i+2} - c_{i+1}) - (c_{i+1} - c_i) = d_{i+2} - d_{i+1} = s_{i+2} \geq 0$: los puntos de control forman un polígono **convexo** (cada incremento es mayor o igual que el anterior). Esto da **convexidad** de la curva, por la misma razón geométrica que un polígono convexo describe una curva convexa.

Dos sumas acumuladas de cantidades no-negativas, y las dos propiedades que necesitábamos (convexa, no-decreciente) quedan garantizadas para **cualquier** valor de los parámetros libres a_i , exactamente el mismo espíritu que softplus(crudo) ≥ 0 del Capítulo 11, aplicado a puntos de control en vez de a pesos.

Ejemplo 21 (Un borde real, verificado con la red ICKAN entrenada). *Tomando un borde real de la red ICKAN entrenada de este proyecto (la conexión de la primera entrada a la primera neurona oculta), sus nueve puntos de control reparametrizados son*

$$(0.0262, 0.0262, 0.0728, 0.1834, 0.3115, 0.4396, 0.5677, 0.6958, 0.8239).$$

Las primeras diferencias son todas ≥ 0 (mínima: 0, exactamente); las segundas diferencias también son todas ≥ 0 hasta ruido de máquina (-5×10^{-12} , indistinguible de cero). Evaluando la curva completa en 400 puntos de su dominio, la pendiente local $\phi(x_{i+1}) - \phi(x_i)$ nunca es negativa (Figura 10): esta curva específica es, verificablemente, no-decreciente y convexa en todo su rango, no solo en los puntos de control.

Un ICKAN construye convexidad con puntos de control, no con pesos




Figure 10: Izquierda: un borde real de la red ICKAN entrenada (curva azul), con sus puntos de control reparametrizados superpuestos (rojo); nótese que los puntos de control forman, ellos mismos, un polígono convexo. Derecha: la pendiente local de la curva evaluada, siempre ≥ 0 : la curva nunca decrece, en ningún punto de su dominio.

13.4 De un borde a toda la red: la misma regla de composición

Con cada borde ϕ_{ij} individualmente convexo y no-decreciente en su única entrada x_i , ¿qué hace falta para que la **suma** $h_j = \sum_i \phi_{ij}(x_i)$ (una capa completa) también sea convexa y no-decreciente en el vector completo $\mathbf{x}$? Esto es, de hecho, más simple que la regla de composición del Capítulo 11: una suma de funciones convexas es convexa (sin necesitar ninguna condición extra, a diferencia de la composición), y una suma de funciones no-decrecientes es no-decreciente. Apilando capas (con las transformaciones afín **fijas** en la identidad entre capas, y sin función base no convexa adicional, tal como lo configura la implementación de referencia), la misma propiedad se preserva capa tras capa, exactamente como en el Capítulo 11, pero por suma en vez de por composición con una activación externa.

Idea clave 31. *Un ICNN y un ICKAN llegan al mismo destino (convexo y no-decreciente en cada entrada) por caminos completamente distintos: uno reparametriza **pesos** con una suma no-negativa (softplus) y compone a través de una activación fija; el otro reparametriza **puntos de control** con dos sumas acumuladas no-negativas y combina por suma directa de curvas aprendidas. Ninguna demostración de este apéndice (Capítulos 11–12) usa el mecanismo específico de un ICNN: solo usan que Φ_θ es convexa y no-decreciente en las quince entradas. Por eso se trasladan a ICKAN sin cambiar una sola línea de argumento, solo cambiando qué red juega el papel de Φ_θ .*

13.5 Resumen de este capítulo

Idea clave 32. • *Una KAN reemplaza pesos numéricos por curvas aprendidas (splines) en cada conexión; la capa suma las salidas de esas curvas en vez de sumar productos peso-por-entrada.*

- *Reparametrizar los puntos de control de cada curva con **dos** sumas acumuladas de cantidades $\text{ReLU}(\cdot) \geq 0$ fuerza, simultáneamente, primeras diferencias ≥ 0 (no-decreciente) y segundas diferencias ≥ 0 (convexa), para cualquier valor de los parámetros libres.*
- *Verificado con un borde real de la red entrenada: puntos de control no-decrecientes y convexos, y la curva evaluada en 400 puntos confirma pendiente local siempre ≥ 0 .*
- *Una suma de funciones convexas y no-decrecientes es convexa y no-decreciente (más simple que la regla de composición del Capítulo 11), así que la propiedad se preserva capa tras capa.*
- *Ninguna demostración de los Capítulos 11–12 depende del mecanismo específico del ICNN: todas se trasladan a ICKAN verbatim, porque solo usan “convexa y no-decreciente en cada entrada”, una propiedad que ambas redes tienen, por caminos distintos.*

Antes de seguir: con los puntos de control del Ejemplo 21, calcula tú mismo las primeras y segundas diferencias (resta consecutiva) y confirma los valores reportados. Cuando estés listo, seguimos con el Capítulo 13: los resultados numéricos del paper, explicados uno por uno.

14 Cook con un FE^2 de verdad: por qué el ROM se atascaba, y cómo se resolvió

Este capítulo empieza la promesa del mapa de capítulos: los resultados numéricos del paper, explicados uno por uno. En vez de seguir el orden exacto del paper, empezamos por el más reciente y, la verdad, el más confuso de resolver: por qué dos maneras de aproximar la misma respuesta del RVE, entrenadas con los mismos datos, se comportan de forma completamente distinta dentro de un problema estructural real, cuando en la comparación directa (Sección 6.3 del paper, la “trayectoria de prueba” held-out) son casi indistinguibles.

14.1 Tres formas de responder la misma pregunta

Todo este proyecto responde, de tres maneras distintas, la misma pregunta: dada una deformación macroscópica $\boldsymbol{\varepsilon}$, ¿cuál es el esfuerzo homogeneizado $\boldsymbol{S}(\boldsymbol{\varepsilon})$ que produce el RVE?

- **FOM** (*full-order model*): resolver de verdad la malla completa del RVE, 990 elementos, imponiendo $\boldsymbol{\varepsilon}$ como condición de frontera y resolviendo el equilibrio con Newton–Raphson. Es la respuesta exacta (hasta el error de discretización de la malla), y también la más cara: una sola consulta, en la máquina de este proyecto, cuesta entre 0.4 y 1.2 segundos.
- **PANN** (los cuatro niveles de los Capítulos 11 en adelante): una red neuronal entrenada directamente sobre $\boldsymbol{\varepsilon} \mapsto \boldsymbol{S}$, usando miles de soluciones del FOM como datos de entrenamiento. Una vez entrenada, evaluarla es casi gratis: ni malla ni Newton, solo un forward pass.
- **PROM/HPROM** (D-HPROM–ANN y HPROM–ANN): un punto medio entre los dos anteriores. No se entrena $\boldsymbol{\varepsilon} \mapsto \boldsymbol{S}$ directamente; se entrena un decodificador que reconstruye el **estado interno reducido** del RVE (un vector $\boldsymbol{q}$ de solo 3 números, en vez de los miles de grados de libertad de la malla completa), y *después* se recalcula el esfuerzo evaluando la ley de Neo–Hookean real, la misma del FOM, en unos pocos puntos de Gauss seleccionados. D-HPROM–ANN usa la predicción del decodificador directamente; HPROM–ANN, además, la corrige con un Newton interno, más caro pero más fiel.

Idea clave 33. *La diferencia clave: PANN aprende la **respuesta completa** ($\boldsymbol{\varepsilon} \mapsto \boldsymbol{S}$ de un solo salto); PROM/HPROM aprende un **atajo dentro del mismo modelo físico**, y sigue evaluando la ley real del material en el camino. Por eso PROM/HPROM es más caro que PANN (todavía hace algo del trabajo del FOM en cada consulta) pero muchísimo más barato que el FOM completo.*

Para ubicarlo con números concretos: en el problema de Cook a resolución $n_x = 8$ (el que usa este capítulo), la malla macroscópica tiene 128 elementos y 384 puntos de Gauss. Si quisiéramos, de verdad, un FE² sin ningún atajo, en **cada uno** de esos 384 puntos, y en **cada** iteración de Newton del problema macroscópico, resolveríamos el RVE completo de 990 elementos desde cero. Con el costo medido arriba, y suponiendo (de forma conservadora, por analogía con lo que de verdad se observa abajo) tres iteraciones de Newton por paso de carga y 20 pasos, más seis evaluaciones extra por punto para la tangente por diferencias finitas (el FOM no tiene, en este proyecto, una tangente analítica lista para usar), eso son del orden de $384 \times 20 \times 3 \times 7 \approx 1.6 \times 10^5$ resoluciones del FOM completo: del orden de 31 horas de cómputo, solo para esta malla, ni la más fina que usa el paper. Ese es exactamente el costo que D-HPROM-ANN y HPROM-ANN evitan, sin dejar de resolver algo real en cada punto.

14.2 La pregunta que no tenía sentido

En la trayectoria de prueba held-out (Sección 6.3 del paper), D-HPROM-ANN y HPROM-ANN predicen el esfuerzo con un error relativo de apenas 0.17–0.20%: tan bueno como el de los núcleos certificados (ICNN, ICKAN), o incluso mejor. La intuición razonable, entonces, es que si son igual de precisos ahí, deberían comportarse igual de bien dentro de Cook. Y no fue lo que pasó: al conectarlos como material real del problema de Cook, con la precisión estándar de 32 bits (float32, la misma que usa el resto del proyecto), **ambos se atascaban en cada uno de los 20 pasos de carga**, sin converger nunca — de manera parecida a como, en el problema de Cook original (Sección 6.6 del paper), se atascan los modelos sin certificado (el regresivo puro y el hiperelástico libre): ni divergían, pero tampoco avanzaban.

Esto sí que no cuadraba. Los modelos sin certificado fallan por una razón que ya conocemos de capítulos anteriores: no hay garantía de convexidad rank-one, así que Newton puede, en principio, encontrarse con un estado localmente mal condicionado. Pero D-HPROM-ANN y HPROM-ANN no aprenden una energía sin certificar: en cada punto de Gauss reconstruido, evalúan la ley de Neo-Hookean **real**, la misma del FOM, que sí es polyconvexa por construcción clásica. No debería haber, en principio, ningún mecanismo parecido al de los Capítulos anteriores para que esto fallara.

14.3 Cuatro sospechosos, revisados uno por uno

Antes de aceptar cualquier explicación, se revisaron cuatro candidatas concretas, en este orden, cada una descartada con una prueba directa antes de pasar a la siguiente:

1. **¿Es la tangente?** D-HPROM-ANN y HPROM-ANN necesitan una tangente consistente (no aprendida, derivada a mano vía la regla de la cadena y, para HPROM-ANN, el teorema de la función implícita) para poder usarse dentro de un Newton estructural. Se probó también con una tangente por diferencias finitas, más lenta pero sin ninguna posibilidad de un error de deducción. El resultado: exactamente el mismo atascamiento con ambas tangentes. Descartado: no es un error en la tangente.
2. **¿Se pierde la elipticidad local?** En el estado final atascado, ¿la matriz tangente reducida $\mathbf{K}_r$ (la que usa el Newton interno para dar su paso) tiene algún valor propio negativo? No: todos son positivos, y la matriz está razonablemente bien condicionada. Descartado.
3. **¿Falla la convexidad rank-one en el estado final?** Se repite, por primera vez para estos dos modelos, el mismo experimento del Capítulo de convexidad: 20 direcciones aleatorias de rango uno, en cada uno de los 384 puntos de Gauss, evaluadas en el estado final (el atascado). Resultado: cero violaciones. Descartado, aparentemente.
4. **¿Y si el problema está en el camino, no en el destino?** Aquí es donde quedó, por un momento, una duda genuina: revisar solo el *mejor* estado de cada paso (el de menor residuo) podría estar escondiendo un problema que sólo aparece en algún punto intermedio

del propio Newton, nunca reportado porque no es el mejor. Se repitió el mismo experimento de convexidad, esta vez en **cada** iteración de una trayectoria completa de Newton, no solo en la mejor. Resultado: cero violaciones, otra vez, en las 15 iteraciones completas.

Idea clave 34. *Cuatro sospechosos razonables, cuatro veces descartados con una prueba directa, no con un argumento de plausibilidad. Esto es exactamente lo que hace falta antes de aceptar cualquier explicación: si alguna de las cuatro pruebas hubiera fallado, esa habría sido la respuesta. Como las cuatro se descartaron, hacía falta seguir buscando.*

14.4 El verdadero culpable: la resta que se come los dígitos

Ambos modelos reconstruyen el estado secundario del RVE (la parte del estado interno que el decodificador aprende, más allá de los 3 números primarios) con una fórmula de la forma

$$\mathbf{q}_s = \mathcal{N}(\mathbf{q}) - \mathcal{N}(\mathbf{0}) - \mathbf{J}_{\mathcal{N}}(\mathbf{0})\mathbf{q},$$

es decir: la salida cruda del decodificador $\mathcal{N}$, **menos** su propio valor en $\mathbf{q} = \mathbf{0}$, **menos** su propia aproximación lineal (su jacobiano en $\mathbf{q} = \mathbf{0}$, multiplicado por $\mathbf{q}$). La razón de diseño es razonable: la parte *lineal* de la reconstrucción ya la carga otro término del modelo (la base $\mathbf{V}\mathbf{q}$), así que $\mathcal{N}$ solo necesita aportar lo que sea genuinamente **no lineal**. El problema aparece cuando $\mathbf{q}$ es pequeño, exactamente lo que pasa en Cook.

Ejemplo 22 (Una resta que destruye la información, con números ilustrativos). *Supongamos, de forma puramente ilustrativa (no son los números reales de la red entrenada, pero muestran el mecanismo exacto), que para un cierto $\mathbf{q}$ pequeño,*

$$\mathcal{N}(\mathbf{q}) = 1.0000123, \quad \mathcal{N}(\mathbf{0}) + \mathbf{J}_{\mathcal{N}}(\mathbf{0})\mathbf{q} = 1.0000098.$$

*La resta correcta es $\mathbf{q}_s = 0.0000025$: un número pequeño, pero perfectamente válido, la parte no lineal genuina que el modelo necesita. El problema es que un número de 32 bits (float32) guarda solo, aproximadamente, 7 cifras decimales significativas. Los dos números de arriba, **antes** de restar, ya usaron esas 7 cifras para representar el “1.000...”: la información que distingue 0000123 de 0000098 vive justo en el límite de lo que el formato puede guardar con confianza. Si el redondeo de float32 afecta, aunque sea levemente, alguna de las últimas cifras de cualquiera de los dos números grandes, el resultado de la resta, que depende **por completo** de esas últimas cifras, puede cambiar en un 10%, un 50%, o más, de su valor correcto. Con 64 bits (float64, más del doble de cifras significativas) el mismo redondeo existe, pero muy por debajo de las cifras que de verdad importan para la resta: el resultado es esencialmente exacto.*

Las deformaciones que de verdad visita Cook son pequeñas ($|\varepsilon| \sim 10^{-3}$ – 10^{-2} , un panel que se dobla pero no se estira violentamente), así que el $\mathbf{q}$ correspondiente también es pequeño, y la resta de arriba cae exactamente en el régimen del ejemplo: dos números grandes y casi iguales, cuya diferencia pequeña es justamente lo único que le importa al modelo. En las verificaciones originales del decodificador (Capítulo 13 y anteriores), las deformaciones usadas para comprobar la precisión eran, en su mayoría, moderadas o grandes: ahí $\mathbf{q}$ no es pequeño, la resta no es delicada, y float32 funciona perfectamente. El problema estaba escondido, no porque el método estuviera mal derivado, sino porque nunca se había puesto a prueba, con este mecanismo específico, en el régimen de deformaciones pequeñas que Cook sí visita.

Idea clave 35. *No es un error de lógica ni de fórmula: la fórmula de reconstrucción es correcta, y la tangente consistente que se derivó para ella también. Es un requisito de precisión aritmética que solo se manifiesta en un régimen de deformación específico (pequeña), no visitado por las verificaciones que se habían hecho hasta ese momento.*

14.5 La solución, y por qué no cambia nada del modelo

La prueba decisiva: reconstruir, con el mismo modelo entrenado (los mismos pesos, la misma base, absolutamente nada reentrenado), toda la aritmética en línea (*online*) en 64 bits en vez de 32. Resultado: D-HPROM-ANN y HPROM-ANN convergen, ambos, en exactamente tres iteraciones de Newton, en cada uno de los 20 pasos de carga — lo mismo que logran los núcleos certificados, y una confirmación, por primera vez de forma genuinamente multiescala (resolviendo algo real en cada punto de Gauss, no solo evaluando una red ya entrenada), de que la ruta PROM/HPROM es tan robusta frente a Newton como la ruta certificada.

Vale la pena remarcar qué **no** cambió: ni los pesos de la red, ni la base reducida, ni el decodificador, ni ninguna elección de modelado. Lo único que cambió es en qué formato numérico se hace la aritmética de la reconstrucción, exactamente como cambiar de calculadora de 7 dígitos a una de 15 no cambia la operación que se está calculando, solo cuántas cifras sobreviven en el camino.

14.6 Un bono: revisando la convexidad rank-one sin necesitar energía

La Tabla 8 del paper (el chequeo de convexidad rank-one en los estados reales que visita Cook) no podía revisar el modelo de regresión pura (tier 1): ese modelo no tiene ninguna energía de la cual calcular la segunda derivada. Resultó que D-HPROM-ANN y HPROM-ANN tienen exactamente el mismo problema: reconstruyen esfuerzo directamente, sin pasar por una energía.

La solución aprovecha algo especial de la perturbación de rango uno que ya usa el chequeo: si $\mathbf{F}(t) = \mathbf{F}_0 + t \mathbf{a} \otimes \mathbf{b}$ (con $\mathbf{a}, \mathbf{b}$ vectores unitarios), entonces $\mathbf{C}(t) = \mathbf{F}(t)^T \mathbf{F}(t)$ es **exactamente** cuadrática en t (no hay términos de orden superior, es un polinomio de grado 2, punto). Eso significa que la primera y la segunda derivada de la deformación de Green-Lagrange $\mathbf{E}(t)$ en $t = 0$ son fórmulas cerradas, calculables sin ningún límite ni diferencia finita: $\dot{\mathbf{E}} = \frac{1}{2}(\mathbf{F}_0^T \mathbf{A} + \mathbf{A}^T \mathbf{F}_0)$ y $\ddot{\mathbf{E}} = \mathbf{A}^T \mathbf{A}$ (con $\mathbf{A} := \mathbf{a} \otimes \mathbf{b}$). Aplicando la regla de la cadena dos veces a $\mathbf{S}(\mathbf{E}(t)) \cdot \dot{\mathbf{E}}(t)$ se obtiene

$$\left. \frac{d^2}{dt^2} \right|_{t=0} (\text{trabajo a lo largo del camino}) = \dot{\mathbf{E}} \cdot \mathbb{C}_0 \cdot \dot{\mathbf{E}} + \mathbf{S}_0 \cdot \ddot{\mathbf{E}},$$

que solo necesita el esfuerzo $\mathbf{S}_0$ y la tangente $\mathbb{C}_0$ en el estado base: exactamente lo que **todo** modelo de este proyecto ya sabe devolver, con o sin energía. Verificada contra el método original (diferencias finitas sobre la energía real, para los modelos que sí la tienen), esta fórmula coincide a precisión de máquina. Con ella, por primera vez, se pudo revisar rank-one para los seis modelos del proyecto a la vez: certificado y ICKAN, cero violaciones (como siempre); regresión, libre, D-HPROM-ANN y HPROM-ANN, entre 7% y 30% de violaciones en una muestra sintética amplia, pero cero violaciones en los estados reales que Cook visita — la misma conclusión honesta de siempre: una tasa de violación global es una propiedad real del modelo, pero que no aparezca en un problema específico no lo certifica en general, solo descarta ese mecanismo para ese problema en particular.

14.7 Resumen de este capítulo

Idea clave 36. • *PANN, PROM/HPROM y FOM responden la misma pregunta con tres costos y tres niveles de “atajo” distintos; PROM/HPROM sigue evaluando la ley real del material, PANN no.*

- *Precisión igual de buena en la trayectoria held-out no implica robustez igual dentro de un Newton estructural: son preguntas distintas, y hace falta probar la segunda directamente, no inferirla de la primera.*
- *Cuatro sospechosos (tangente, elipticidad local, rank-one en el estado final, rank-one en toda la trayectoria) se descartaron uno por uno con pruebas directas antes de encontrar la causa real.*

- *La causa real: una resta de reconstrucción ($\mathcal{N}(\mathbf{q})$ menos su propia aproximación lineal en $\mathbf{q} = \mathbf{0}$) que, para el $\mathbf{q}$ pequeño que Cook produce, resta dos números casi iguales y pierde casi toda su precisión en float32. No visitado por las verificaciones anteriores, hechas a deformaciones más grandes.*
- *La solución (hacer esa aritmética en float64) no cambia ningún peso ni ninguna elección de modelado: solo cuántas cifras sobreviven la resta.*
- *Bono: una fórmula de curvatura rank-one que solo necesita esfuerzo y tangente, no energía, extiende el chequeo a los tres modelos que antes no se podían revisar así.*

Antes de seguir: con el ejemplo numérico de la Sección 14.4, repite la resta guardando cada número a solo 5 cifras decimales en vez de 7, y compara qué tan distinto sale $\mathbf{q}_s$. Cuando estés listo, seguimos con el resto de los resultados numéricos del paper, en orden.

References

- [1] P. Thakolkaran, Y. Guo, S. Saini, M. Peirlinck, B. Alheit, and S. Kumar. Can KAN CANs? Input-convex Kolmogorov–Arnold networks (KANs) as hyperelastic constitutive artificial neural networks (CANs). *Computer Methods in Applied Mechanics and Engineering*, 443:118089, 2025.
- [2] B. Amos, L. Xu, and J. Z. Kolter. Input convex neural networks. In *Proceedings of the 34th International Conference on Machine Learning*, 2017.
- [3] A. J. M. Spencer. Theory of invariants. In: A. C. Eringen (ed.), *Continuum Physics, Volume I: Mathematics*, pp. 239–353. Academic Press, New York, 1971.
- [4] A. J. M. Spencer. Constitutive theory for strongly anisotropic solids. In: A. J. M. Spencer (ed.), *Continuum Theory of the Mechanics of Fibre-Reinforced Composites*, CISM Courses and Lectures No. 282, pp. 1–32. Springer-Verlag, Vienna, 1984.
- [5] J. P. Boehler. Introduction to the invariant formulation of anisotropic constitutive equations. In: J. P. Boehler (ed.), *Applications of Tensor Functions in Solid Mechanics*, CISM Courses and Lectures No. 292, pp. 13–30. Springer-Verlag, Vienna, 1987.
- [6] J. Schröder and P. Neff. Invariant formulation of hyperelastic transverse isotropy based on polyconvex free energy functions. *International Journal of Solids and Structures*, 40(2):401–445, 2003.
- [7] T. C. Gasser, R. W. Ogden, and G. A. Holzapfel. Hyperelastic modelling of arterial layers with distributed collagen fibre orientations. *Journal of the Royal Society Interface*, 3(6):15–35, 2006.
- [8] Z. P. Bažant and B. H. Oh. Efficient numerical integration on the surface of a sphere. *ZAMM: Journal of Applied Mathematics and Mechanics*, 66(1):37–49, 1986.